Universidad César Vallejo

ESCUELA DE POSGRADO

PROGRAMA ACADÉMICO DE MAESTRÍA EN INTELIGENCIA ARTIFICIAL

Aplicación de machine learning para predecir la flotación de relaves de lixiviación, Lima 2026

Trabajo de investigación para obtener el grado de maestro en Inteligencia Artificial

Autor(es):

Barboza Duran, Edwin Miguel (orcid.org/0009-0003-8589-8277)

Ruiz Torres, Alfonso (orcid.org/0009-0004-2440-6563)

Asesor(a)(es):

MSc. Quispe Llacctarimay, Ruben (orcid.org/0000-0003-2550-1840)

Línea de investigación:

Machine Learning para gestión de decisiones empresariales

Línea de responsabilidad social universitaria:

Desarrollo económico, empleo y emprendimiento

LIMA — PERÚ

2026

Declaratoria de Autenticidad del Asesor

Yo, QUISPE LLACCTARIMAY RUBEN, docente de la ESCUELA DE POSGRADO del programa de MAESTRÍA EN INTELIGENCIA ARTIFICIAL de la UNIVERSIDAD CÉSAR VALLEJO SAC – LIMA NORTE, asesor del Trabajo de Investigación titulado: “Aplicación de machine learning para predecir la flotación de relaves de lixiviación, Lima 2026”, cuyos autores son BARBOZA DURAN EDWIN MIGUEL y RUIZ TORRES ALFONSO, constato que la investigación tiene un índice de similitud de 7%, verificable en el reporte de originalidad del programa Turnitin, el cual ha sido realizado sin filtros ni exclusiones.

He revisado dicho reporte y concluyo que cada una de las coincidencias detectadas no constituye plagio. A mi leal saber y entender, el Trabajo de Investigación cumple con todas las normas para el uso de citas y referencias establecidas por la Universidad César Vallejo.

En tal sentido, asumo la responsabilidad que corresponda ante cualquier falsedad, ocultamiento u omisión tanto de los documentos como de la información aportada, por lo cual me someto a lo dispuesto en las normas académicas vigentes de la Universidad César Vallejo.

Lima, 12 de octubre de 2026

Apellidos y nombres del asesor	**Firma**
QUISPE LLACCTARIMAY, RUBEN DNI: 43512517 ORCID: 0000-0003-2550-1840	

Declaratoria de Originalidad de los Autores

Nosotros, BARBOZA DURAN EDWIN MIGUEL y RUIZ TORRES ALFONSO, estudiantes de la ESCUELA DE POSGRADO del programa de MAESTRÍA EN INTELIGENCIA ARTIFICIAL de la UNIVERSIDAD CÉSAR VALLEJO SAC – LIMA NORTE, declaramos bajo juramento que todos los datos e información que acompañan el Trabajo de Investigación titulado: “Aplicación de machine learning para predecir la flotación de relaves de lixiviación, Lima 2026”, son de nuestra autoría; por lo tanto, declaramos que el Trabajo de Investigación:

1. No ha sido plagiado ni total ni parcialmente.
2. Hemos mencionado todas las fuentes empleadas, identificando correctamente toda cita textual o de paráfrasis proveniente de otras fuentes, conforme a la norma IEEE.
3. No ha sido publicado ni presentado anteriormente para la obtención de otro grado académico o título profesional.
4. Los datos presentados en los resultados no han sido falseados, ni duplicados, ni copiados.
5. Las herramientas de inteligencia artificial se emplearon solo como apoyo, bajo nuestra supervisión y conforme a la normativa de originalidad de la universidad, sin sustituir nuestra autoría en el análisis ni en las conclusiones.

En tal sentido, asumimos la responsabilidad que corresponda ante cualquier falsedad, ocultamiento u omisión tanto de los documentos como de la información aportada, por lo cual nos sometemos a lo dispuesto en las normas académicas vigentes de la Universidad César Vallejo.

Lima, 12 de octubre de 2026

Apellidos y nombres de los autores	**Firma**
BARBOZA DURAN, EDWIN MIGUEL DNI: 20119834 ORCID: 0009-0003-8589-8277	
RUIZ TORRES, ALFONSO DNI: 40445900 ORCID: 0009-0004-2440-6563	

Dedicatoria

A nuestras familias, por su amor, su paciencia y su apoyo incondicional durante cada etapa de esta maestría. Las horas que este trabajo les restó se convirtieron, gracias a su comprensión, en el impulso para culminarlo.

A los operadores, metalurgistas y analistas de laboratorio de las plantas concentradoras del país, cuyo trabajo diario frente a un proceso tan variable como la flotación inspiró esta investigación.

Los autores

Agradecimiento

A la Universidad César Vallejo y a su Escuela de Posgrado, por brindarnos, a través del Programa Académico de Maestría en Inteligencia Artificial, la formación y los espacios académicos que hicieron posible esta investigación.

A nuestro asesor, MSc. Ruben Quispe Llacctarimay, por su orientación metodológica, sus observaciones oportunas y la exigencia académica con que acompañó cada etapa de este trabajo.

A los docentes del programa, cuyas enseñanzas en aprendizaje automático, ciencia de datos y metodología de la investigación sentaron las bases técnicas de este estudio.

A la empresa titular de la planta concentradora en la región de Lima, que por razones de confidencialidad no se nombra, por autorizar el uso de sus registros operacionales y metalúrgicos; y a su personal de operaciones y de laboratorio metalúrgico, por compartir con generosidad su conocimiento del proceso.

A nuestros compañeros de la maestría, por el intercambio de ideas, el trabajo en equipo y el aliento constante a lo largo de este camino.

Índice de Contenidos

Declaratoria de Autenticidad del Asesor ii
Declaratoria de Originalidad de los Autores iii
Dedicatoria iv
Agradecimiento v
Índice de Contenidos vi
Índice de Tablas vii
Índice de Figuras viii
Lista de abreviaturas y siglas ix
Resumen xii
Abstract xiii
I. Introducción 1
II. Metodología 39
III. Resultados 59
IV. Discusión de resultados 78
V. Conclusiones 87
VI. Recomendaciones 89
Referencias 91
Anexos 102

Índice de Tablas

Tabla 1. Rangos de interpretación de las métricas de desempeño 29
Tabla 2. Desempeño predictivo reportado en estudios recientes de flotación 31
Tabla 3. Criterios de decisión para el contraste de las hipótesis 37
Tabla 4. Estadísticos descriptivos de las variables objetivo por subconjunto 59
Tabla 5. Estadísticos descriptivos de las variables predictoras por subconjunto 61
Tabla 6. Desempeño predictivo de los modelos en el conjunto de prueba 64
Tabla 7. Desempeño de los modelos en la predicción de la recuperación de Au (%) por subconjunto 66
Tabla 8. Desempeño de los modelos en la predicción de la ley de Au en el concentrado (g/t) por subconjunto 69
Tabla 9. Desempeño de los modelos en la predicción del consumo específico de reactivos (kg/t) por subconjunto 72
Tabla 10. Contraste de las hipótesis Ho1-Hi1, Ho2-Hi2 y Ho3-Hi3 en el conjunto de prueba 75
Tabla 11. Contraste de la hipótesis Ho4-Hi4 entre Random Forest y XGBoost en el conjunto de prueba 76

Índice de Figuras

Figura 1. Distribución de las variables objetivo por subconjunto 60
Figura 2. Comparación del R² de Random Forest y XGBoost en el conjunto de prueba 65
Figura 3. Valores observados frente a valores predichos de la recuperación de Au por Random Forest en el conjunto de prueba 67
Figura 4. Importancia de las variables predictoras en los modelos de recuperación de Au 68
Figura 5. Valores observados frente a valores predichos de la ley de Au en el concentrado por Random Forest en el conjunto de prueba 70
Figura 6. Importancia de las variables predictoras en los modelos de ley de Au en el concentrado 71
Figura 7. Valores observados frente a valores predichos del consumo específico de reactivos por XGBoost en el conjunto de prueba 73
Figura 8. Importancia de las variables predictoras en los modelos de consumo específico de reactivos 74

Lista de abreviaturas y siglas

A continuación se presentan, en orden alfabético, las abreviaturas, siglas, símbolos químicos y unidades de medida empleados en el documento. Cuando la sigla procede del inglés, se indica entre paréntesis su forma original.

Abreviatura o símbolo	Significado
Abreviaturas y siglas	
%IncMSE	Incremento porcentual del error cuadrático medio al permutar una variable en Random Forest (medida de importancia de variables)
200M_ccPy	Porcentaje pasante la malla 200 en el bloque ccPy
AdaBoost	Potenciación adaptativa (Adaptive Boosting)
ANFIS	Sistema de inferencia neurodifusa adaptativa (Adaptive Neuro-Fuzzy Inference System)
ANN	Red neuronal artificial (Artificial Neural Network)
ANOVA	Análisis de varianza (Analysis of Variance)
CatBoost	Potenciación del gradiente para variables categóricas (Categorical Boosting)
ccPy	Sufijo con el que el registro de planta identifica un bloque de determinaciones químicas y físicas (leyes, humedad y granulometría); su punto de muestreo se examina en la discusión
CNN	Red neuronal convolucional (Convolutional Neural Network)
CSV	Valores separados por comas (Comma-Separated Values)
CV	Coeficiente de variación
DE	Desviación estándar
DM	Estadístico de la prueba de Diebold-Mariano
DM*	Estadístico de Diebold-Mariano con la corrección de Harvey, Leybourne y Newbold
DNN	Red neuronal profunda (Deep Neural Network)
DT	Árbol de decisión (Decision Tree)
ExtraTrees	Árboles extremadamente aleatorizados (Extremely Randomized Trees)
FCN_Fin	Concentración final de cianuro libre
FCN_Inic	Concentración inicial de cianuro libre
Gain	Ganancia relativa de una variable en XGBoost (medida de importancia de variables)
GBDT	Árboles de decisión con potenciación del gradiente (Gradient Boosting Decision Trees)
GBR	Regresión por potenciación del gradiente (Gradient Boosting Regressor)
GPR	Regresión por procesos gaussianos (Gaussian Process Regression)
GRU	Unidad recurrente con compuertas (Gated Recurrent Unit)
HE1–HE4	Hipótesis específicas 1 a 4
HG	Hipótesis general
Hi; Hi1–Hi4	Hipótesis alterna general; hipótesis alternas específicas 1 a 4
Ho; Ho1–Ho4	Hipótesis nula general; hipótesis nulas específicas 1 a 4
HyFIS	Sistema híbrido de inferencia neurodifusa (Hybrid Neural Fuzzy Inference System)

Abreviatura o símbolo	Significado
IA	Inteligencia artificial
ICC	Coeficiente de correlación intraclase (Intraclass Correlation Coefficient)
IEEE	Instituto de Ingenieros Eléctricos y Electrónicos (Institute of Electrical and Electronics Engineers)
K30, K50, K80	Tamaños de partícula por debajo de los cuales se encuentra el 30 %, el 50 % y el 80 % del material
L.Xx ccPy	Ley del elemento Xx (Ag, As, Cu, Fe, Pb o Zn) en el bloque ccPy, según las etiquetas de las figuras de importancia
LightGBM	Máquina ligera de potenciación del gradiente (Light Gradient Boosting Machine)
LSTM	Red de memoria de corto y largo plazo (Long Short-Term Memory)
MAE	Error absoluto medio (Mean Absolute Error)
MAPE	Error porcentual absoluto medio (Mean Absolute Percentage Error)
MCMC	Monte Carlo basado en cadenas de Markov (Markov Chain Monte Carlo)
MIBC	Metil isobutil carbinol (espumante)
MLA	Analizador de liberación mineral (Mineral Liberation Analyser)
MLP	Perceptrón multicapa (Multilayer Perceptron)
MRE	Error relativo medio (Mean Relative Error)
MSE	Error cuadrático medio (Mean Squared Error)
NA	Dato faltante (Not Available)
OE1–OE4	Objetivos específicos 1 a 4
PAX	Xantato amílico de potasio (Potassium Amyl Xanthate), comercializado como Z-6
PDF	Formato de documento portátil (Portable Document Format)
PE1–PE4	Problemas específicos 1 a 4
PINN	Red neuronal informada por la física (Physics-Informed Neural Network)
PLC	Controlador lógico programable (Programmable Logic Controller)
Q1, Q3	Primer y tercer cuartil
R^2	Coeficiente de determinación
Red_E	Reducción porcentual del error respecto al modelo base
ResNet	Red neuronal residual (Residual Network)
RF	Random Forest (bosque aleatorio)
RMSE	Raíz del error cuadrático medio (Root Mean Squared Error)
ROC	Característica operativa del receptor (Receiver Operating Characteristic)
SCADA	Supervisión, control y adquisición de datos (Supervisory Control and Data Acquisition)
SEM/EDS	Microscopía electrónica de barrido con espectroscopía de rayos X por dispersión de energía (Scanning Electron Microscopy / Energy-Dispersive X-ray Spectroscopy)
SEX	Etilxantato de sodio (Sodium Ethyl Xanthate)
SHAP	Explicaciones aditivas de Shapley (SHapley Additive exPlanations)
SIPX	Xantato isopropílico de sodio (Sodium Isopropyl Xanthate), comercializado como Z-11
SVM	Máquina de vectores de soporte (Support Vector Machine)

Abreviatura o símbolo	Significado
SVR	Regresión de vectores de soporte (Support Vector Regression)
VAF	Varianza explicada (Variance Accounted For)
XGBoost	Potenciación extrema del gradiente (eXtreme Gradient Boosting)
XRD	Difracción de rayos X (X-Ray Diffraction)
Z-6, Z-11	Denominaciones comerciales del PAX y del SIPX, respectivamente
Símbolos químicos	
Ag	Plata
As	Arsénico
Au	Oro
CN	Cianuro
Cu	Cobre
Fe	Hierro
H_2O	Agua (humedad del bloque ccPy)
O_2	Oxígeno (oxígeno disuelto)
P_2O_5	Pentóxido de fósforo
Pb	Plomo
SiO_2	Dióxido de silicio (sílice)
Zn	Zinc
$ZnSO_4$	Sulfato de zinc
Unidades de medida	
%	Porcentaje
g	Gramo
g/L	Gramos por litro
g/t	Gramos por tonelada
g/TM	Gramos por tonelada métrica
kg	Kilogramo
kg/t	Kilogramos por tonelada
kPa	Kilopascal
m^3/h	Metros cúbicos por hora
mg/L	Miligramos por litro
min	Minuto
mm	Milímetro
mV	Milivoltio
Nm^3/h	Metros cúbicos normales por hora
pp	Puntos porcentuales
ppm	Partes por millón
t	Tonelada
µm	Micrómetro

Resumen

El objetivo fue determinar en qué medida un modelo predictivo basado en inteligencia artificial permitía predecir la flotación de relaves de lixiviación en una planta concentradora de la región de Lima, en el marco del Objetivo de Desarrollo Sostenible 9. La investigación fue aplicada y cuantitativa, con diseño no experimental, transversal y predictivo. Se analizaron 547 registros operacionales y metalúrgicos de enero a setiembre de 2026, con 38 variables predictoras, y se entrenaron Random Forest y XGBoost para estimar la recuperación de Au, la ley de Au en el concentrado y el consumo específico de reactivos. Con una partición cronológica (382 registros de entrenamiento, 82 de validación y 83 de prueba), los modelos se compararon con un modelo base de media histórica mediante R^2, MAE, RMSE y MAPE, y entre sí con la prueba de Diebold-Mariano. En prueba, Random Forest alcanzó un R^2 de 0.973 en la recuperación (MAPE = 0.94 %) y de 0.985 en la ley (MAPE = 0.46 %), y XGBoost un R^2 de 0.897 en el consumo (MAPE = 8.92 %), con reducciones del MAE y del RMSE superiores a 85 % frente al modelo base. Random Forest fue significativamente superior en la recuperación y XGBoost en el consumo ($p < 0.05$), sin diferencia significativa en la ley. Se concluyó que el modelo predijo con exactitud la flotación de relaves de lixiviación y puede servir como sensor blando de apoyo a la decisión, siempre que se verifique la disponibilidad temporal de las variables de laboratorio y se reentrene periódicamente.

Palabras clave: aprendizaje automático, flotación, relaves de lixiviación, sensor blando, XGBoost.

Abstract

The objective was to determine the extent to which an artificial intelligence-based predictive model could predict the flotation of leach tailings at a concentrator plant in the Lima region of Peru, within the framework of Sustainable Development Goal 9. The research was applied and quantitative, with a non-experimental, cross-sectional, and predictive design. A total of 547 operational and metallurgical records from January to September 2026, with 38 predictor variables, were analyzed, and Random Forest and XGBoost were trained to estimate Au recovery, Au grade in the concentrate, and specific reagent consumption. Using a chronological split (382 training, 82 validation, and 83 test records), the models were compared with a historical-mean baseline using R^2, MAE, RMSE, and MAPE, and with each other using the Diebold-Mariano test. On the test set, Random Forest achieved an R^2 of 0.973 for recovery (MAPE = 0.94%) and 0.985 for grade (MAPE = 0.46%), and XGBoost an R^2 of 0.897 for consumption (MAPE = 8.92%), with MAE and RMSE reductions above 85% relative to the baseline. Random Forest was significantly better for recovery and XGBoost for consumption ($p < 0.05$), with no significant difference for grade. It was concluded that the model accurately predicted leach tailings flotation and can serve as a soft sensor to support decision-making, provided that the time at which laboratory variables become available is verified and the models are retrained periodically.

Keywords: machine learning, flotation, leach tailings, soft sensor, XGBoost.

I. Introducción

En el ámbito internacional, la industria minera enfrentó una presión creciente por la reducción de las reservas de alta ley, el incremento de los costos operativos y la necesidad de cumplir estándares ambientales cada vez más rigurosos. En ese contexto, los relaves mineros dejaron de verse solo como residuos o pasivos ambientales y pasaron a considerarse fuentes secundarias de metales, ya que aún contenían minerales valiosos que no se extrajeron en procesos previos. Esta transición se guio por los principios de economía circular, eficiencia en el uso de los recursos y disminución de los riesgos ambientales vinculados a la disposición de los residuos mineros [1]. Kursunoglu [2] afirmó que el reprocesamiento de relaves facilitaba la recuperación de materiales críticos y, al mismo tiempo, reducía los impactos ambientales y los costos de rehabilitación de los depósitos.

Sin embargo, reprocesar por flotación el relave de lixiviación planteó un problema técnico complejo, debido a la elevada variabilidad mineralógica, granulométrica y fisicoquímica del material alimentado. La flotación se mostró muy sensible a la interacción de variables como el pH, densidad de pulpa, dosificación de reactivos, tiempo de residencia, potencial redox, caudal de aire, tamaño de partícula y composición mineralógica. Esta interacción generó comportamientos no lineales que dificultaron el control estable del proceso y la predicción de indicadores críticos como la recuperación metalúrgica y la ley del concentrado. Szmigiel et al. [3] señalaron que la flotación involucraba varios subprocesos interconectados (colisión, adhesión, transporte en la zona de pulpa y drenaje en la espuma), razón por la cual su monitoreo y optimización requerían modelos capaces de capturar relaciones complejas entre variables operacionales y metalúrgicas [4].

Frente a esta problemática, la inteligencia artificial se consolidó como una alternativa útil para predecir y mejorar los procesos de flotación. Los modelos de aprendizaje automático permitieron procesar grandes volúmenes de datos industriales, detectar patrones ocultos y construir sensores blandos capaces de estimar variables difíciles de medir en línea, como la ley del concentrado o la eficiencia de separación [5]. Estudios recientes mostraron que los modelos híbridos, las redes neuronales, los gemelos digitales, los bosques aleatorios, los algoritmos genéticos y los modelos de potenciación del gradiente se emplearon con éxito para estimar variables

metalúrgicas y recomendar condiciones operativas óptimas [3], [6]. Devasahayam [7] demostró que, en la flotación de oro, el aprendizaje automático explicable, combinado con valores SHAP, permitía identificar las variables que más incidían en la recuperación y la ley del oro, incluso con conjuntos de datos pequeños. Este hallazgo resultó relevante para las operaciones en las que la obtención de datos experimentales era costosa o limitada.

En el ámbito nacional, la minería fue uno de los sectores económicos más estratégicos del Perú, aunque también afrontó retos vinculados con la sostenibilidad ambiental, la eficiencia operativa y el manejo de relaves. La adopción de tecnologías digitales en la minería peruana avanzó de forma progresiva mediante gemelos digitales, sistemas integrados de control, análisis de datos, automatización, inteligencia artificial y aprendizaje automático. Chávez Quispe [8] informó que varias empresas mineras nacionales incorporaban modelos predictivos e inteligencia artificial con el fin de mejorar sus procesos, aumentar la recuperación metalúrgica y tomar decisiones basadas en datos. Sin embargo, su implementación no fue homogénea en las plantas de beneficio del país, y muchas operaciones siguieron dependiendo de ajustes manuales, criterios empíricos del operador y herramientas estadísticas tradicionales.

En el ámbito local, la problemática se presentó en una planta concentradora en la región de Lima que procesaba relaves de lixiviación procedentes del acopio de minerales de distintos yacimientos. Esta condición generó una alimentación altamente heterogénea, caracterizada por variaciones en las leyes de oro y plata, así como por la presencia de elementos asociados como cobre, plomo, zinc y arsénico. Según las investigaciones de Berrospi Borda [9] y Mory Blas [10], desarrolladas en plantas peruanas de tratamiento de relaves auríferos, la variabilidad de la alimentación constituyó uno de los principales factores que afectaron la estabilidad del proceso de flotación y dificultaron la obtención de recuperaciones metalúrgicas constantes.

Los datos de la planta del primer trimestre de 2026 (enero a marzo) comprendieron 181 registros por guardia de operación, 180 de ellos con resultado metalúrgico, y permitieron dimensionar el problema [11]. En ese periodo, la recuperación de oro promedió 79.78 %, con una desviación estándar de 7.29 puntos porcentuales y un coeficiente de variación de 9.13 %. Los valores por turno oscilaron entre 47.45 % y

90.70 %, y en 18 de ellos (10.0 % de los registros con resultado metalúrgico) la recuperación cayó por debajo de 70 %; a nivel mensual, la media pasó de 77.45 % en enero y 77.84 % en febrero a 83.86 % en marzo. Esta dispersión reflejó la dificultad del proceso para sostener un rendimiento metalúrgico constante frente a una alimentación heterogénea y a condiciones de operación cambiantes. La ley de oro en el concentrado mostró un comportamiento semejante: promedió 7.65 g/t, con una desviación estándar de 0.73 g/t y un coeficiente de variación de 9.51 %, osciló por turno entre 5.62 g/t y 9.64 g/t y registró medias mensuales de 7.54 g/t, 7.67 g/t y 7.75 g/t. Aunque la tendencia mensual fue ligeramente ascendente, la amplitud entre turnos confirmó que la calidad del producto final no se mantuvo estable.

El consumo de reactivos mostró fluctuaciones igualmente preocupantes. El consumo específico total promedió 3.98 kg/t, con un coeficiente de variación de 44.84 % y valores por turno entre 1.20 kg/t y 16.88 kg/t, y su media mensual aumentó de 3.12 kg/t en enero a 4.14 kg/t en febrero y 4.72 kg/t en marzo [11]. El sulfato de cobre pentahidratado, el reactivo de mayor dosificación media, osciló entre 0.18 kg/t y 7.39 kg/t, con una media de 1.38 kg/t, y su media mensual descendió de 1.98 kg/t en enero a 1.71 kg/t en febrero y 0.49 kg/t en marzo. Esa reducción coincidió con una mejora de la recuperación media, de 77.45 % a 83.86 %, y con un leve aumento de la ley, de 7.54 g/t a 7.75 g/t, mientras que el consumo específico total siguió en aumento, lo que sugirió que la dosificación de reactivos se ajustó sin un criterio cuantitativo que la vinculara con los indicadores metalúrgicos. El metabisulfito de sodio varió entre 0 kg/t, en turnos sin dosificación, y 4.09 kg/t, con una media de 1.05 kg/t y el consumo más elevado en febrero (1.25 kg/t). Los colectores xantato PAX + SIPX (Z-6 + Z-11) variaron entre 0.03 kg/t y 1.53 kg/t, con una media de 0.36 kg/t; el MIBC, entre 0 kg/t y 0.43 kg/t, con una media de 0.07 kg/t; y el antiespumante, entre 0 kg/t y 0.98 kg/t, con una media de 0.04 kg/t. Estas variaciones reflejaron ajustes operativos no estandarizados, que respondieron más a criterios empíricos que a una dosificación respaldada por modelos predictivos, en un sistema en el que la activación con cobre y la depresión con metabisulfito modifican de manera sensible la flotabilidad de la pirita aurífera [12], [13].

El proceso operativo de la planta comprendió tres etapas secuenciales: extracción de relaves por repulpeo, detoxificación de relaves cianurados y flotación convencional [11]. Una condición técnica particular fue la ausencia de una etapa de molienda, ya

que el material ingresaba al circuito con una granulometría promedio de 89.67 % pasante la malla −200, con valores por turno entre 79.08 % y 97.50 %, lo que impidió corregir los problemas de liberación mineral durante el proceso. Esta condición resultó crítica porque, en los relaves de cianuración, el oro remanente suele quedar encapsulado en sulfuros como la pirita, cuyas superficies pueden presentar películas pasivantes y cianuro residual que deprimen su flotación [14], [15]. En consecuencia, la flotación se volvió inestable, compleja y poco predecible. Sus manifestaciones más relevantes fueron las oscilaciones de la recuperación metalúrgica, con un coeficiente de variación de 9.13 %; un consumo de reactivos fluctuante, que en algunos turnos llegó a 16.88 kg/t, más de cuatro veces la media trimestral de 3.98 kg/t; las dificultades recurrentes para mantener la ley del concentrado dentro de márgenes estables, pues varió por turno entre 5.62 g/t y 9.64 g/t; y las pérdidas económicas asociadas con la ineficiencia operativa.

Debido a su elevado costo, sus largos tiempos de respuesta y su escasa frecuencia de actualización, los métodos convencionales de caracterización mineralógica no resultaron apropiados para el control en tiempo real. Esta restricción coincidió con lo señalado por Nasiri Abarbekouh, Iqbal y Särkkä [16]: la medición directa de variables críticas en metalurgia normalmente exigía equipos costosos y mantenimiento especializado, de ahí que los modelos predictivos o sensores blandos constituyeran una opción más económica y rápida.

No obstante, la planta disponía de una base histórica de datos recopilados por su sistema SCADA/PLC, que incluía variables como caudales, densidades de pulpa, pH, potencial redox, dosificación de reactivos y tiempos de residencia. Estos datos ofrecían una oportunidad valiosa para desarrollar modelos predictivos basados en inteligencia artificial, capaces de aprender el comportamiento del proceso a partir de las variables operativas disponibles. Sin embargo, al inicio del estudio no existía un modelo que empleara únicamente variables operativas para predecir la ley del concentrado o la recuperación metalúrgica, ni una herramienta que sugiriera modificaciones en tiempo real para optimizar la dosificación de reactivos. Ante esta carencia, las decisiones dependían en gran medida de la experiencia del operador y de análisis posteriores al proceso, lo que reducía la capacidad de respuesta ante cambios en la alimentación.

A partir de la revisión de la literatura científica, y conforme a los criterios básicos para identificar problemáticas, se reconocieron cinco condiciones que justificaron abordar el problema. En primer lugar, se identificó un vacío de conocimiento, puesto que en la literatura revisada no se hallaron estudios que desarrollaran modelos predictivos o sensores blandos para relaves auríferos previamente lixiviados y reprocesados por flotación a escala industrial; además, Gomez-Flores et al. [17] advirtieron que las aplicaciones de inteligencia artificial en la concentración de minerales rara vez incorporaron las propiedades fundamentales de las partículas como variables de entrada. En segundo lugar, se observaron limitaciones metodológicas, ya que parte de la evidencia provino de conjuntos de datos pequeños o de laboratorio, como las once observaciones experimentales analizadas por Devasahayam [7], o de datos generados mediante un gemelo digital [16], lo que restringió la validez externa de sus resultados. En tercer lugar, se constató una falta de contextualización acompañada de un sesgo geográfico de la evidencia, porque los estudios revisados se desarrollaron con relaves fosfáticos, minerales de hierro o menas auríferas frescas en Estados Unidos, China, Australia y Finlandia, sin considerar la alimentación heterogénea de las plantas peruanas de relaves [7], [16], [18], [19].

En cuarto lugar, se reconoció una fragmentación del conocimiento y una ausencia de enfoques comparativos, dado que los trabajos revisados predijeron, por lo general, una sola respuesta metalúrgica, como ocurrió con la recuperación en He et al. [20] o con la ley en Devasahayam [21], sin integrar el consumo de reactivos ni comparar algoritmos de ensamble bajo un mismo protocolo de validación temporal. Finalmente, se evidenció una escasa aplicabilidad práctica, pues Estay et al. [22] señalaron que la escasez de datos confiables y la ausencia de sensores en línea limitaron la transferencia de los modelos de aprendizaje automático a la operación industrial, mientras que Lartey et al. [23] indicaron que los datos industriales de flotación solían estar afectados por valores atípicos que reducían la exactitud y la capacidad de generalización de los modelos, por lo que su adopción exigía procedimientos rigurosos de aseguramiento de la calidad de los datos.

En resumen, la realidad problemática respondió a la interacción de tres elementos: la alta variabilidad de los relaves lixiviados, la complejidad no lineal del proceso de flotación y el limitado aprovechamiento de los datos operacionales existentes. Esta investigación se alineó con el Objetivo de Desarrollo Sostenible 9: Industria,

Innovación e Infraestructura, cuyo propósito es construir infraestructuras resilientes, promover la industrialización inclusiva y sostenible y fomentar la innovación, específicamente con la meta 9.4, que busca modernizar las industrias para hacerlas sostenibles, utilizando los recursos con mayor eficiencia y adoptando tecnologías y procesos industriales ambientalmente racionales. El estudio contribuyó a dicho objetivo al proponer un modelo predictivo basado en inteligencia artificial que apoyara la optimización del consumo de reactivos, la reducción de la variabilidad operativa y una recuperación más eficiente de metales preciosos a partir de relaves, con lo cual se reduciría el impacto ambiental de los pasivos mineros.

Ante esta situación, se formuló la siguiente interrogante general: ¿En qué medida el modelo predictivo basado en inteligencia artificial permite predecir la flotación de relaves de lixiviación, Lima 2026?

Además, se propusieron las siguientes interrogantes específicas: (PE1) ¿En qué medida el modelo predictivo basado en inteligencia artificial permite predecir el rendimiento de la recuperación metálica, Lima 2026? (PE2) ¿En qué medida el modelo predictivo basado en inteligencia artificial permite predecir la calidad del concentrado, Lima 2026? (PE3) ¿En qué medida el modelo predictivo basado en inteligencia artificial permite predecir la eficiencia en el uso de insumos químicos, Lima 2026? (PE4) ¿Cuál de los modelos, Random Forest o XGBoost, presenta un mejor desempeño en la predicción de la flotación de relaves de lixiviación, Lima 2026?

La investigación se justificó desde cuatro perspectivas complementarias, ya que respondió a una necesidad real de la operación metalúrgica [22].

En primer lugar, en el plano teórico, el estudio buscó contribuir al conocimiento sobre la aplicación de la inteligencia artificial en la metalurgia extractiva, en particular en la mejora de procesos de flotación afectados por la variabilidad mineralógica. Aunque tradicionalmente este problema se abordó mediante la caracterización mineralógica directa, estas técnicas presentaban restricciones cuando se necesitaba una respuesta rápida o en tiempo real durante la operación metalúrgica [17], [22].

En este escenario, se detectó un vacío científico importante: los sensores blandos aplicados específicamente a relaves lixiviados eran escasos o inexistentes, lo que limitaba la posibilidad de estimar variables críticas del proceso sin depender solo de mediciones directas. Además, se observó una escasez de investigaciones enfocadas

en la minería aurífera del Perú, particularmente en operaciones con una composición mineralógica muy variable y donde los relaves lixiviados tenían el potencial de ser una fuente para recuperar metales. Tampoco existían modelos explicables basados en inteligencia artificial para la flotación de relaves lixiviados, ya que muchos métodos predictivos priorizaban la precisión sobre la comprensión de cómo las variables mineralógicas y operativas afectaban el rendimiento del proceso [7], [17].

Por lo tanto, esta investigación aportó un enfoque novedoso, basado en datos operativos reales, para desarrollar un modelo inteligente interpretable y aplicable a la realidad de los relaves lixiviados de las minas de oro peruanas. Este aporte contribuyó al avance teórico en el desarrollo de modelos explicables y sensores blandos para flotación, con el propósito de optimizar los procedimientos metalúrgicos en situaciones de incertidumbre mineralógica y operativa [7], [16].

En segundo lugar, en el plano metodológico, el estudio siguió un procedimiento sistemático para seleccionar, entrenar, validar y comparar algoritmos de aprendizaje automático aplicados a la flotación de relaves de lixiviación. Los modelos se eligieron atendiendo a la naturaleza de los datos, al tipo de problema, a su capacidad para detectar relaciones no lineales, a su desempeño en aplicaciones metalúrgicas y a su interpretabilidad [20], [24].

Se optó por dos modelos de ensamble basados en árboles de decisión, Random Forest y XGBoost, porque suelen ofrecer un buen desempeño en problemas con variables metalúrgicas, operacionales y fisicoquímicas que contenían interacciones entre variables, relaciones no lineales y posibles efectos de ruido experimental. Random Forest se incorporó por su resistencia al sobreajuste y su capacidad para estimar la importancia relativa de las variables [25]; XGBoost, por su eficacia en problemas de clasificación y regresión con datos tabulares y por su capacidad para reducir el error de forma progresiva mediante boosting [26].

Ambos algoritmos manejan bien las relaciones no lineales y los conjuntos de datos industriales con muchas variables, como los que genera una planta de flotación. Para elegir entre ellos, se compararon con las métricas R^2, MAE, RMSE y MAPE y, para juzgar si sus diferencias eran significativas, con la prueba de Diebold-Mariano [20], [27].

El procedimiento permitió decidir qué modelo convenía para cada respuesta del proceso atendiendo a su precisión, pero también a la estabilidad de sus errores y a la posibilidad de interpretar sus predicciones. Al documentar la partición de los datos, el modelo de referencia y los criterios de decisión, el estudio quedó en condiciones de ser replicado y de servir como punto de comparación para trabajos posteriores sobre concentración de minerales [24], [28].

En tercer lugar, en el plano práctico, la investigación fue particularmente relevante porque abrió la posibilidad de usar herramientas predictivas directamente en la operación metalúrgica. Mediante modelos entrenados con datos históricos de los sistemas SCADA o PLC de la planta, se buscó anticipar con exactitud el comportamiento de la flotación, en particular la recuperación de oro, la ley del concentrado y el consumo específico de reactivos [6], [16].

Desde una perspectiva operativa, estos modelos permitirían a los ingenieros disponer de estimaciones oportunas para ajustar variables esenciales, como la dosificación de reactivos, el control del pH, el tiempo de residencia y otros factores vinculados con la productividad metalúrgica. Por ello, se esperó que el modelo aportara criterios cuantitativos para racionalizar el uso de reactivos sin perjudicar la calidad del producto final ni la eficiencia del proceso, en la línea de los sistemas de monitoreo y optimización de circuitos de flotación basados en datos [4], [29].

Además, se planteó que el modelo predictivo podía estimar la recuperación de oro, la ley del concentrado y el consumo específico de reactivos con un coeficiente de determinación de al menos 0.75, un error porcentual absoluto medio no mayor de 10 % y un MAE y un RMSE menores que los del modelo base, umbrales que se fijaron en las hipótesis a partir de las convenciones de evaluación y del desempeño reportado en estudios de flotación [20], [30], [31]. Con ese nivel de precisión, la planta contaría con estimaciones confiables para reducir la variabilidad del proceso y dosificar los insumos con un criterio cuantitativo.

En la práctica, contar con estas estimaciones ayudaría a mejorar el rendimiento metalúrgico y a reducir costos de operación, porque las decisiones de la guardia se apoyarían en predicciones obtenidas con los propios datos de la planta y no solo en la experiencia del operador [4], [16].

Finalmente, en el plano social, optimizar la flotación de relaves permitiría recuperar metales preciosos con mayor eficiencia, lo que se traduciría en mayor rentabilidad para la empresa, beneficios económicos para sus accionistas y la comunidad, y una mejor gestión de los pasivos ambientales al reducir el potencial contaminante de los relaves finales. De este modo, el estudio contribuiría a una minería más sostenible y responsable en la región de Lima [1], [2].

Para dar respuesta a la problemática planteada, se formuló el siguiente objetivo general: Determinar en qué medida el modelo predictivo basado en inteligencia artificial permite predecir la flotación de relaves de lixiviación, Lima 2026.

Asimismo, se establecieron cuatro objetivos específicos: (OE1) Determinar en qué medida el modelo predictivo basado en inteligencia artificial permite predecir el rendimiento de la recuperación metálica, Lima 2026. (OE2) Determinar en qué medida el modelo predictivo basado en inteligencia artificial permite predecir la calidad del concentrado, Lima 2026. (OE3) Determinar en qué medida el modelo predictivo basado en inteligencia artificial permite predecir la eficiencia en el uso de insumos químicos, Lima 2026. (OE4) Comparar el desempeño de los modelos Random Forest y XGBoost para identificar cuál presenta mayor capacidad predictiva en la flotación de relaves de lixiviación, Lima 2026.

Alsafasfeh, Alagha, Alzidaneen y Nadendla, en 2022, desarrollaron desde la Missouri University of Science and Technology, en el contexto de relaves fosfáticos ricos en silicatos, el estudio titulado “Optimization of flotation efficiency of phosphate minerals in mine tailings using polymeric depressants: experiments and machine learning”. El objetivo fue optimizar la eficiencia de flotación de minerales fosfáticos en relaves mediante depresores poliméricos y aprendizaje automático. La metodología correspondió a un enfoque cuantitativo, de tipo aplicado y experimental, con diseño de pruebas de flotación directa; la población estuvo constituida por relaves fosfáticos y la muestra experimental presentó una ley promedio de alimentación de 21.6 % de P_2O_5. Como técnicas e instrumentos se utilizaron ensayos de flotación, caracterización mineralógica por XRD, MLA y SEM/EDS, además de redes neuronales artificiales entrenadas con los datos experimentales; el análisis se realizó mediante R^2, MAE y RMSE. Los principales resultados mostraron una recuperación de 84.6 % y una ley de 28.6 % de P_2O_5 cuando se empleó Hy-PAM, y la red neuronal

permitió predecir la eficiencia de flotación según las variables de pulpa y reactivos. El estudio concluyó que la combinación de experimentación metalúrgica y redes neuronales permitió optimizar condiciones de flotación en relaves. Su aporte para la investigación actual fue metodológico, porque validó el uso de IA para estimar el desempeño metalúrgico en función de las variables de pulpa y de la dosificación de reactivos; su limitación fue que trabajó con relaves fosfáticos y no con relaves auríferos lixiviados; y su diferencia fue que la presente investigación comparó Random Forest y XGBoost en la predicción de la recuperación, la ley del concentrado y el consumo de reactivos en una planta en la región de Lima [18].

Zhang, Gao y Wang, en 2023, desarrollaron su investigación en China, en el contexto de flotación inversa de hierro, con el título “Prediction model of iron reverse flotation tailings grade based on multi-feature fusion”. El objetivo fue predecir la ley de relaves en flotación inversa mediante fusión de características extraídas de imágenes de espuma. La metodología fue cuantitativa, aplicada y predictiva, con diseño no experimental basado en datos industriales e imágenes de espuma; la población estuvo constituida por registros visuales del proceso de flotación y la muestra correspondió a imágenes procesadas para estimar la ley de relaves. Como técnicas e instrumentos se emplearon visión computacional, segmentación de espuma mediante una U-Net mejorada, extracción de características de tamaño y color de burbujas, y una red neuronal profunda basada en ResNet; el análisis se realizó mediante pruebas de exactitud predictiva del modelo. Los resultados evidenciaron que la segmentación mejorada evitó problemas de subsegmentación y sobresegmentación, y que la fusión multicaracterística permitió estimar la ley con precisión suficiente para su uso operativo. El estudio concluyó que los sensores blandos basados en imágenes de espuma y deep learning pudieron apoyar el control del régimen de reactivos y la calidad del producto. Su aporte fue relevante para el objetivo referido a estimar la ley del concentrado; su limitación fue que se centró en hierro y en variables visuales de espuma, no en variables operativas SCADA/PLC ni en oro; y su diferencia fue que la investigación actual buscó estimar recuperación, ley y consumo de reactivos en relaves de lixiviación aurífera, incorporando modelos tabulares e interpretables [19].

Szmigiel, Apel, Skrzypkowski, Wojtecki y Pu, en 2024, realizaron una revisión internacional publicada en Minerals titulada “Advancements in Machine Learning for

Optimal Performance in Flotation Processes: A Review". El objetivo fue revisar los avances del aprendizaje automático y la inteligencia artificial aplicados al monitoreo, control y optimización de procesos de flotación. La metodología correspondió a un enfoque cualitativo-documental, de tipo revisión científica, con diseño bibliográfico; la población estuvo conformada por investigaciones académicas sobre flotación e inteligencia artificial de la última década, y la muestra fue la literatura especializada seleccionada por pertinencia temática. Las técnicas e instrumentos fueron la revisión documental, el análisis comparativo de algoritmos y la síntesis de aplicaciones de machine learning, visión artificial y deep learning; el procedimiento de análisis consistió en identificar tendencias, limitaciones y oportunidades de implementación. Los resultados mostraron que el interés científico en modelos de aprendizaje automático para flotación aumentó y que las redes profundas aplicadas al análisis de imágenes de espuma tuvieron una tendencia creciente para monitoreo y control. El estudio concluyó que la flotación, por su complejidad fisicoquímica y multivariable, requirió herramientas inteligentes para mejorar la supervisión y el rendimiento. Su aporte fue teórico, porque sustentó la pertinencia de comparar algoritmos de IA en flotación; su limitación fue que no desarrolló un modelo empírico propio ni se enfocó en relaves lixiviados de oro; y su diferencia fue que la investigación actual realizó una validación empírica con datos operativos de una planta peruana y métricas como R^2, MAE, RMSE y MAPE [3].

Devasahayam, en 2025, desarrolló en Australia, desde la Western Australian School of Mines de Curtin University, el estudio "Interpretable Machine Learning for Identifying Key Variables Influencing Gold Recovery and Grade". El objetivo fue identificar e interpretar las variables que influían en la recuperación acumulada de oro y en la ley durante la flotación. La metodología fue cuantitativa, aplicada y explicativa-predictiva, con diseño experimental basado en un conjunto pequeño de datos derivados de pruebas de flotación de mineral aurífero de Ballarat; la muestra estuvo compuesta por 11 observaciones experimentales. Las técnicas e instrumentos incluyeron Gradient Boosting Regressor, SHAP, importancia por permutación e importancia de variables; el análisis permitió detectar relaciones lineales, no lineales e interacciones entre variables. Los resultados indicaron que la potencia de molienda, la ley de cabeza y el tiempo de procesamiento fueron predictores dominantes, mientras que las interacciones entre ley de cabeza, colector y tamaño de partícula explicaron parte del

comportamiento metalúrgico. El estudio concluyó que el aprendizaje automático interpretable pudo conectar la modelación estadística con la optimización metalúrgica, incluso en escenarios con pocos datos. Su aporte fue central para la investigación actual porque reforzó la necesidad de modelos explicables y no solo precisos; su limitación fue el tamaño muestral reducido y el carácter experimental de laboratorio; y su diferencia fue que la presente investigación trabajó con datos operativos de planta y comparó varios modelos predictivos para recuperación, ley y reactivos en relaves lixiviados [7].

Devasahayam, en 2025, también desarrolló el estudio “Advancing Flotation Process Modeling: Bayesian vs. Sklearn Approaches for Gold Grade Prediction”, publicado en Minerals. El objetivo fue predecir la ley acumulada de oro mediante modelos bayesianos y modelos tradicionales de sklearn, integrando conocimiento previo e incertidumbre. La metodología fue cuantitativa, aplicada y predictiva, con diseño comparativo de modelos; la muestra estuvo constituida por datos experimentales de flotación aurífera con variables como tipo de chancadora, tamaño de partícula, potencia, tiempo, ley de cabeza y tipo de colector. Como técnicas e instrumentos se emplearon regresión bayesiana Ridge, PyMC, modelos de sklearn, verificación posterior predictiva, estandarización de datos y análisis de convergencia MCMC; el análisis de desempeño consideró R^2 y MSE. Los resultados mostraron que el enfoque PyMC alcanzó un R^2 de 0.92 y un MSE de 102.37, con lo que superó a los modelos tradicionales en la predicción de la ley acumulada de oro. El estudio concluyó que los modelos bayesianos fueron útiles para optimización robusta en procesamiento de minerales, especialmente cuando se requirió interpretar incertidumbre. Su aporte fue relevante para el objetivo de estimar la ley del concentrado; su limitación fue que se enfocó en predicción de ley y no en recuperación ni consumo de reactivos; y su diferencia fue que la investigación actual evaluó simultáneamente la recuperación, la ley y el consumo específico de reactivos mediante modelos de IA comparables e interpretables [21].

Nasiri Abarbekouh, Iqbal y Särkkä, en 2025, desarrollaron en Finlandia, desde Aalto University, el estudio “Physics-informed machine learning for grade prediction in froth flotation”, publicado en Minerals Engineering. El objetivo fue predecir la ley de concentrado de oro en celdas de flotación mediante redes neuronales informadas por física. La metodología fue cuantitativa, aplicada y predictiva, con diseño de

modelamiento híbrido físico-datos; la población estuvo constituida por el proceso de flotación simulado mediante un gemelo digital, y la muestra correspondió a datos generados a partir de un modelo que integraba información real del proceso y simulaciones físicas, con registros de casi medio año a una frecuencia de cinco minutos. Las técnicas e instrumentos incluyeron redes neuronales informadas por física, modelos matemáticos clásicos de flotación, gemelo digital y comparación contra modelos puramente basados en datos; el análisis se realizó mediante MSE y error relativo medio. Los resultados mostraron que el mejor modelo informado por física redujo el MSE en 65 % y el error relativo medio en 34 % frente al mejor modelo puramente data-driven. El estudio concluyó que la incorporación de conocimiento físico mejoraba la generalización en ambientes industriales dinámicos. Su aporte fue importante para el objetivo de estimar la ley del concentrado y para justificar el uso de modelos robustos; su limitación fue que usó datos de gemelo digital y no necesariamente datos directos de relaves lixiviados; y su diferencia fue que la investigación actual priorizó datos reales operativos de planta peruana y modelos comparativos de machine learning aplicables a sensores blandos metalúrgicos [16].

He, Liu, Zhao y Huang, en 2024, desarrollaron en China el estudio “Ensemble prediction modeling of flotation recovery based on machine learning”, publicado en el International Journal of Mining Science and Technology. El objetivo fue predecir la recuperación de flotación mediante modelos de aprendizaje automático individuales y de ensamble. La metodología fue cuantitativa, aplicada y predictiva, con diseño no experimental basado en datos de producción de una planta de procesamiento de minerales registrados durante 182 días, a los que se aplicaron algoritmos de detección de valores atípicos y de filtrado antes del modelamiento. Como técnicas se compararon el árbol de decisión, la regresión de vectores de soporte y Random Forest frente a métodos de ensamble de tipo bagging, boosting (GBR y XGBoost) y stacking. Los resultados mostraron que el ensamble stacking, con diez variables del proceso de flotación, alcanzó un R^2 de 0.843, un MAE de 0.929, un RMSE de 1.370 y un error relativo medio de 1.229 %, además de tasas de acierto de 82.4 % y 94.6 % dentro de márgenes de error de ±2 % y ±4 %, respectivamente, aunque demandó el mayor tiempo de cómputo. El estudio concluyó que el aprendizaje de ensamble fue eficaz para tareas industriales de predicción con múltiples variables en interacción. Su aporte fue directo para el objetivo referido a la recuperación metalúrgica, porque

demostró la viabilidad de predecirla con datos de producción; su limitación fue que no abordó la ley del concentrado ni el consumo de reactivos; y su diferencia fue que la presente investigación evaluó las tres respuestas metalúrgicas en relaves de lixiviación aurífera [20].

Chehreh Chelgani, Homafar, Nasiri y Rezaei Laksar, en 2024, publicaron en Minerals Engineering el estudio “CatBoost-SHAP for modeling industrial operational flotation variables – A ‘conscious lab’ approach”. El objetivo fue modelar e interpretar las respuestas metalúrgicas, ley y recuperación de cobre, de un circuito industrial de flotación antes y después de sustituir el colector secundario etil xantato de sodio por amil xantato de potasio. La metodología fue cuantitativa, aplicada y predictiva, con diseño no experimental basado en 684 registros operativos diarios de una planta de flotación de cobre en Irán; como técnicas se emplearon CatBoost y el análisis SHAP, y el desempeño se contrastó con Random Forest, XGBoost, regresión de vectores de soporte y redes neuronales convolucionales. Los resultados mostraron que CatBoost alcanzó coeficientes de determinación de hasta 0.90 en la ley y 0.88 en la recuperación de cobre en el conjunto de prueba, con errores inferiores al 2 % entre los valores reales y predichos, mientras que Random Forest (R^2 de 0.75 a 0.87) superó a XGBoost (R^2 de 0.64 a 0.80) en todos los escenarios de prueba. El estudio concluyó que la combinación CatBoost-SHAP modeló con precisión las respuestas de flotación y permitió interpretar cómo la sustitución del colector modificó las interacciones entre las variables operativas. Su aporte fue metodológico, porque respaldó la comparación de algoritmos de ensamble de árboles, incluidos Random Forest y XGBoost, con interpretabilidad SHAP y datos operativos industriales; su limitación fue que se aplicó a un circuito de cobre y no a relaves auríferos lixiviados; y su diferencia fue que la presente investigación utilizó registros SCADA/PLC de una planta peruana de flotación de relaves de lixiviación [28].

Castro Melendez, en 2025, desarrolló en Huánuco, Perú, la tesis “Aplicación del Machine Learning y el pronóstico de mineralización en la concesión minera Gus del Aire, Huánuco 2023”, en la Universidad Nacional Daniel Alcides Carrión. El objetivo fue predecir depósitos minerales mediante modelos de machine learning integrando información geológica, geoquímica, estructural y espectral. La metodología fue cuantitativa, aplicada y predictiva, con diseño de modelamiento computacional; la población estuvo conformada por la información geológica de la concesión minera y

la muestra por los datos seleccionados para la base de modelamiento. Como técnicas e instrumentos se emplearon revisión bibliográfica, recopilación de datos, preprocesamiento, transformación, Random Forest y redes neuronales artificiales; el análisis se realizó mediante matriz de confusión y curva ROC. Los resultados mostraron una precisión de 99.91 % para Random Forest y 99.81 % para redes neuronales artificiales, además de mapas predictivos de zonas con potencial mineralógico. El estudio concluyó que el aprendizaje automático permitió optimizar la exploración minera y reducir riesgos económicos. Su aporte fue nacional y metodológico, porque evidenció que Random Forest y redes neuronales pudieron aplicarse con alta precisión en minería peruana; su limitación fue que se enfocó en exploración geológica y clasificación de mineralización, no en flotación ni relaves; y su diferencia fue que la investigación actual evaluó desempeño predictivo en procesos metalúrgicos de flotación de relaves de lixiviación, usando métricas de regresión como R^2, MAE, RMSE y MAPE [32].

Idrogo Zamora, en 2022, desarrolló en Perú, desde la Universidad Nacional de Ingeniería, la tesis “Machine Learning aplicado al control de la fragmentación de rocas en la voladura de minas a tajo abierto”. El objetivo fue aplicar machine learning para controlar la fragmentación de rocas en una mina a tajo abierto. La metodología fue cuantitativa, aplicada y predictiva, con diseño de análisis y modelamiento de datos; la población estuvo constituida por registros operativos de voladura y la muestra por los parámetros seleccionados para el entrenamiento. Las técnicas e instrumentos incluyeron análisis de variables, tratamiento de datos, estandarización, transformación Yeo-Johnson y redes neuronales artificiales; el análisis comparó el método tradicional con el método basado en IA. Los resultados indicaron que la flexibilidad de las redes neuronales permitió ajustar modelos a necesidades de diseño, costo y objetivos de fragmentación. El estudio concluyó que la inteligencia artificial pudo apoyar decisiones técnicas en minería peruana. Su aporte fue demostrar la viabilidad nacional del modelamiento predictivo en operaciones mineras; su limitación fue que no abordó metalurgia extractiva ni flotación; y su diferencia fue que la investigación actual se centró en variables metalúrgicas, recuperación, ley de concentrado y consumo de reactivos en relaves lixiviados [33].

Berrospi Borda, en 2023, desarrolló, en una planta concentradora peruana dedicada al tratamiento de relaves auríferos, la tesis “Tratamiento metalúrgico a los relaves para

la recuperación de oro a nivel de laboratorio en la planta concentradora Copperfield Perú S.A.C. Lima – 2022", en la Universidad Nacional Daniel Alcides Carrión. El objetivo fue determinar el grado de remolienda y la concentración y dosificación de reactivos para recuperar oro desde relaves. La metodología fue cuantitativa, aplicada y experimental, con diseño explicativo; la población estuvo constituida por relaves con ley de cabeza de 2.07 g/TM de Au, 29.26 g/TM de Ag y otros elementos, y la muestra correspondió a ensayos de laboratorio. Como técnicas e instrumentos se emplearon remolienda, pruebas de flotación, dosificación de xantato Z-6 y análisis estadístico ANOVA 2^n. Los resultados mostraron una recuperación de oro de 74.49 % con granulometría equivalente a 85 % malla -200 y dosificación de xantato Z-6 al 10 % y 30 g/TM; el ANOVA estimó una recuperación de 74.65 %, muy cercana al valor experimental. El estudio concluyó que fue posible recuperar oro desde relaves mediante control de granulometría y reactivos. Su aporte fue práctico, porque proporcionó condiciones metalúrgicas de referencia para relaves auríferos; su limitación fue que no empleó inteligencia artificial ni sensores blandos; y su diferencia fue que la investigación actual usó datos operativos históricos para construir modelos predictivos capaces de estimar recuperación, ley y consumo de reactivos [9].

Mory Blas, en 2024, desarrolló en una planta peruana de tratamiento de relaves auríferos, desde la Universidad Nacional José Faustino Sánchez Carrión, la tesis "Efecto de colectores secundarios en el tratamiento de relaves para la flotación de pirita aurífera". El objetivo fue evaluar el efecto de colectores secundarios en el tratamiento de relaves para flotación de pirita aurífera. La metodología fue cuantitativa, aplicada y experimental; la población estuvo constituida por relaves auríferos y la muestra experimental utilizó 1000 g de mineral por prueba, con ley de cabeza de 1.89 g/t Au y 31.75 g/t Ag, liberación de 85 % pasante malla 200, pH 7.3, dosificación de $ZnSO_4$, A-404, Z-6, MIBC y promotores A-242, MX-945, A-3926, MX-5160 y A-3894. Las técnicas e instrumentos fueron molienda, acondicionamiento, flotación por tiempos de 0.5, 1, 2 y 4 minutos, y análisis metalúrgico de leyes y recuperaciones. Los resultados mostraron que el A-242 alcanzó leyes de concentrado de 11.25 g/t Au y 105.31 g/t Ag, con recuperación de 62.04 % de oro y 54.60 % de plata; mientras que el A-3894 alcanzó mayor recuperación, con 65.32 % de oro y 58.67 % de plata, aunque con menor ley de concentrado. El estudio concluyó que el A-242 favoreció la calidad del concentrado, mientras que el A-3894 favoreció la

recuperación de masa metálica. Su aporte fue directo para el objetivo referido a la eficiencia en el uso de insumos químicos, porque mostró cómo la selección y la dosificación de reactivos modifican la ley y la recuperación; su limitación fue que no desarrolló modelos predictivos ni comparó algoritmos de IA; y su diferencia fue que la investigación actual buscó aprender de los datos históricos para estimar automáticamente la recuperación, la ley y el consumo específico de reactivos en condiciones operativas variables [10].

En conjunto, los antecedentes revisados permitieron sostener que la inteligencia artificial se aplicó con pertinencia en procesos de flotación, tanto para predicción de recuperación como para estimación de ley y optimización de reactivos; sin embargo, también evidenciaron un vacío específico: la ausencia de modelos predictivos explicables, comparativos y entrenados con datos operativos reales para flotación de relaves auríferos previamente lixiviados en la región Lima. Por ello, la investigación actual se diferenció al evaluar el desempeño de Random Forest y XGBoost mediante R^2, MAE, RMSE y MAPE, incorporando además criterios de robustez, interpretabilidad y viabilidad operativa.

En cuanto al marco teórico del estudio, los relaves mineros fueron entendidos como materiales residuales generados durante el procesamiento de minerales, pero su condición de residuo no implicó ausencia de valor económico o metalúrgico. En escenarios de agotamiento progresivo de reservas de alta ley, incremento de costos operativos y exigencias ambientales más estrictas, los relaves pudieron considerarse fuentes secundarias de metales recuperables, especialmente cuando contenían oro, plata u otros elementos valiosos no extraídos en etapas previas de beneficio. Esta perspectiva se articuló con los principios de economía circular, valorización de pasivos ambientales y eficiencia en el uso de recursos minerales, debido a que permitía transformar un residuo históricamente acumulado en una oportunidad tecnológica, económica y ambiental [2].

En la minería moderna, el reprocesamiento de relaves adquirió importancia porque permitía disminuir la presión sobre nuevas explotaciones, reducir el volumen o peligrosidad de depósitos existentes y recuperar metales que quedaron atrapados por limitaciones tecnológicas, mineralógicas u operativas de procesos anteriores [34]. Desde el enfoque de sostenibilidad industrial, esta estrategia se relacionó con el

Objetivo de Desarrollo Sostenible 9, particularmente con la modernización de industrias mediante tecnologías limpias, uso eficiente de recursos e innovación en procesos productivos [2].

En el caso de relaves auríferos previamente lixiviados, la problemática resultó más compleja que en minerales frescos, debido a que el material ya había sido sometido a procesos químicos de extracción, generalmente cianuración, y podía presentar cambios en su superficie mineral, composición química residual, presencia de compuestos solubles, alteración de sulfuros, variabilidad de leyes y heterogeneidad granulométrica. Por ello, su tratamiento mediante flotación requirió comprender simultáneamente variables mineralógicas, fisicoquímicas y operacionales que incidían sobre la selectividad del proceso [9], [10], [35].

Físicamente, los relaves están formados por partículas finas, agua, reactivos residuales y los minerales que el proceso anterior no recuperó [2].

Los relaves de lixiviación aurífera correspondieron a residuos sólidos generados después de procesos hidrometalúrgicos, como la cianuración, cuyo objetivo principal fue disolver oro y plata. Sin embargo, parte del oro pudo permanecer en el residuo por encapsulamiento mineralógico, asociación con sulfuros, baja liberación, pasivación superficial o condiciones químicas desfavorables, lo que justificó su reprocesamiento mediante flotación [9], [10], [14], [15].

Reprocesar relaves supone, por tanto, devolver al ciclo productivo un material que ya fue extraído y molido, lo que reduce la necesidad de abrir nuevas explotaciones y, a la vez, el volumen o la peligrosidad de los depósitos [1], [2].

En el caso del oro, recuperar el metal que quedó en los relaves de lixiviación permite aumentar la producción sin incrementar en la misma proporción la extracción primaria, con un menor costo ambiental que el de un yacimiento nuevo [2].

La flotación fue definida como un proceso fisicoquímico de concentración mineral basado en las diferencias de hidrofobicidad superficial entre partículas valiosas y ganga. En este proceso, las partículas hidrofóbicas se adherían a burbujas de aire, ascendían hacia la espuma y eran recuperadas como concentrado, mientras que las partículas hidrofílicas permanecían en la pulpa y eran descargadas como relave [3], [36].

En relaves de lixiviación aurífera, la flotación presentó mayor complejidad debido a que el material ya había sido sometido a procesos químicos previos, como lixiviación y detoxificación. Estos tratamientos podían modificar la superficie mineral, alterar la adsorción de reactivos y generar respuestas metalúrgicas variables frente a cambios de pH, potencial redox, dosificación de colectores, espumantes y activadores [9], [10], [14].

Las variables de la flotación de relaves de lixiviación se clasificaron en variables de entrada y variables de salida [3].

Las variables de entrada consideradas en la investigación se agruparon en cinco bloques: mineralógicas y de composición de la alimentación; de dosificación de reactivos; fisicoquímicas; operacionales e hidráulicas; y de aireación y formación de espuma [3], [11], [23]. En primer lugar, las variables mineralógicas y de composición de la alimentación comprendieron las leyes de cobre (Cu ccPy), plomo (Pb ccPy), zinc (Zn ccPy), hierro (Fe ccPy), arsénico (As ccPy) y plata (Ag ccPy) [11], [34], [37], así como el contenido de humedad (%H_2O ccPy) [11], el porcentaje pasante por la malla 200 (200M_ccPy) [10], [23], la ley de oro en la alimentación o cabeza, expresada en gramos por tonelada (g/t) [7], [10], [38], el porcentaje de sólidos, el contenido de insolubles, la densidad de pulpa en gramos por litro (g/L) [5], [11], [36] y la granulometría pasante por la malla 200 [23], [36]. Asimismo, se incluyeron los parámetros granulométricos K30, K50 y K80, expresados en micrómetros (µm) [7], [36]. En segundo lugar, las variables relacionadas con la dosificación de reactivos estuvieron constituidas por el consumo de sulfato de cobre [12], [13], la mezcla de xantato amílico de potasio y xantato isopropílico de sodio, identificados como PAX + SIPX (Z-6 + Z-11) [7], [10], [28], [37], el metil isobutil carbinol (MIBC) [10], [23], [37], el metabisulfito de sodio [12], [13] y el antiespumante [11], cuyas dosificaciones se expresaron en kilogramos por tonelada de mineral tratado (kg/t) [10], [11]. Las variables fisicoquímicas incluyeron el pH inicial y final, de carácter adimensional [5], [10], [18]; el potencial de oxidación-reducción o potencial redox, expresado en milivoltios (mV) [12], [23]; el oxígeno disuelto, medido en miligramos por litro (mg/L) [12]; las concentraciones inicial y final de cianuro libre (FCN_Inic y FCN_Fin), expresadas en partes por millón (ppm) [11], [12], [37]; y la concentración residual de cianuro libre, medida en miligramos por litro (mg/L) [11], [34], [38]. Por otro lado, las variables operacionales e hidráulicas comprendieron la masa de alimentación en

toneladas [23], [38], el caudal de pulpa en metros cúbicos por hora (m³/h) [5], [38], el caudal de agua de lavado cuando correspondiera [11], [36], el nivel de pulpa [4], [5] y el tiempo de flotación expresado en minutos [10], [18], [37]. Finalmente, las variables asociadas con la aireación y la formación de espuma estuvieron conformadas por el caudal de aire en metros cúbicos normales por hora (Nm³/h) [4], [5], [37], la presión de aire y la presión del manifold en kilopascales (kPa), el porcentaje de apertura de aire [11] y la altura de la espuma en milímetros (mm) [4], [23].

Las variables de salida correspondieron a los resultados metalúrgicos y operacionales utilizados para evaluar el desempeño del proceso de flotación [3], [17], [20]. Estas comprendieron la recuperación de Au (%) [7], [9], [10], [23]; la ley de Au en el concentrado (g/t) [7], [10], [16], [21]; y el consumo específico de reactivos (kg/t) [10], [11].

La recuperación de Au expresó el porcentaje de oro contenido en la alimentación que se transfirió al concentrado. Este indicador permitió evaluar el rendimiento de recuperación metálica y constituyó una de las principales variables objetivo en modelos predictivos aplicados a flotación [36], [38].

$$\mathrm{R} = \frac{\mathrm{Cc} \times \mathrm{L}}{\mathrm{F} \times \mathrm{f}} \times 100 \qquad \text{i1}$$

Donde R es la recuperación de Au (%), Cc es la masa del concentrado (t), L es la ley de Au en el concentrado (g/t), F es la masa de alimentación (t) y f es la ley de Au en la alimentación (g/t).

La ley de Au en el concentrado representó la concentración de oro contenida en el producto obtenido por flotación. Este indicador reflejó la calidad del concentrado y debió evaluarse conjuntamente con la recuperación, debido a que una mayor selectividad podía incrementar la ley, pero reducir la recuperación si parte del oro quedaba en el relave [10], [36].

$$\mathrm{L} = \frac{\mathrm{Cf}}{\mathrm{Cc}} \qquad \text{i2}$$

Donde L es la ley de Au en el concentrado (g/t), Cf es el contenido de oro fino en el concentrado (g) y Cc es la masa del concentrado (t).

El consumo específico de reactivos expresó la cantidad total de reactivos utilizados por unidad de masa alimentada al proceso. Este indicador resultó importante porque permitió evaluar la eficiencia en el uso de insumos químicos y, por ende, mejorar la viabilidad económica y ambiental del circuito de flotación, especialmente cuando se buscaba reducir costos sin afectar la recuperación ni la calidad del concentrado [12], [36].

$$\mathrm{Cerf} = \frac{R_1 + R_2 + \cdots + R_n}{F} \qquad \text{i3}$$

Donde Cerf es el consumo específico de reactivos de flotación (kg/t); R_1, R_2, ⋯, R_n son los consumos de cada reactivo (kg) y F es la masa de alimentación (t).

La optimización del consumo de reactivos buscó reducir la cantidad de insumos químicos utilizados sin afectar negativamente la recuperación de oro ni la ley del concentrado. En flotación de relaves auríferos, una dosificación excesiva podía incrementar costos, reducir selectividad, generar arrastre de ganga y elevar el impacto ambiental del proceso [10], [13], [29].

Este enfoque permitió buscar condiciones operativas que maximizaran el desempeño metalúrgico y minimizaran el consumo de reactivos, considerando restricciones técnicas del proceso [3], [18].

Aplicada a la flotación de relaves de lixiviación, la inteligencia artificial puede contribuir a la sostenibilidad minera por dos vías: elevar la recuperación de metales y ajustar el uso de reactivos, lo que a su vez reduce el impacto de los pasivos mineros [2], [8].

En los procesos metalúrgicos, la inteligencia artificial permite construir modelos que aprenden del historial de operación. Su interés en flotación se explica porque las variables del proceso dependen unas de otras de manera no lineal y las condiciones cambian de un turno a otro, algo difícil de manejar con los métodos de control convencionales [3], [6].

Los modelos de aprendizaje automático se han utilizado para estimar la recuperación metalúrgica, la ley del concentrado, el consumo de reactivos y las condiciones operativas óptimas. Además, cuando se integraban con sistemas SCADA/PLC,

podían funcionar como sensores blandos capaces de entregar estimaciones en tiempo real de variables que normalmente requerían análisis de laboratorio [16], [39].

Entre los modelos de aprendizaje automático con mayor presencia en la literatura de flotación destacaron Random Forest (RF) y XGBoost. RF promedió las predicciones de numerosos árboles de decisión entrenados sobre submuestras bootstrap y subconjuntos aleatorios de variables, mientras que XGBoost entrenó árboles de forma secuencial para corregir los residuos del ensamble previo, empleó información de segundo orden para optimizar la función de pérdida e incorporó regularización para limitar el sobreajuste [25], [40]. En flotación, Gomez-Flores et al. [41] predijeron la ley y la recuperación a partir de aspectos fisicoquímicos y operativos mediante modelos de aprendizaje automático, y Henríquez et al. [42] aplicaron RF a los datos históricos de un prototipo de flotación de la Universidad Católica del Norte, en Chile, con el que alcanzaron una exactitud final de 94.44 % y generaron recomendaciones para mejorar la recuperación de cobre. Con un enfoque comparativo, Erkan y Günen [43] evaluaron árboles de decisión, redes neuronales, modelos aditivos generalizados y RF para predecir la recuperación de zinc en menas carbonatadas, y RF obtuvo el mejor desempeño, con un R^2 de 0.8541 en el conjunto de prueba. En el caso de XGBoost, Ji et al. [27] lo compararon con GBDT, CatBoost y LightGBM sobre 641 ensayos de flotación de carbón; XGBoost fue el más preciso, con R^2 de 0.836 para el rendimiento y de 0.853 para el contenido de cenizas del concentrado, valores que subieron a 0.877 y 0.971 cuando se excluyeron los ensayos con recuperaciones inferiores al 40 %. Sin embargo, la superioridad de un algoritmo no fue universal: con datos de una planta industrial de cobre, CatBoost superó a RF, XGBoost, la regresión de vectores de soporte y una red neuronal convolucional [28], mientras que en un circuito rougher de cobre la regresión por procesos gaussianos superó a la regresión lineal, a RF, a las máquinas de vectores de soporte y al perceptrón multicapa [44]. Esta ausencia de un ganador único justificó comparar RF y XGBoost bajo un mismo protocolo de validación temporal y con datos de la propia planta.

El modelo base se definió como un predictor de referencia cuya finalidad fue establecer una línea mínima de desempeño frente a la cual comparar objetivamente los modelos de inteligencia artificial. A diferencia de los algoritmos de aprendizaje automático, este modelo no empleó variables predictoras ni buscó patrones en los datos: su estimación correspondió a la media histórica de la variable objetivo,

calculada con los subconjuntos de entrenamiento y validación, y asignó ese mismo valor a todas las observaciones del conjunto de prueba. Contrastar los modelos con un referente ingenuo de este tipo es una práctica recomendada en la evaluación predictiva, porque permitió cuantificar cuánto error eliminaban realmente los algoritmos avanzados [24], [25].

La media histórica de la variable objetivo se obtuvo mediante la siguiente expresión [25]:

$$\overline{Y} = \frac{1}{n}\sum_{i=1}^{n} Y_i \qquad i4$$

donde $\overline{Y}$representa el valor promedio de la variable objetivo, $Y_i$corresponde a cada observación registrada y $n$es el número total de observaciones utilizadas para el ajuste del modelo.

Una vez calculado dicho promedio, el modelo asignó el mismo valor a todas las observaciones del conjunto de prueba. En consecuencia, la predicción para cualquier registro se expresó como [24]:

$$\widehat{Y}_i = \overline{Y} \qquad i5$$

donde $\widehat{Y}_i$representa el valor predicho para la observación iy $\overline{Y}$corresponde al promedio histórico de la variable objetivo.

Debido a que todas sus predicciones fueron constantes, el modelo base no consideró las condiciones operativas, las variables metalúrgicas ni ninguna otra característica del proceso de flotación de relaves de lixiviación, por lo que se esperó que su desempeño fuera inferior al de los modelos de aprendizaje automático. Su valor fue metodológico, ya que permitió verificar si los algoritmos desarrollados aportaban capacidad predictiva real. En este sentido, un modelo de inteligencia artificial se consideró útil cuando obtuvo errores menores y un coeficiente de determinación superior al del modelo base, señal de que aprendió relaciones significativas entre las variables del proceso y la variable objetivo [24], [45].

Random Forest fue definido como un algoritmo de ensamble basado en múltiples árboles de decisión entrenados con subconjuntos aleatorios de datos y variables. En

problemas de regresión, la predicción final se obtenía como el promedio de las predicciones individuales de cada árbol [25], [40].

$$\hat{y}_{RF} = \frac{1}{B}\sum_{b=1}^{B} T_b(x) \quad \text{i6}$$

Donde $\hat{y}_{RF}$ es la predicción final del modelo Random Forest, B es el número de árboles, $T_b(x)$ es la predicción del árbol b y x es el vector de variables predictoras.

Random Forest se utilizó porque resultaba robusto frente al sobreajuste, manejaba relaciones no lineales, toleraba ruido en los datos y permitía estimar la importancia relativa de las variables. Estas características resultaron adecuadas para procesos de flotación en los que intervenían variables operacionales, fisicoquímicas y de dosificación con interacciones complejas [3], [25], [43].

XGBoost fue definido como un algoritmo de boosting basado en árboles de decisión que construía modelos de forma secuencial, donde cada árbol nuevo corregía los errores residuales de los árboles anteriores. Su estructura incorporaba regularización, lo que mejoraba la precisión y reducía el riesgo de sobreajuste [3], [25], [40].

$$\hat{y}_i = \sum_{k=1}^{K} f_k(x_i) \quad \text{i7}$$

$$Obj = \sum_{i=1}^{n} l(y_i, \hat{y}_i) + \sum_{k=1}^{K} \Omega(f_k) \quad \text{i8}$$

Donde $\hat{y}_i$ es el valor predicho, y_i es el valor observado, f_k es el árbol de decisión número k, $l(y_i, \hat{y}_i)$ es la función de pérdida, $\Omega(f_k)$ es el término de regularización y K es el número total de árboles.

XGBoost se utilizó porque ofrecía alto desempeño en datos tabulares industriales, capturaba relaciones no lineales, permitía controlar el sobreajuste mediante regularización y solía presentar elevada precisión en problemas de regresión. Estas ventajas fueron relevantes para estimar recuperación, ley de concentrado y consumo de reactivos en flotación de relaves [3], [7], [27]. En esa línea, Chehreh Chelgani et al. [28] demostraron que la combinación de un algoritmo de boosting (CatBoost) con valores SHAP permitió modelar e interpretar las respuestas metalúrgicas de un circuito industrial de flotación, con un desempeño superior al de XGBoost y Random Forest.

Los valores SHAP, fundamentados en la teoría de juegos cooperativos, asignaron a cada variable predictora una contribución aditiva a cada predicción individual del modelo, y su formulación para modelos basados en árboles permitió pasar de explicaciones locales a una comprensión global del comportamiento del modelo [46]. Esta propiedad resultó pertinente para verificar si las variables identificadas como influyentes tenían sentido metalúrgico.

Un sensor blando fue definido como un modelo matemático o computacional que estimaba variables difíciles, costosas o lentas de medir directamente, utilizando otras variables disponibles en línea. En flotación, los sensores blandos permitieron estimar recuperación de Au (%), ley de Au en el concentrado (g/t) y consumo específico de reactivos (kg/t) a partir de variables registradas por sistemas SCADA/PLC [16]. En la misma línea, Pural [5] desarrolló un sensor blando basado en variables operativas para predecir la impureza de sílice en concentrados de hierro, mientras que otros trabajos estimaron leyes en línea a partir de características de imágenes de espuma [19], [47]–[49].

$$\hat{y} = f(x) \quad \text{i9}$$

Donde ŷ es la variable objetivo estimada, x es el vector de variables predictoras, y f(x) es la función aprendida por el modelo predictivo.

En esta investigación, el vector de variables predictoras estuvo compuesto por las variables mineralógicas y de composición de la alimentación, de dosificación de reactivos, fisicoquímicas, operacionales e hidráulicas, y de aireación y formación de espuma [3], [11], [23]. Las variables objetivo fueron la recuperación de Au (%), la ley de Au en el concentrado (g/t) y el consumo específico de reactivos (kg/t) [3], [16].

El desempeño predictivo de los modelos se evaluó mediante métricas de regresión que permitían comparar valores observados y valores estimados. En esta investigación se utilizaron R^2, MAE, RMSE y MAPE, porque permitían analizar la capacidad explicativa, la magnitud del error, la penalización de los errores grandes y el error porcentual [7], [18].

El coeficiente de determinación (R^2) midió la proporción de variabilidad de la variable objetivo explicada por el modelo; valores cercanos a 1 indicaron mejor ajuste predictivo [18], [45].

$$R^2 = 1 - \frac{\sum_{i=1}^{n}(y_i - \hat{y}_i)^2}{\sum_{i=1}^{n}(y_i - \bar{y})^2} \quad \text{i10}$$

Donde R^2 es el coeficiente de determinación, y_i es el valor observado, $\hat{y}_i$ es el valor predicho, $\bar{y}$ es el promedio de valores observados, y n es el número de observaciones.

El error absoluto medio (MAE) midió la magnitud promedio del error en las mismas unidades de la variable objetivo y resultó útil por su interpretación directa [18], [50].

$$MAE = \frac{1}{n}\sum_{i=1}^{n} | y_i - \hat{y}_i | \quad \text{i11}$$

Donde MAE es el error absoluto medio, y_i es el valor observado, $\hat{y}_i$ es el valor predicho, y n es el número de observaciones.

La raíz del error cuadrático medio (RMSE) penalizó con mayor fuerza los errores grandes, por lo que fue útil cuando desviaciones elevadas podían afectar la operación, como en la dosificación de reactivos o en la predicción de recuperación [16], [18], [50].

$$RMSE = \sqrt{\frac{1}{n}\sum_{i=1}^{n}(y_i - \hat{y}_i)^2} \quad \text{i12}$$

$$RMSE = \sigma_y\sqrt{1 - R^2} \quad \text{i13}$$

Donde RMSE es la raíz del error cuadrático medio, y_i es el valor observado, $\hat{y}_i$ es el valor predicho, y n es el número de observaciones.
La expresión i13 se deduce de las ecuaciones i10 e i12 cuando el R^2 se calcula con la media de los valores observados del mismo conjunto, siendo σ_y la desviación estándar poblacional de esos valores. Muestra que el RMSE depende tanto del R^2 como de la dispersión de la variable, de modo que dos conjuntos con el mismo R^2 pueden tener RMSE distintos si su variabilidad difiere.

El error porcentual absoluto medio (MAPE) expresó el error en términos porcentuales, lo que facilitó la interpretación operativa y gerencial del desempeño del modelo. Sin embargo, debía aplicarse con precaución cuando los valores reales eran cercanos a cero [24].

$$MAPE = \frac{100}{n}\sum_{i=1}^{n} \left| \frac{y_i - \hat{y}_i}{y_i} \right| \quad \text{i14}$$

Donde MAPE es el error porcentual absoluto medio, y_i es el valor observado, $\hat{y}_i$ es el valor predicho, y n es el número de observaciones.

El aporte de cada algoritmo frente al modelo base se cuantificó como la reducción porcentual de sus errores, una forma directa de expresar cuánto error elimina un modelo respecto de un referente ingenuo [24]:

$$\mathrm{Red}_{\mathrm{E}} = \frac{\mathrm{E}_{\mathrm{base}} - \mathrm{E}_{\mathrm{modelo}}}{\mathrm{E}_{\mathrm{base}}} \times 100 \qquad \text{i15}$$

Donde $\mathrm{Red}_{\mathrm{E}}$ es la reducción porcentual del error (%), E representa la métrica de error evaluada (MAE o RMSE), $\mathrm{E}_{\mathrm{base}}$ es el error del modelo base y $\mathrm{E}_{\mathrm{modelo}}$ es el error de Random Forest o de XGBoost, ambos calculados en el conjunto de prueba. Un valor positivo indica que el algoritmo redujo el error de la media histórica; un valor nulo o negativo, que no logró superarla [24], [45].

El modelo base tiene, además, una propiedad que ayuda a interpretar su R^2. Si en la ecuación i10 se reemplaza la predicción constante de la ecuación i5, el coeficiente de determinación del modelo base queda en función de la distancia entre la media histórica y la media del conjunto evaluado [45], [60]:

$$\mathrm{R}^2_{\mathrm{base}} = -\left(\frac{\bar{\mathrm{y}}_{\mathrm{p}} - \bar{\mathrm{Y}}}{\sigma_{\mathrm{p}}}\right)^2 \qquad \text{i16}$$

Donde R^2_{base} es el coeficiente de determinación del modelo base, $\bar{y}_p$ es la media de la variable objetivo en el conjunto de prueba, $\bar{Y}$ es la media histórica calculada con los datos de entrenamiento y validación (ecuación i4) y σ_p es la desviación estándar poblacional de la variable en el conjunto de prueba. La expresión indica que el R^2 del modelo base nunca es positivo y que se vuelve más negativo cuanto más se aleja el nivel del periodo evaluado del nivel histórico.

Para comparar dos algoritmos entre sí no basta con ordenar sus métricas; hace falta saber si la diferencia entre sus errores supera lo que cabría esperar por azar. Con ese fin se empleó la prueba de Diebold-Mariano, que parte del diferencial de pérdida entre las predicciones de ambos modelos en cada observación [70]:

$$\mathrm{d}_{\mathrm{t}} = \mathrm{L}\left(\mathrm{e}_{\mathrm{RF,t}}\right) - \mathrm{L}\left(\mathrm{e}_{\mathrm{XGB,t}}\right) \qquad \text{i17}$$

Donde d_t es el diferencial de pérdida en la observación t; $e_{RF,t}$ y $e_{XGB,t}$ son los errores de predicción de Random Forest y de XGBoost en esa observación; y L(·) es la función de pérdida, que puede ser el error al cuadrado, $L(e) = e^2$, o el error absoluto, L(e) = |e|. A partir de esos diferenciales, el estadístico de la prueba se define como [70]:

$$\mathrm{DM} = \frac{\bar{d}}{\sqrt{\frac{\hat{\gamma}_0}{n}}} \qquad \text{i18}$$

Donde el numerador es la media de los diferenciales d_t, $\hat{\gamma}_0$ es su autocovarianza de orden cero, es decir, su varianza, y n es el número de observaciones evaluadas. Como esta versión tiende a rechazar la igualdad de exactitud con demasiada frecuencia en muestras pequeñas, Harvey, Leybourne y Newbold propusieron corregir el estadístico y contrastarlo con una distribución t de Student con n − 1 grados de libertad [71], [74]:

$$\mathrm{DM}^* = \mathrm{DM} \cdot \sqrt{\frac{n+1-2h+\frac{h(h-1)}{n}}{n}} \qquad \text{i19}$$

Donde DM* es el estadístico corregido y h es el horizonte de predicción. Para predicciones a un paso (h = 1), el factor de corrección se reduce a $\sqrt{((n-1)/n)}$. Un valor negativo de DM* indica que el primer modelo, en este caso Random Forest, tuvo menor pérdida, y uno positivo, que la tuvo el segundo, XGBoost.

Por último, el cociente entre el RMSE y el MAE permite juzgar cómo se distribuyen los errores, porque la conveniencia de una u otra métrica depende de esa distribución [50]:

$$Q = \frac{\mathrm{RMSE}}{\mathrm{MAE}} \qquad \text{i20}$$

Donde Q es el cociente entre la raíz del error cuadrático medio (ecuación i12) y el error absoluto medio (ecuación i11). Su valor teórico es $\sqrt{(\pi/2)} \approx 1.25$ para errores normales de media nula y $\sqrt{2} \approx 1.41$ para errores de Laplace, de colas más pesadas; nunca es menor que 1 y aumenta cuando el error total se concentra en pocas predicciones de gran magnitud [50].

Tabla 1

Rangos de interpretación de las métricas de desempeño

Métrica	Rango matemático	Valor ideal	Categoría	Rango de interpretación	Cumple el criterio de Hi	Fuente
Coeficiente de determinación (R^2)	(−∞; 1]	1	Sustancial	≥ 0.75	Sí	[91]
			Moderado	0.50 a < 0.75	No	[91]
			Débil	0.25 a < 0.50	No	[91]
			Muy débil	< 0.25; si es negativo, el modelo predice peor que la media observada	No	[60], [91]
Error porcentual absoluto medio (MAPE)	[0; +∞) %	0 %	Excelente	< 10 %	Sí	[31]
			Bueno	10 % a 20 %	No	[31]
			Aceptable	20 % a 50 %	No	[31]
			Inexacto	> 50 %	No	[31]
Error absoluto medio (MAE)	[0; +∞), en unidades de la variable	0	Supera al modelo base	MAE del algoritmo menor que el MAE del modelo base	Sí	[24], [60]
			No supera al modelo base	MAE del algoritmo igual o mayor que el MAE del modelo base	No	[24], [60]
Raíz del error cuadrático medio (RMSE)	[0; +∞), en unidades de la variable	0	Supera al modelo base	RMSE del algoritmo menor que el RMSE del modelo base	Sí	[24], [60]
			No supera al modelo base	RMSE del algoritmo igual o mayor que el RMSE del modelo base	No	[24], [60]
Prueba de Diebold-Mariano con errores al cuadrado	DM*: (−∞; +∞) p: [0; 1]	No aplica	Diferencia significativa	p < 0.05	Sí (HE4)	[52], [53], [74]
			Sin diferencia significativa	p ≥ 0.05	No	[52], [53], [74]
Prueba de Diebold-Mariano con errores absolutos	DM*: (−∞; +∞) p: [0; 1]	No aplica	Diferencia significativa	p < 0.05	Sí (HE4)	[53], [72], [74]
			Sin diferencia significativa	p ≥ 0.05	No	[53], [72], [74]

Nota. Elaboración propia a partir de [24], [31], [52], [53], [60], [72], [74] y [91]. Todas las métricas se calculan en el conjunto de prueba. La escala del MAPE se aplica sobre el error relativo al valor observado. El MAE y el RMSE no tienen escala normativa porque se expresan en las unidades de cada variable objetivo (puntos porcentuales [pp], g/t o kg/t); por ello se interpretan frente al modelo base, que predice la media de los datos de entrenamiento y validación [24], [60]. Siempre se cumple que MAE ≤ RMSE; el MAE es menos sensible a los valores atípicos y el RMSE da más peso a los errores grandes [31]. En la prueba de Diebold-Mariano, DM* es el estadístico corregido para muestras pequeñas y p su valor p bilateral; un estadístico negativo indica menor pérdida de Random Forest, y uno positivo, de XGBoost [74]. En la columna «Cumple el criterio de Hi», Hi1, Hi2 e Hi3 exigen que un mismo algoritmo cumpla a la vez los criterios de R^2, MAPE, MAE y RMSE, y Hi4 exige $p < 0.05$ en las dos versiones de la prueba de Diebold-Mariano y que el algoritmo superior obtenga mayor R^2 y menores RMSE, MAE y MAPE (Tabla 3).

El R^2 tomó valores negativos cuando el modelo predijo peor que la media de los datos observados [45]. El MAPE, por su parte, no estuvo definido cuando algún valor observado fue igual a cero y se volvió inestable con valores cercanos a cero [24]; en esta investigación no se presentó esa situación, porque la recuperación, la ley y el consumo específico de reactivos fueron siempre positivos [11]. Las escalas de interpretación de R^2, RMSE y MAPE se adoptaron como convenciones de estudios aplicados y no como normas universales [30], [31], por lo que su lectura se complementó con la comparación frente al modelo base y con el desempeño reportado en investigaciones de flotación.

Para verificar que esos rangos fueran adecuados al contexto de la flotación, se revisó el desempeño reportado por estudios recientes que aplicaron regresión lineal, Random Forest, XGBoost y otros algoritmos a la predicción de la recuperación, la ley y variables afines (Tabla 2). Con datos de planta o de ensayos sistemáticos, los mejores modelos de ensamble alcanzaron coeficientes de determinación entre 0.836 y 0.971 y errores relativos inferiores a 2 % [20], [27], [28], [43]; en conjuntos de laboratorio, el R^2 también superó 0.90 [21], [37]. En cuanto a la regresión lineal, los estudios revisados la emplearon como modelo de comparación y, en el caso documentado de un circuito rougher de cobre, fue superada por algoritmos no lineales [44]. En la literatura verificada no se encontraron valores de R^2, MAE, RMSE y MAPE de regresión lineal aplicada específicamente a relaves de lixiviación aurífera, razón por la cual la referencia mínima de esta investigación fue el modelo base y no un modelo lineal.

Tabla 2

Desempeño predictivo reportado en estudios recientes de flotación

Estudio	Material, datos y variable objetivo	Modelos comparados	Mejor modelo	Desempeño reportado	Hipótesis
[20]	Planta de procesamiento de minerales (datos de campo); recuperación de flotación	Árbol de decisión, SVR, RF, bagging, boosting y stacking	Stacking con 10 variables	R^2 = 0.843; MAE = 0.929; RMSE = 1.370; MRE = 1.229 %; 82.4 % de predicciones con error dentro de ±2 %	HE1
[44]	Circuito rougher de Cu de Olympic Dam; 1 325 270 registros de 15 variables (6 años); recuperación de Cu	SVM, GPR, MLP, regresión lineal y RF	GPR (kernel Matérn 3/2)	r > 0.96; RMSE < 0.42; MAPE < 0.25 %; VAF > 94 %	HE1
[37]	62 ensayos de flotación de sulfuros complejos (80 % entrenamiento y 20 % prueba); recuperación y ley de Pb y Cu	RF, ANN, ANFIS, lógica difusa de Mamdani e HyFIS	HyFIS	R^2 = 0.9128; RMSE = 2.859 (entrenamiento: R^2 = 0.9895; RMSE = 1.069)	HE1, HE2
[28]	Planta industrial de flotación de Cu, antes y después de sustituir el colector SEX por PAX; ley y recuperación de Cu	CatBoost, RF, SVR, XGBoost y CNN	CatBoost	Error inferior a 2 % entre valores reales y predichos; superó a RF y XGBoost	HE1, HE2
[16]	Gemelo digital de dos celdas rougher de flotación de Au (registros cada 5 min durante casi 6 meses); ley de Au en el concentrado	Redes neuronales informadas por la física (PINN), red neuronal, regresión lineal, árbol de decisión y RF	PINN de balance de masa global	65 % menos MSE y 34 % menos MRE que el mejor modelo basado solo en datos	HE2
[27]	641 ensayos de laboratorio de flotación de carbón (512 de entrenamiento y 129 de prueba); rendimiento y cenizas del concentrado	GBDT, CatBoost, LightGBM y XGBoost	XGBoost	Rendimiento: R^2 = 0.836, MAE = 5.28, RMSE = 8.37; cenizas: R^2 = 0.853, MAE = 0.96, RMSE = 1.83. GBDT: R^2 = 0.764 y 0.688. Sin ensayos de rendimiento < 40 %: R^2 = 0.877 y 0.971	HE2
[87]	Planta polimetálica industrial (Marruecos), 6 meses de datos por guardia, 620 a 759 muestras (80/20); ley del concentrado y del relave de Cu, Pb y Zn	13 modelos: DT, RF, ExtraTrees, GBR, AdaBoost, XGBoost, LightGBM, CatBoost y cinco redes neuronales	CatBoost	Ley de Cu (MAE/RMSE): CatBoost 1.43/1.82; RF 1.46/1.84; XGBoost 1.47/1.87. Ley de Pb: 3.36/4.24; 3.39/4.46; 3.46/4.52. Diferencias no sometidas a prueba estadística	HE2, HE4
[88]	Planta de flotación de Fe (datos horarios de marzo a setiembre de 2017); ley de Fe y de SiO_2 del concentrado a 1 h	DGraFormer, modelo de persistencia, RF, XGBoost, LSTM y Transformer	DGraFormer	Fe: R^2 = 0.5423, RMSE = 0.7587, MAE = 0.5549 (persistencia: R^2 = 0.4660); SiO_2: R^2 = 0.6384, RMSE = 0.6917; RF y XGBoost con menor exactitud	HE2

Estudio	Material, datos y variable objetivo	Modelos comparados	Mejor modelo	Desempeño reportado	Hipótesis
[89]	Planta industrial de flotación de carbón; 26 225 registros continuos durante 45 días; dosificación de colector y de espumante	RF, XGBoost, DNN, LSTM, GRU, DNN-LSTM y LSTM-DNN	RF (modelos individuales); LSTM-DNN (global)	RF: MRE = 5.94 % (colector) y 8.11 % (espumante); LSTM-DNN: MRE = 4.39 % y 6.26 %	HE3, HE4
[90]	Dos plantas concentradoras de Cu por flotación (Antofagasta); 366 registros diarios (292 de entrenamiento y 74 de prueba); consumo de agua	SVR, XGBoost, ANN y RF	ANN	MAPE: ANN 4.47 %; SVR 4.57 %; RF 4.95 %; XGBoost 5.17 %	HE3, HE4

Nota. Elaboración propia a partir de los estudios citados. Las métricas corresponden a los datos de prueba o de validación que informa cada estudio; en [44] se reportan cotas del mejor modelo. HE: hipótesis específica; RF: Random Forest; SVR: regresión de vectores de soporte; SVM: máquina de vectores de soporte; GPR: regresión por procesos gaussianos; MLP: perceptrón multicapa; ANN: red neuronal artificial; ANFIS: sistema de inferencia neurodifusa adaptativa; HyFIS: sistema híbrido de inferencia neurodifusa; SEX: etilxantato de sodio; PAX: amilxantato de potasio; CNN: red neuronal convolucional; PINN: red neuronal informada por la física; GBDT: árboles de decisión con gradient boosting; DT: árbol de decisión; GBR: regresión por gradient boosting; DNN: red neuronal profunda; LSTM: red de memoria de corto y largo plazo; GRU: unidad recurrente con compuertas; MRE: error relativo medio, comparable con el MAPE; MSE: error cuadrático medio; VAF: varianza explicada.

La comparación anterior permitió sostener que los umbrales adoptados fueron exigentes, pero alcanzables. Un R^2 igual o superior a 0.75 coincidió con la categoría sustancial [30] y quedó por debajo de los valores reportados en los estudios revisados [20], [27], [43], lo que dejó margen para la mayor variabilidad de los relaves lixiviados. Un MAPE igual o inferior a 10 % correspondió a la categoría de precisión excelente [31] y fue coherente con los errores relativos inferiores a 2 % obtenidos para recuperación y ley [20], [28], [44]; en cambio, para el consumo específico de reactivos, cuyo coeficiente de variación en el primer trimestre fue de 44.84 % [11], ese mismo umbral representó un reto mayor. Por último, no se halló una norma que fijara una reducción mínima del error frente al modelo base, por lo que el valor de 15 % se estableció como criterio de mejora práctica definido por los autores, en concordancia con la recomendación de contrastar todo modelo con un referente ingenuo [24] y con reducciones muy superiores documentadas en flotación, como el 65 % del MSE logrado por Nasiri Abarbekouh et al. [16].

Un modelo predictivo fue concebido como una herramienta matemática o computacional que utilizaba datos históricos para estimar valores futuros o no observados de una variable objetivo. En esta investigación, el modelo predictivo

permitió estimar la recuperación de Au (%), la ley de Au en el concentrado (g/t) y el consumo específico de reactivos (kg/t) a partir de las variables mineralógicas y de composición de la alimentación, de dosificación de reactivos, fisicoquímicas, operacionales e hidráulicas, y de aireación y formación de espuma registradas en el proceso de flotación [7], [18].

La inteligencia artificial fue entendida como el conjunto de técnicas computacionales que permitían a los sistemas aprender de datos, reconocer patrones y apoyar la toma de decisiones. En procesos metalúrgicos, estas técnicas permitieron modelar relaciones complejas entre variables de operación y resultados metalúrgicos [3], [6], [51].

La flotación fue entendida como un proceso fisicoquímico de concentración mineral que separaba partículas valiosas de la ganga mediante diferencias de hidrofobicidad, utilizando burbujas de aire y reactivos químicos que favorecían la adhesión selectiva de minerales valiosos a la espuma [3], [36].

Los relaves de lixiviación fueron residuos sólidos generados después de un proceso de extracción química de metales, como la cianuración aurífera. Estos residuos podían contener Au remanente debido a limitaciones mineralógicas, químicas u operacionales del proceso previo [9], [10].

La flotación de relaves de lixiviación fue el proceso de concentración aplicado a residuos previamente lixiviados con el objetivo de recuperar minerales valiosos remanentes, principalmente Au asociado a sulfuros u otras fases minerales recuperables [10], [36].

El rendimiento de recuperación metálica expresó la eficiencia con la que un proceso lograba transferir el metal valioso desde la alimentación hacia el concentrado, y constituyó un indicador clave para evaluar la eficacia técnica de la flotación [36].

La recuperación de Au fue el porcentaje de oro contenido en la alimentación que se recuperó en el concentrado de flotación, descrita en la ecuación i1 [36], [38].

La calidad del concentrado se refirió al grado de enriquecimiento del mineral valioso en el producto obtenido por flotación. En el caso del oro, se expresó mediante la ley de Au en el concentrado, generalmente en g/t [10], [36].

La ley de Au en el concentrado expresó la cantidad de oro contenida por tonelada de concentrado producido, descrita en la ecuación i2 [36].

La eficiencia en el uso de insumos químicos se refirió al grado en que el proceso utilizaba reactivos de flotación de manera óptima para lograr recuperación y ley adecuadas, minimizando costos y efectos ambientales [12], [18].

El consumo específico de reactivos correspondió a la cantidad total de reactivos utilizados por unidad de masa alimentada al proceso, descrita en la ecuación i3 [12], [36].

Un sensor blando fue un modelo predictivo que permitía estimar variables difíciles de medir directamente mediante variables disponibles en línea. En flotación, podía estimar recuperación, ley de concentrado o consumo de reactivos usando datos operacionales [16].

La gestión sostenible de relaves implicó reducir los riesgos ambientales asociados a su almacenamiento, promover su reaprovechamiento y minimizar impactos sobre el entorno. El procesamiento de relaves auríferos mediante flotación permitía recuperar metales remanentes y disminuir la carga contaminante potencial de los depósitos mineros [2].

La economía circular en minería propuso aprovechar residuos y subproductos como nuevas fuentes de valor [1]. En este contexto, los relaves de lixiviación podían ser reincorporados al ciclo productivo mediante tecnologías de concentración y modelos predictivos que optimizaran la recuperación de metales y el uso de reactivos [2], [3].

Esta investigación se alineó con el Objetivo de Desarrollo Sostenible 9, referido a industria, innovación e infraestructura, especialmente con la modernización de industrias mediante tecnologías limpias, uso eficiente de recursos y procesos industriales ambientalmente racionales. La integración de modelos predictivos, sensores blandos e inteligencia artificial explicable favorecía una minería más eficiente, innovadora y sostenible [2], [16].

Se planteó la siguiente hipótesis general. Ho: El modelo predictivo basado en inteligencia artificial no presenta un desempeño predictivo adecuado para estimar la flotación de relaves de lixiviación. Esto se evidencia cuando, en al menos una de las variables objetivo (recuperación de Au, ley de Au en el concentrado o consumo

específico de reactivos), tanto Random Forest como XGBoost obtienen en el conjunto de prueba al menos uno de estos resultados: $R^2 < 0.75$, MAPE > 10 %, o un MAE o un RMSE igual o mayor que el del modelo base, Lima 2026.
Hi: El modelo predictivo basado en inteligencia artificial presenta un desempeño predictivo adecuado para estimar la flotación de relaves de lixiviación. Esto se evidencia cuando, en cada una de las tres variables objetivo, al menos uno de los algoritmos, Random Forest o XGBoost, obtiene a la vez en el conjunto de prueba un $R^2 \geq 0.75$, un MAPE ≤ 10 %, y un MAE y un RMSE menores que los del modelo base, Lima 2026. Regla de decisión: se acepta Hi cuando se aceptan Hi1, Hi2 y Hi3.

Se plantearon las siguientes hipótesis específicas: Hipótesis específica 1. Ho1: El modelo predictivo basado en inteligencia artificial no presenta una capacidad predictiva adecuada para estimar el rendimiento de la recuperación metálica, expresado mediante la recuperación de Au (%). Esto se evidencia cuando tanto Random Forest como XGBoost obtienen en el conjunto de prueba al menos uno de estos resultados: $R^2 < 0.75$, MAPE > 10 %, o un MAE o un RMSE igual o mayor que el del modelo base, Lima 2026. Hi1: El modelo predictivo basado en inteligencia artificial presenta una capacidad predictiva adecuada para estimar el rendimiento de la recuperación metálica, expresado mediante la recuperación de Au (%). Esto se evidencia cuando al menos uno de los algoritmos, Random Forest o XGBoost, obtiene a la vez en el conjunto de prueba un $R^2 \geq 0.75$, un MAPE ≤ 10 %, y un MAE y un RMSE menores que los del modelo base, Lima 2026. Hipótesis específica 2. Ho2: El modelo predictivo basado en inteligencia artificial no presenta una capacidad predictiva adecuada para estimar la calidad del concentrado, expresada mediante la ley de Au en el concentrado (g/t). Esto se evidencia cuando tanto Random Forest como XGBoost obtienen en el conjunto de prueba al menos uno de estos resultados: $R^2 < 0.75$, MAPE > 10 %, o un MAE o un RMSE igual o mayor que el del modelo base, Lima 2026. Hi2: El modelo predictivo basado en inteligencia artificial presenta una capacidad predictiva adecuada para estimar la calidad del concentrado, expresada mediante la ley de Au en el concentrado (g/t). Esto se evidencia cuando al menos uno de los algoritmos, Random Forest o XGBoost, obtiene a la vez en el conjunto de prueba un $R^2 \geq 0.75$, un MAPE ≤ 10 %, y un MAE y un RMSE menores que los del modelo base, Lima 2026. Hipótesis específica 3. Ho3: El modelo predictivo basado en inteligencia artificial no presenta una capacidad predictiva adecuada para estimar

la eficiencia en el uso de insumos químicos, expresada mediante el consumo específico de reactivos (kg/t). Esto se evidencia cuando tanto Random Forest como XGBoost obtienen en el conjunto de prueba al menos uno de estos resultados: $R^2 < 0.75$, MAPE > 10 %, o un MAE o un RMSE igual o mayor que el del modelo base, Lima 2026.

Hi3: El modelo predictivo basado en inteligencia artificial presenta una capacidad predictiva adecuada para estimar la eficiencia en el uso de insumos químicos, expresada mediante el consumo específico de reactivos (kg/t). Esto se evidencia cuando al menos uno de los algoritmos, Random Forest o XGBoost, obtiene a la vez en el conjunto de prueba un $R^2 \geq 0.75$, un MAPE ≤ 10 %, y un MAE y un RMSE menores que los del modelo base, Lima 2026. Hipótesis específica 4. Ho4: Ninguno de los modelos, Random Forest o XGBoost, presenta un desempeño predictivo significativamente superior al del otro en las variables objetivo de la flotación de relaves de lixiviación. Esto se evidencia cuando, en cada variable, ocurre en el conjunto de prueba al menos una de estas situaciones: ningún algoritmo obtiene a la vez mayor R^2 y menores RMSE, MAE y MAPE que el otro; la prueba de Diebold-Mariano da $p \geq 0.05$ con los errores al cuadrado o con los errores absolutos, Lima 2026. Hi4: Uno de los modelos, Random Forest o XGBoost, presenta un desempeño predictivo significativamente superior al del otro en al menos una de las variables objetivo de la flotación de relaves de lixiviación. Esto se evidencia cuando, en esa variable, el algoritmo superior cumple a la vez en el conjunto de prueba estas condiciones: obtiene mayor R^2 y menores RMSE, MAE y MAPE que el otro; la prueba de Diebold-Mariano da $p < 0.05$ tanto con los errores al cuadrado como con los errores absolutos, Lima 2026.

Los valores de decisión de las hipótesis se fijaron a partir de la literatura revisada y se resumen en la Tabla 3. El umbral de $R^2 \geq 0.75$ correspondió a la categoría sustancial de las convenciones de análisis multivariado [30] y fue coherente con los coeficientes de 0.836 a 0.971 reportados para modelos de ensamble en flotación [20], [27], [43]; el umbral de MAPE ≤ 10 % se basó en la categoría de precisión excelente [31]; y la reducción del MAE y del RMSE frente al modelo base se definió como criterio de mejora práctica, siguiendo la recomendación de comparar todo modelo con un referente ingenuo [24]. La hipótesis alterna se aceptó solo cuando se cumplieron simultáneamente los tres criterios, de modo que bastó el incumplimiento de uno de

ellos para no rechazar la hipótesis nula. Para la cuarta hipótesis específica, la significancia de las diferencias entre los errores de Random Forest y XGBoost se evaluó con la prueba de Diebold-Mariano, empleada para comparar la exactitud predictiva de modelos de regresión, aprendizaje automático y aprendizaje profundo [52], [53].

Tabla 3

Criterios de decisión para el contraste de las hipótesis

Hipótesis	Variable objetivo	Métrica en el conjunto de prueba	Criterio para aceptar la hipótesis alterna	Sustento
HE1	Recuperación de Au (%)	R^2	≥ 0.75	[20], [37]
		MAPE	≤ 10 %	[20], [31], [44]
		MAE	Menor que el MAE del modelo base	[24], [60]
		RMSE	Menor que el RMSE del modelo base	[24], [60]
		Regla de decisión	Se acepta Hi1 si Random Forest o XGBoost cumple a la vez los cuatro criterios. Se acepta Ho1 si ambos algoritmos incumplen al menos uno de ellos	[59]
HE2	Ley de Au en el concentrado (g/t)	R^2	≥ 0.75	[27], [37]
		MAPE	≤ 10 %	[16], [31]
		MAE	Menor que el MAE del modelo base	[24], [88]
		RMSE	Menor que el RMSE del modelo base	[24], [88]
		Regla de decisión	Se acepta Hi2 si Random Forest o XGBoost cumple a la vez los cuatro criterios. Se acepta Ho2 si ambos algoritmos incumplen al menos uno de ellos	[59]
HE3	Consumo específico de reactivos (kg/t)	R^2	≥ 0.75	[20], [27]
		MAPE	≤ 10 %	[31], [89], [90]
		MAE	Menor que el MAE del modelo base	[24], [60]
		RMSE	Menor que el RMSE del modelo base	[24], [60]
		Regla de decisión	Se acepta Hi3 si Random Forest o XGBoost cumple a la vez los cuatro criterios. Se acepta Ho3 si ambos algoritmos incumplen al menos uno de ellos	[59]
HG	Recuperación de Au, ley de Au en el concentrado y consumo específico de reactivos	Regla de decisión conjunta	Se acepta Hi si se aceptan Hi1, Hi2 y Hi3. Se acepta Ho si se acepta al menos una de Ho1, Ho2 u Ho3	Autores

Hipótesis	Variable objetivo	Métrica en el conjunto de prueba	Criterio para aceptar la hipótesis alterna	Sustento
HE4	Random Forest frente a XGBoost, en cada variable objetivo	R^2, RMSE, MAE y MAPE	Un mismo algoritmo obtiene mayor R^2 y menores RMSE, MAE y MAPE que el otro	[59], [87]
		Prueba de Diebold-Mariano con errores al cuadrado	$p < 0.05$	[52], [53], [74]
		Prueba de Diebold-Mariano con errores absolutos	$p < 0.05$	[52], [72], [74]
		Regla de decisión	Se acepta Hi4 si, en al menos una variable objetivo, el mismo algoritmo cumple a la vez los tres criterios. Se acepta Ho4 si, en cada variable, ningún algoritmo domina las cuatro métricas o la prueba da $p \geq 0.05$ con alguno de los dos tipos de error	[24], [59]

Nota. Elaboración propia a partir de las hipótesis de la investigación y de [16], [20], [24], [27], [31], [37], [44], [52], [53], [59], [60], [72], [74] y [87]–[90]. Todas las métricas se calculan en el conjunto de prueba. El modelo base predice la media de la variable objetivo en los datos de entrenamiento y validación [60]. Los umbrales de R^2 y MAPE coinciden con el límite inferior de la categoría «sustancial» y el límite superior de la categoría «excelente» de la Tabla 1, respectivamente. En HE4, el signo del estadístico de Diebold-Mariano indica qué algoritmo predice mejor y debe coincidir con el que domina en las cuatro métricas; la prueba se aplica con la corrección para muestras pequeñas de la función dm.test [74]. Hi: hipótesis alterna; Ho: hipótesis nula; HG: hipótesis general; HE: hipótesis específica.

El contraste de estas hipótesis brindó una base estadística para valorar si el modelo de inteligencia artificial desarrollado funcionaba de manera estable y repetible con los datos de operación de enero a setiembre de 2026, de modo que los responsables de la toma de decisiones en una planta en la región de Lima contaran con criterios objetivos para confiar en sus predicciones. La correspondencia entre problemas, objetivos, hipótesis, variables y metodología se resume en la matriz de consistencia (Anexo 6).

II. Metodología

La investigación fue de tipo aplicado, según la clasificación de Ñaupas et al. [54], y tuvo orientación tecnológica. Partió de un problema concreto de la planta, la flotación inestable de relaves de lixiviación, que se manifestaba en una alimentación variable, recuperaciones y leyes fluctuantes y una dosificación de reactivos sin criterio cuantitativo. Más que describir ese comportamiento, el estudio buscó una herramienta que lo anticipara: modelos predictivos basados en inteligencia artificial que estimaran las variables metalúrgicas críticas y sirvieran de apoyo a las decisiones de operación [3], [6].

Las tres variables que se buscó predecir, la recuperación de oro, la ley de oro en el concentrado y el consumo específico de reactivos, son las que la planta usa para juzgar su desempeño técnico y económico, y deben leerse juntas: de poco sirve una recuperación alta si la ley del concentrado cae o si se logra a costa de un consumo excesivo de reactivos [36], [38].

La orientación tecnológica se reflejó en el uso de Random Forest y XGBoost, entrenados con los datos del sistema SCADA/PLC, los reportes metalúrgicos y los análisis de laboratorio. Con ellos se construyeron sensores blandos, es decir, modelos que estiman variables difíciles de medir en línea (ecuación i9), de modo que la operación no dependa únicamente de los análisis que llegan después del proceso [7], [16].

El estudio se inscribe así en la línea de la minería digital. En flotación, el pH, el potencial redox, la densidad de pulpa, el caudal de aire, la granulometría, el tiempo de residencia y la dosificación de reactivos interactúan entre sí, y esas interacciones producen respuestas que un modelo lineal o el criterio empírico del operador no siempre alcanzan a captar [3], [6].

El enfoque fue cuantitativo. Todo el análisis se hizo sobre datos numéricos del proceso: masas y leyes de alimentación y de concentrado, recuperación, pH, densidad de pulpa, potencial redox, caudal de aire, tiempo de flotación y consumo de reactivos, entre otros. Con esos datos fue posible representar el proceso mediante modelos matemáticos y juzgar su desempeño con indicadores estadísticos [7], [18].

Lo que se buscó medir fue la relación entre las entradas y las salidas del proceso. Las entradas fueron 38 variables agrupadas en cinco bloques (composición de la alimentación, dosificación de reactivos, condiciones fisicoquímicas, condiciones operacionales e hidráulicas, y aireación y formación de espuma), y las salidas, la recuperación de Au, la ley de Au en el concentrado y el consumo específico de reactivos. La precisión de las predicciones se evaluó con métricas de regresión [3], [18].

Ese mismo enfoque hizo posible comparar los algoritmos con el R^2, el MAE, el RMSE y el MAPE calculados sobre datos que los modelos no habían visto durante el entrenamiento, de manera que la elección del mejor modelo descansó en cifras que cualquier otro investigador puede recalcular [16], [18].

El diseño fue no experimental, transversal y predictivo. Fue no experimental porque los investigadores no modificaron las condiciones de la flotación ni aplicaron tratamientos: se trabajó con los registros que la planta generó durante su operación normal, de modo que el pH, la densidad de pulpa, el potencial redox, el caudal de aire, la dosificación de reactivos, la recuperación y la ley se analizaron tal como ocurrieron [3], [18].

El diseño fue transversal según el tiempo, porque la información se recopiló y analizó dentro de un periodo delimitado, de enero a setiembre de 2026. Aunque los registros se distribuyeron en diferentes turnos, días y meses de operación, se consolidaron en una sola base de datos que conservó su orden cronológico, requisito de la partición temporal empleada para evaluar los modelos. Esta delimitación permitió evaluar el comportamiento de la flotación en un periodo definido, sin que el estudio implicara seguimiento experimental prolongado ni intervención gradual sobre las condiciones de operación [3], [16].

Fue predictivo porque el propósito era construir, entrenar, validar y comparar modelos capaces de estimar la recuperación de Au, la ley de Au en el concentrado y el consumo específico de reactivos a partir de las variables registradas en planta. Los datos históricos se usaron, por tanto, para aprender el comportamiento del proceso y anticiparlo en condiciones nuevas, algo que los métodos convencionales logran con dificultad en un sistema multivariable y no lineal como la flotación [3], [7].

Los modelos se concibieron como apoyo a la decisión y no como un control automático. Sus predicciones debían pasar por el criterio de los metalurgistas, que conocen las restricciones del proceso y las condiciones de seguridad, sobre todo cuando la planta opera en escenarios que no aparecen en los datos con que se entrenaron [7], [16].

El alcance fue explicativo, con propósito predictivo y orientación aplicada. Se consideró explicativo porque, además de estimar las salidas del proceso, el estudio buscó identificar qué variables de composición de la alimentación, de dosificación, fisicoquímicas y operacionales pesaban más en la recuperación de oro, en la ley del concentrado y en el consumo específico de reactivos. Para ello se recurrió a medidas de importancia de variables, que muestran en qué predictores se apoya cada modelo [3], [7], [46].

El propósito predictivo responde a una limitación práctica: la ley del concentrado y la recuperación de oro se conocen recién cuando llegan los análisis de laboratorio o el balance metalúrgico, y para entonces la guardia ya terminó. Un sensor blando que las estime antes da al operador la oportunidad de corregir a tiempo [6], [16].

La orientación aplicada se tradujo en recomendaciones concretas para la planta: implementar los modelos como sensores blandos, reentrenarlos periódicamente y revisar la dosificación de reactivos. Con ellas se espera reducir costos y el uso innecesario de reactivos, y aprovechar mejor los relaves como fuente secundaria de metales, en línea con la economía circular en minería [2], [13].

La variable independiente estuvo constituida por el “modelo predictivo basado en inteligencia artificial”, definido como un sistema computacional basado en aprendizaje automático que permitía procesar datos históricos, reconocer patrones y estimar el comportamiento de variables objetivo a partir de un conjunto de variables predictoras. En procesos metalúrgicos, estos modelos resultaron especialmente útiles porque permitían representar relaciones no lineales entre variables operacionales y resultados del proceso, tales como la recuperación de oro, la ley del concentrado y el consumo de reactivos. Su aplicación en flotación permitió superar en parte las limitaciones de los métodos tradicionales, ya que estos modelos podían analizar simultáneamente múltiples variables que interactuaban de forma compleja dentro del circuito [3], [7].

La variable dependiente estuvo constituida por el proceso de “flotación de relaves de lixiviación”, definido como un proceso fisicoquímico de concentración mineral aplicado a residuos sólidos posteriores a la lixiviación, cuyo objetivo era recuperar minerales valiosos remanentes mediante la separación selectiva por flotación. En este proceso, las partículas con comportamiento hidrofóbico se adherían a burbujas de aire y eran transportadas hacia la espuma para formar el concentrado, mientras que las partículas hidrofílicas permanecían en la pulpa y eran descargadas como relave. En relaves previamente lixiviados, la respuesta metalúrgica podía ser más compleja debido a alteraciones superficiales del mineral, presencia de reactivos residuales, variabilidad granulométrica y heterogeneidad mineralógica [2], [3], [18].

Desde el punto de vista operacional, la variable dependiente “flotación de relaves de lixiviación” se midió cuantitativamente mediante tres dimensiones: “rendimiento de recuperación metálica”, “calidad del concentrado” y “eficiencia en el uso de insumos químicos” (Anexo 1). Con estas tres dimensiones se cubrió el proceso completo: una operación eficiente debe recuperar la mayor cantidad posible de oro, producir un concentrado de buena calidad y usar solo los reactivos necesarios. Los tres indicadores se midieron en escala de razón, lo que permite compararlos de manera proporcional [12], [36], [38].

La dimensión “rendimiento de recuperación metálica”, de la variable dependiente “flotación de relaves de lixiviación”, se midió mediante el indicador “recuperación de Au” (%), expresado en escala de razón. Este indicador representó el porcentaje de oro contenido en la alimentación que se transfirió al concentrado, por lo que constituyó una medida directa de la eficiencia metalúrgica del proceso. Su evaluación permitió determinar si las condiciones operacionales y de dosificación favorecían la recuperación del metal valioso remanente en los relaves lixiviados [36], [38]. Matemáticamente, se calculó mediante la expresión i1 [36], [38].

La dimensión “calidad del concentrado”, de la variable dependiente “flotación de relaves de lixiviación”, se midió mediante el indicador “ley de Au en el concentrado” (g/t), expresado en escala de razón. Este indicador representó la cantidad de oro contenida por unidad de masa de concentrado y permitió evaluar el grado de enriquecimiento del producto obtenido. Su importancia radicó en que una alta

recuperación no necesariamente implicaba una adecuada selectividad; por ello, la ley del concentrado debió analizarse conjuntamente con la recuperación para determinar el equilibrio metalúrgico entre cantidad recuperada y calidad del producto [36], [38]. Matemáticamente, se determinó mediante la expresión i2 [36], [38].

La dimensión “eficiencia en el uso de insumos químicos”, de la variable dependiente “flotación de relaves de lixiviación”, se midió mediante el indicador “consumo específico de reactivos en la flotación” (kg/t), expresado en escala de razón. Este indicador representó la cantidad total de reactivos utilizados por unidad de masa alimentada al proceso, lo que permitió evaluar la eficiencia económica, operativa y ambiental del circuito. Su análisis fue importante porque un consumo excesivo de reactivos podía incrementar los costos operativos, afectar la selectividad, generar arrastre de ganga y aumentar el impacto ambiental del proceso [12], [36]. Matemáticamente, se calculó mediante la expresión i3 [12], [36].

La unidad de análisis fue el registro operacional del circuito industrial de flotación de relaves de lixiviación de una planta concentradora de la región de Lima, generado entre enero y setiembre de 2026. Cada registro correspondió a una guardia de operación y reunió, en una sola fila, las lecturas del sistema SCADA/PLC, las determinaciones del laboratorio metalúrgico y los consumos de reactivos de ese turno. Así, cada observación describió el estado del circuito en condiciones industriales que los investigadores no manipularon [3], [7].

Cada registro contenía las 38 variables predictoras de la ficha, entre ellas las determinaciones de composición del bloque ccPy, la ley de Au de cabeza, el pH, la densidad de pulpa, el porcentaje de sólidos, el potencial redox, el caudal de pulpa, el caudal de aire, el nivel de pulpa, el tiempo de flotación, la masa de alimentación y las dosificaciones de sulfato de cobre, metabisulfito de sodio, PAX + SIPX, MIBC y antiespumante. A estas se sumaban las tres variables de respuesta: recuperación de Au, ley de Au en el concentrado y consumo específico de reactivos. Esta estructura, con entradas y salidas del mismo turno en una misma fila, es la que necesita un modelo supervisado para aprender la relación entre ambas [16], [36].

Trabajar con registros individuales y fechados facilitó armar una base ordenada en el tiempo, requisito para separar los datos en entrenamiento, validación y prueba. Además, al provenir de la operación real, los registros recogieron la variabilidad

natural del proceso, que es justamente lo que un modelo debe aprender para generalizar a condiciones nuevas [3], [55].

Definir la guardia como unidad obligó, además, a sincronizar los datos del SCADA/PLC con los análisis químicos, los balances metalúrgicos y los reportes diarios. Sin ese cuidado, las condiciones de un turno podían quedar asociadas al resultado de laboratorio de otro, error que distorsionaría tanto el entrenamiento como la interpretación de los modelos [7], [16].

La población de la investigación estuvo conformada por la totalidad de los registros históricos y operacionales correspondientes al proceso de flotación de relaves de lixiviación generados entre enero y setiembre de 2026, en una planta concentradora ubicada en la región de Lima. Esta población comprendió los datos registrados por los sistemas SCADA/PLC, reportes metalúrgicos, análisis químicos de laboratorio, balances de masa y registros de consumo de reactivos. Por tanto, estuvo integrada por información cuantitativa asociada tanto a las condiciones de operación del proceso como a los resultados metalúrgicos obtenidos en el circuito de flotación [3], [6].

La población incluyó variables operacionales como flujo de alimentación, tiempo de residencia, tonelaje procesado y condiciones de operación del circuito; variables fisicoquímicas como pH, potencial redox y densidad de pulpa; y variables de dosificación química, como consumo de colectores, espumantes, activadores, depresores, modificadores de pH y antiespumantes. Asimismo, comprendió variables de respuesta metalúrgica, entre ellas recuperación de Au, ley de Au en el concentrado, ley de relave, masa de concentrado, masa de relave y consumo específico de reactivos. Así, la población abarcó tanto las entradas como las salidas del proceso [12], [36].

Se tomaron los nueve meses de operación disponibles, de enero a setiembre de 2026, para que la base incluyera cambios en el relave alimentado, en la dosificación de reactivos y en las prácticas de operación, así como periodos de recuperación y ley altas y bajas. Un modelo que solo ha visto un régimen de operación tiende a fallar cuando la planta cambia; por eso convenía que el periodo de estudio abarcara varios [20], [55].

En términos metalúrgicos, la heterogeneidad del relave hacía que condiciones de flotación en apariencia iguales dieran resultados distintos. Por esa razón se analizaron todos los registros disponibles y no una selección. A diferencia de los estudios de laboratorio, en los que las condiciones se controlan, aquí los datos procedieron de la planta, lo que acerca los resultados a su uso real [3], [9], [10].

Se consideraron como criterios de inclusión los registros generados durante la operación normal del circuito de flotación de relaves de lixiviación en el periodo de estudio, que contaron con valores válidos de las variables de entrada definidas en la ficha de recolección de datos y con resultados metalúrgicos de laboratorio sincronizables con las condiciones de operación. Se establecieron como criterios de exclusión los registros correspondientes a paradas de planta, arranques, mantenimientos programados o fallas de instrumentación; los registros duplicados; aquellos con valores fuera del rango físico de medición de los sensores; y los que no pudieron vincularse con un resultado metalúrgico de laboratorio [23], [55].

La muestra estuvo conformada por la totalidad de los registros válidos del periodo de estudio. Dado que la investigación utilizó todos los registros que cumplieron los criterios de inclusión, se trabajó con un censo de datos; por ello, no fue necesario aplicar un procedimiento de muestreo y la muestra coincidió con la población válida, conformada por 547 registros, obtenidos tras aplicar los criterios de inclusión y exclusión [7], [16], [55].

La técnica fue la observación estructurada y no participante de los registros que generó la flotación de relaves de lixiviación en la planta. Se eligió porque permite obtener los datos numéricos del proceso sin intervenir en él, como corresponde a un diseño no experimental, y porque variables como el pH, la densidad de pulpa, el potencial redox, el caudal de pulpa, el tiempo de flotación y la dosificación de reactivos ya quedaban registradas en la operación diaria [3], [36].

En concreto, la observación consistió en revisar y extraer los datos del sistema SCADA/PLC, de los reportes metalúrgicos, de los balances de masa, de los análisis químicos y de los registros de consumo de reactivos, y en trasladarlos a la ficha de recolección. De esas fuentes salieron tanto las variables de entrada como las de salida: la recuperación de Au, la ley de Au en el concentrado y el consumo específico de reactivos [3], [18].

Se trató de una observación indirecta y documental: los datos ya habían sido generados por los instrumentos de planta, el laboratorio y el sistema de control cuando los investigadores los recopilaron. Esto redujo la posibilidad de que el observador influyera en las mediciones y permitió rastrear cada dato hasta su fuente. Los registros históricos de este tipo son, además, la materia prima habitual de los sensores blandos en procesamiento de minerales [7], [16].

Al cubrir todo el periodo de estudio, la observación recogió las fluctuaciones de la alimentación, los cambios de dosificación, las variaciones de la pulpa y las diferencias en los resultados metalúrgicos, información sin la cual Random Forest y XGBoost no habrían tenido de qué aprender [6], [7].

Por estas razones, la observación de registros fue la técnica que mejor se ajustó al objetivo de evaluar modelos predictivos con datos industriales reales, cuyos resultados pudieran trasladarse a la toma de decisiones en la planta [16], [36].

El instrumento fue la Ficha de Recolección de Datos Operacionales y Metalúrgicos (Anexo 2), con la que se reunió y ordenó la información de la flotación de relaves de lixiviación entre enero y setiembre de 2026. En ella se integraron, por guardia, los datos del sistema SCADA/PLC, de los reportes de laboratorio metalúrgico y de los reportes de producción, de modo que la base resultante pudiera usarse directamente para entrenar, validar y evaluar los modelos. Un proceso con tantas variables en juego como la flotación exige registros sistemáticos de este tipo [3], [36].

La ficha reunió, para cada registro, las variables de entrada y las tres variables de salida que los modelos debían estimar. Su diseño respondió a la lógica de un sensor blando: dejar juntas las variables disponibles durante el proceso y aquellas que solo se conocen después, cuando llegan el análisis de laboratorio o el balance metalúrgico [7], [16].

En el instrumento se consignaron las variables de entrada y de salida del proceso de “flotación de relaves de lixiviación” registradas por el sistema SCADA/PLC y por el laboratorio metalúrgico. Las variables de entrada se agruparon en cinco bloques: mineralógicas y de composición de la alimentación; de dosificación de reactivos; fisicoquímicas; operacionales e hidráulicas; y de aireación y formación de espuma [3], [11], [23]. En primer lugar, las variables mineralógicas y de composición de la alimentación comprendieron las leyes de cobre (Cu ccPy), plomo (Pb ccPy), zinc (Zn

ccPy), hierro (Fe ccPy), arsénico (As ccPy) y plata (Ag ccPy) [11], [34], [37], así como el contenido de humedad (%H_2O ccPy) [11], el porcentaje pasante por la malla 200 (200M_ccPy) [10], [23], la ley de oro en la alimentación o cabeza, expresada en gramos por tonelada (g/t) [7], [10], [38], el porcentaje de sólidos, el contenido de insolubles, la densidad de pulpa en gramos por litro (g/L) [5], [11], [36] y la granulometría pasante por la malla 200 [23], [36]. Asimismo, se incluyeron los parámetros granulométricos K30, K50 y K80, expresados en micrómetros (µm) [7], [36]. En segundo lugar, las variables relacionadas con la dosificación de reactivos estuvieron constituidas por el consumo de sulfato de cobre [12], [13], la mezcla de xantato amílico de potasio y xantato isopropílico de sodio, identificados como PAX + SIPX (Z-6 + Z-11) [7], [10], [28], [37], el metil isobutil carbinol (MIBC) [10], [23], [37], el metabisulfito de sodio [12], [13] y el antiespumante [11], cuyas dosificaciones se expresaron en kilogramos por tonelada de mineral tratado (kg/t) [10], [11]. Las variables fisicoquímicas incluyeron el pH inicial y final, de carácter adimensional [5], [10], [18]; el potencial de oxidación-reducción o potencial redox, expresado en milivoltios (mV) [12], [23]; el oxígeno disuelto, medido en miligramos por litro (mg/L) [12]; las concentraciones inicial y final de cianuro libre (FCN_Inic y FCN_Fin), expresadas en partes por millón (ppm) [11], [12], [37]; y la concentración residual de cianuro libre, medida en miligramos por litro (mg/L) [11], [34], [38]. Por otro lado, las variables operacionales e hidráulicas comprendieron la masa de alimentación en toneladas [23], [38], el caudal de pulpa en metros cúbicos por hora (m^3/h) [5], [38], el caudal de agua de lavado cuando correspondiera [11], [36], el nivel de pulpa [4], [5] y el tiempo de flotación expresado en minutos [10], [18], [37]. Finalmente, las variables asociadas con la aireación y la formación de espuma estuvieron conformadas por el caudal de aire en metros cúbicos normales por hora (Nm^3/h) [4], [5], [37], la presión de aire y la presión del manifold en kilopascales (kPa), el porcentaje de apertura de aire [11] y la altura de la espuma en milímetros (mm) [4], [23]. En conjunto, estas variables constituyeron predictores (features) pertinentes para el entrenamiento del “modelo predictivo basado en inteligencia artificial”, debido a que los modelos de aprendizaje automático aplicados a flotación empleaban parámetros fisicoquímicos, operacionales y dosificaciones de reactivos como entradas para predecir el desempeño metalúrgico del proceso [3], [12], [36]. El bloque identificado con el sufijo ccPy se agrupó con la composición de la alimentación siguiendo la estructura del

registro de planta; el punto de muestreo y el momento en que estas determinaciones quedan disponibles se examinan en la discusión.

Las variables de salida estuvieron conformadas por la recuperación de Au (%), la ley de Au en el concentrado (g/t) y el consumo específico de reactivos (kg/t). Estos indicadores permitieron evaluar el rendimiento de recuperación metálica, la calidad del concentrado y la eficiencia en el uso de insumos químicos, por lo que constituyeron las variables objetivo para el entrenamiento, validación y evaluación de los modelos predictivos aplicados al proceso de flotación [3], [18], [36].

La ficha de registro fue sometida a juicio de expertos: un ingeniero industrial, un ingeniero de minas y un ingeniero de sistemas, quienes evaluaron la pertinencia, claridad y consistencia de cada uno de sus componentes según los criterios de suficiencia, claridad, coherencia y relevancia [56]. Posteriormente, la validez de contenido fue determinada mediante el coeficiente V de Aiken [57], [58], y se obtuvo un valor de 1.00 en cada uno de los cuatro criterios y en el coeficiente general, dado que los tres jueces calificaron con acuerdo total todos los indicadores del instrumento, lo que evidenció una validez de contenido adecuada (Anexo 3).

Asimismo, los registros históricos fueron sometidos a un proceso de depuración que incluyó la identificación de valores atípicos, tratamiento de datos faltantes, normalización de variables y verificación de consistencia antes del entrenamiento de los modelos predictivos [23].

La confiabilidad del instrumento se verificó con una prueba piloto sobre un grupo reducido de registros operacionales y metalúrgicos. El propósito fue comprobar que la ficha registrara de forma consistente las 38 variables de entrada y las tres de salida, ya que cualquier error en ellas se trasladaría a los modelos [6], [16].

En la prueba se buscaron errores de transcripción, datos faltantes, campos duplicados, unidades mal consignadas y desfases entre los datos del SCADA/PLC y los resultados de laboratorio; las inconsistencias halladas se corrigieron antes de aplicar la ficha a toda la base. Bajo este enfoque, un instrumento confiable es el que produce datos completos, en unidades homogéneas y rastreables hasta su fuente [7], [55]. La prueba piloto se aplicó a 10 registros y arrojó coeficientes de correlación intraclase (ICC) y de Pearson cercanos a la unidad, con errores porcentuales mínimos. Como el instrumento era una ficha de registro de datos cuantitativos y no

una escala de ítems, no correspondía estimar un coeficiente de consistencia interna como el alfa de Cronbach.

Una vez validado y ajustado el instrumento, se consolidó el dataset definitivo, el cual fue dividido en subconjuntos de entrenamiento, validación y prueba, en proporciones de 70 %, 15 % y 15 %, respectivamente. Esta partición correspondió al proceso de evaluación del modelo predictivo y no debía confundirse con la prueba piloto del instrumento. Además, se priorizó una partición temporal para respetar la cronología de los datos y evitar fugas de información entre subconjuntos, lo cual permitió evaluar de manera más realista la capacidad de generalización del modelo frente a nuevas condiciones operativas [24].

La confiabilidad del modelo predictivo se determinó a partir de la estabilidad y la precisión de sus resultados en los subconjuntos de entrenamiento, validación y prueba. Para ello, se emplearon R^2, MAE, RMSE y MAPE, que permitieron medir la capacidad predictiva de Random Forest y XGBoost y contrastarla con la del modelo base, cuya predicción constante correspondió a la media histórica de la variable objetivo [24]. Además, el riesgo de sobreajuste se controló mediante la comparación entre modelos, la evaluación de los hiperparámetros en el subconjunto de validación y la partición cronológica de los datos [24], [40]. El modelo fue considerado adecuado cuando cumplió los criterios establecidos en las hipótesis del estudio y cuando sus predicciones resultaron técnicamente coherentes con el comportamiento metalúrgico del proceso [3], [7], [18].

La interpretabilidad se usó como criterio complementario. Mediante la importancia de variables, por permutación en Random Forest y por ganancia en XGBoost, se revisó si los predictores que cada modelo consideraba relevantes tenían sentido desde el punto de vista metalúrgico; el análisis SHAP quedó contemplado como complemento. Un modelo preciso pero cuyas variables principales carecieran de explicación física difícilmente sería aceptado por los ingenieros de planta [7], [16].

El análisis de datos se desarrolló a partir de los registros operacionales y metalúrgicos obtenidos del proceso de flotación de relaves de lixiviación en una planta en la región Lima durante el año 2026. La base de datos integró variables de entrada asociadas a condiciones de alimentación, variables fisicoquímicas, parámetros operacionales y dosificación de reactivos; mientras que las variables de salida estuvieron conformadas

por recuperación de Au, ley de Au en el concentrado y consumo específico de reactivos. Esta estructura permitió relacionar las condiciones reales de operación con el desempeño metalúrgico, algo necesario en un sistema multivariable y no lineal como la flotación [3], [16].

En una primera fase se realizó el análisis exploratorio de datos, con el propósito de describir el comportamiento de las variables consideradas en el estudio. Para ello, se calcularon medidas de tendencia central, dispersión, valores máximos, mínimos, rangos y coeficientes de variación; asimismo, se elaboraron histogramas, diagramas de caja, gráficos de dispersión y análisis temporal de los registros. Esta fase permitió identificar patrones de operación, fluctuaciones en la recuperación metalúrgica, variaciones en la ley del concentrado, consumos anómalos de reactivos y posibles valores atípicos. Antes de entrenar cualquier modelo convenía conocer cómo se comportaba cada variable, porque en un proceso tan complejo como la flotación los valores anómalos o los cambios de régimen pueden pasar inadvertidos si se trabaja directamente con el algoritmo [3], [7].

En una segunda fase se efectuó el preprocesamiento de datos, que comprendió la depuración de registros incompletos, tratamiento de valores faltantes, identificación de datos atípicos, estandarización de unidades de medida, normalización o escalamiento de variables cuando correspondió y sincronización temporal entre los datos generados por el sistema SCADA/PLC y los resultados metalúrgicos de laboratorio. Esta etapa fue necesaria porque los datos provenían de fuentes con distinta frecuencia de captura y los resultados de laboratorio podían llegar desfasados respecto a las condiciones registradas en línea; una mala correspondencia entre ambos habría introducido errores en el entrenamiento [16], [55].

En una tercera fase se realizó la partición del dataset en subconjuntos de entrenamiento, validación y prueba, priorizando una división temporal que respetó la cronología de los registros operacionales. Esta partición evitó la fuga de información entre subconjuntos y permitió evaluar de manera más realista la capacidad de generalización de los modelos frente a condiciones futuras del proceso. De manera referencial, se empleó una proporción de 70 % para entrenamiento, 15 % para validación y 15 % para prueba. Esta etapa no debía confundirse con la prueba piloto

del instrumento, porque la partición del dataset correspondió a la evaluación del modelo predictivo y no a la confiabilidad de la ficha de recolección de datos [7], [16].

En una cuarta fase se entrenaron y compararon modelos supervisados de regresión, Random Forest y XGBoost, debido a que ambos algoritmos presentaban ventajas para trabajar con datos tabulares industriales, relaciones no lineales e interacciones complejas entre variables de proceso. Random Forest fue utilizado por su capacidad para combinar múltiples árboles de decisión y reducir la varianza mediante ensamble (ecuación i6), mientras que XGBoost fue considerado por su capacidad de construir árboles de manera secuencial, corrigiendo errores residuales y controlando el sobreajuste mediante regularización (ecuaciones i7 e i8). Esta selección fue coherente con el objetivo del estudio, debido a que se buscó estimar variables cuantitativas críticas del proceso de flotación, como la recuperación metalúrgica, la ley del concentrado y el consumo específico de reactivos [3], [7].

Antes del entrenamiento de estos algoritmos, se construyó un modelo base (baseline) para cada una de las tres variables objetivo, con la finalidad de disponer de una referencia mínima de desempeño frente a la cual juzgar si los modelos de inteligencia artificial aportaban capacidad predictiva real [24], [59]. Este modelo correspondió a un predictor ingenuo de valor constante, también denominado modelo dummy, que no empleó ninguna variable predictora ni aprendió patrones de los datos: su único parámetro fue la media aritmética de la variable objetivo, calculada con la ecuación i4 a partir de los registros de los subconjuntos de entrenamiento y validación, y ese mismo valor se asignó como predicción a todos los registros del conjunto de prueba, conforme a la ecuación i5 [25], [59]. Debido a que carecía de hiperparámetros, el modelo base no requirió una etapa de ajuste en el subconjunto de validación, por lo que dicho subconjunto se incorporó al cálculo de la media; asimismo, al emplear solo registros anteriores al periodo de prueba, respetó la partición temporal y evitó la fuga de información futura [24]. Se programó directamente en R y equivale a la clase DummyRegressor de scikit-learn con la estrategia de la media (strategy = "mean"), que asigna a toda observación nueva el promedio de la variable objetivo en los datos de ajuste [60].

En concreto, el modelo base se aplicó de manera independiente a cada una de las tres variables objetivo, y su único cálculo fue la media aritmética de la variable en el

conjunto de ajuste, formado por los 464 registros de los subconjuntos de entrenamiento (382) y de validación (82). Para facilitar la lectura, se reproduce la ecuación i4 de la Introducción, aplicada a ese conjunto [25]:

$$\bar{Y} = \frac{1}{n}\sum_{i=1}^{n} Y_i \qquad \text{i4}$$

Donde $\bar{Y}$ es la media histórica de la variable objetivo, Y_i es el valor observado en el registro i del conjunto de ajuste y n = 464 es el número de registros de ese conjunto. Con esta expresión, la media histórica fue de 78.23 % para la recuperación de Au, de 7.575 g/t para la ley de Au en el concentrado y de 3.154 kg/t para el consumo específico de reactivos. Cada uno de esos valores se asignó como predicción a los 83 registros del conjunto de prueba, según la ecuación i5, que también se reproduce [24]:

$$\hat{Y}_i = \bar{Y} \qquad \text{i5}$$

Donde $\hat{Y}_i$ es el valor predicho para el registro i del conjunto de prueba. Como la predicción es la misma para todos los registros, el modelo base no utiliza ninguna de las 38 variables predictoras ni necesita hiperparámetros. Se eligió la media histórica, y no otro referente ingenuo como la persistencia del último valor observado, porque representa lo que la planta obtendría si estimara cada guardia solo con su promedio histórico, sin información del proceso; además, coincide con la estrategia de la media del DummyRegressor [60] y con la recomendación de comparar todo modelo con referentes simples [24].

El modelo base se evaluó en el mismo conjunto de prueba y con las mismas métricas aplicadas a Random Forest y XGBoost (R^2, MAE, RMSE y MAPE), de modo que las diferencias de desempeño fueran atribuibles a la capacidad de cada algoritmo para aprender de las variables del proceso y no a diferencias en los datos de evaluación [59]. Puesto que su predicción fue constante, el modelo base obtuvo, por construcción, un R^2 menor o igual que cero en el conjunto de prueba, ya que solo habría alcanzado el valor de cero si la media histórica hubiera coincidido exactamente con la media del periodo de prueba [45], [60]. Por ello, su función no fue competir en capacidad explicativa, sino servir como punto de comparación para cuantificar cuánto error eliminaban los modelos de inteligencia artificial. Dicha mejora se expresó como la reducción porcentual del MAE y del RMSE de cada modelo respecto al modelo base, calculada mediante la ecuación i15 [24].

La ecuación i15, que se reproduce a continuación, se aplicó por separado al MAE y al RMSE de cada algoritmo:

$$\mathrm{Red}_{\mathrm{E}} = \frac{\mathrm{E}_{\mathrm{base}} - \mathrm{E}_{\mathrm{modelo}}}{\mathrm{E}_{\mathrm{base}}} \times 100 \qquad \text{i15}$$

Donde $\mathrm{Red}_{\mathrm{E}}$ es la reducción porcentual del error (%), $\mathrm{E}_{\mathrm{base}}$ es el MAE o el RMSE del modelo base y $\mathrm{E}_{\mathrm{modelo}}$ es el error correspondiente de Random Forest o de XGBoost, ambos en las unidades de la variable objetivo (pp, g/t o kg/t) y calculados en el conjunto de prueba.

La expresión equivale al complemento de la medida relativa de error, definida como el cociente entre el error del modelo y el error del referente [24]. Así, un valor positivo de esta reducción indicó que el algoritmo redujo el error del modelo base, mientras que un valor nulo o negativo indicó que no superó a la media histórica y, por tanto, que no aprendió relaciones útiles entre las variables del proceso y la variable objetivo [24], [45]. Como criterio complementario a los de la Tabla 3, se consideró que un modelo de inteligencia artificial superó de forma práctica al modelo base cuando la reducción fue igual o superior a 15 % tanto en el MAE como en el RMSE de la variable objetivo correspondiente.

Por último, el R^2 del modelo base se interpretó con la ecuación i16, que resulta de sustituir la predicción constante de la ecuación i5 en la definición del R^2 de la ecuación i10:

$$\mathrm{R}^2_{\mathrm{base}} = -\left(\frac{\bar{\mathrm{y}}_{\mathrm{p}} - \bar{\mathrm{Y}}}{\sigma_{\mathrm{p}}}\right)^2 \qquad \text{i16}$$

Donde R^2_{base} es el coeficiente de determinación del modelo base, $\bar{y}_p$ es la media de la variable objetivo en el conjunto de prueba, $\bar{Y}$ es la media histórica de la ecuación i4 y σ_p es la desviación estándar poblacional de la variable en el conjunto de prueba. La expresión anticipa que el R^2 del modelo base será negativo siempre que la media del periodo de prueba se aparte de la media histórica, y que ese valor no revela un error de cálculo, sino un cambio de nivel del proceso entre periodos [45], [60]. En síntesis, el modelo base cumplió tres funciones: fijó la referencia de los criterios de MAE y RMSE de las hipótesis Hi1, Hi2 e Hi3 (Tabla 3), permitió calcular las reducciones del error de la ecuación i15 y mostró, mediante la ecuación i16, cuánto cambió el nivel de cada variable entre el periodo de ajuste y el de prueba.

Durante el entrenamiento de Random Forest se evaluaron hiperparámetros principales como n_estimators, max_depth, min_samples_leaf y max_features, debido a su influencia directa en la complejidad, estabilidad y capacidad de generalización del modelo. El hiperparámetro n_estimators definió el número de árboles que conformaban el bosque, influyendo en la estabilidad del ensamble y en el costo computacional. Por su parte, max_depth controló la profundidad máxima de cada árbol, ayudando a limitar modelos excesivamente complejos; min_samples_leaf estableció el número mínimo de observaciones requeridas en cada nodo terminal, contribuyendo a reducir el sobreajuste; y max_features definió la cantidad máxima de variables predictoras consideradas en cada partición del árbol. Este último parámetro resultó importante porque introducía aleatoriedad en la construcción de los árboles, favoreciendo la diversidad del ensamble y reduciendo la correlación entre ellos. La combinación de estos valores se eligió según el error obtenido en el subconjunto de validación [3], [40].

En el caso de XGBoost, se evaluaron hiperparámetros como learning_rate, max_depth, subsample y colsample_bytree, debido a su influencia directa en la velocidad de aprendizaje, la complejidad del modelo y su capacidad de generalización. El hiperparámetro learning_rate reguló la magnitud de la contribución de cada árbol nuevo al modelo, permitiendo un aprendizaje más gradual y reduciendo el riesgo de sobreajuste. Por su parte, max_depth controló la complejidad estructural de los árboles base, limitando la profundidad máxima de cada árbol; subsample definió la proporción de observaciones utilizadas en cada iteración de entrenamiento, incorporando aleatoriedad sobre las muestras; y colsample_bytree estableció la proporción de variables predictoras seleccionadas para la construcción de cada árbol. Al igual que max_features en Random Forest, este parámetro introduce aleatoriedad en la selección de variables y evita que el modelo dependa en exceso de unas pocas. Ajustarlos fue la principal defensa contra el sobreajuste, es decir, contra un modelo que memoriza el entrenamiento y falla con datos nuevos [7], [40].

Como los hiperparámetros no se aprenden de los datos, sino que se fijan antes del entrenamiento, su elección se hizo de forma sistemática: cada configuración candidata se entrenó con el subconjunto de entrenamiento y se comparó con las demás según su error en el de validación [24], [40]. Una vez seleccionada la configuración, cada modelo se reentrenó con los subconjuntos de entrenamiento y

validación, a fin de incorporar los registros más recientes, y se evaluó por única vez en el conjunto de prueba, cuyos registros no intervinieron en ninguna etapa del ajuste.

El desempeño predictivo de los modelos fue evaluado mediante métricas de regresión como R^2, MAE, RMSE y MAPE (ecuaciones i10, i11, i12 e i14). El coeficiente R^2 permitió analizar la proporción de variabilidad de la variable objetivo explicada por el modelo; el MAE permitió interpretar el error promedio en las mismas unidades de la variable analizada (pp en la recuperación, g/t en la ley y kg/t en el consumo); el RMSE penalizó con mayor intensidad los errores grandes; y el MAPE expresó el error en términos porcentuales, facilitando la interpretación operativa de los resultados. Estas métricas permitieron comparar de manera objetiva el rendimiento de Random Forest y XGBoost, entre sí y frente al modelo base, para cada variable objetivo: recuperación de Au, ley de Au en el concentrado y consumo específico de reactivos [7], [18]. De forma complementaria, el cociente entre el RMSE y el MAE se empleó como indicador de la distribución de los errores, dado que la pertinencia de cada métrica depende de dicha distribución [50]; su definición y sus valores teóricos de referencia se describen en la ecuación i20. Asimismo, como verificación complementaria y sin carácter decisorio, los errores se contrastaron con tolerancias operativas definidas por los autores: MAE ≤ 3 pp y RMSE ≤ 5 pp en la recuperación, y MAE ≤ 10 % y RMSE ≤ 15 % de la media observada en la ley y en el consumo. Para uniformar la presentación, el R^2, el MAE y el RMSE se informan con tres decimales; el MAPE, con dos; y las reducciones porcentuales del error, con uno; y los valores p, con cuatro. El R^2 es adimensional, el MAE y el RMSE se expresan en las unidades de cada variable y el MAPE y las reducciones, en porcentaje.

Para el contraste de la cuarta hipótesis específica, la significancia estadística de las diferencias entre los errores de predicción de Random Forest y XGBoost en el conjunto de prueba se evaluó mediante la prueba de Diebold-Mariano [52], [53] (ecuaciones i17 a i19), con un nivel de significancia de 0.05; las demás hipótesis se contrastaron comparando las métricas obtenidas con los umbrales de decisión establecidos ($R^2 \geq 0.75$; MAPE ≤ 10 %; y MAE y RMSE menores que los del modelo base), con las reducciones calculadas mediante la ecuación i15. El procesamiento se realizó en el lenguaje R, versión 4.6.1 [61], en el entorno RStudio [62], mediante una aplicación interactiva desarrollada con el paquete shiny [63], cuya interfaz se diseñó con bslib [64]. Los datos se importaron desde archivos Excel con readxl [65] y desde

archivos CSV con las funciones base de R [61]. Se entrenaron dos algoritmos: Random Forest, con el paquete randomForest [66], y XGBoost, con el paquete xgboost [67]. Como referencia se utilizó un modelo base que predice la media histórica de los datos de entrenamiento y validación, siguiendo la recomendación de comparar los modelos con referencias simples [24]. La importancia de las variables se obtuvo con las funciones de cada paquete: en Random Forest, el incremento del error cuadrático medio al permutar cada variable (%IncMSE) [66], [68], y en XGBoost, la ganancia relativa (Gain) [67]. Se programaron directamente en R las métricas de desempeño (R^2, MAE, RMSE y MAPE) [24], [69], la prueba de Diebold-Mariano con la corrección de Harvey, Leybourne y Newbold [70]–[74] para comparar Random Forest y XGBoost, y la verificación de los criterios de las hipótesis definidos en la Tabla 3. Los gráficos se elaboraron con ggplot2 [75]. Las tablas se mostraron en la aplicación con DT [76] y se incluyeron en el reporte PDF con gridExtra [77].

En una quinta fase se interpretaron los modelos finales mediante la importancia de variables (%IncMSE en Random Forest y ganancia en XGBoost), y se previó el uso de valores SHAP como complemento. El objetivo fue reconocer qué variables de composición, de dosificación, fisicoquímicas u operacionales influían más en la recuperación, en la ley del concentrado y en el consumo específico de reactivos, y contrastar ese orden con lo que se sabe de la metalurgia del proceso [7], [16], [46].

Finalmente, se realizó la comparación estadística entre los algoritmos y se planteó el uso del modelo seleccionado para explorar, en una etapa posterior, condiciones operativas que permitan mejorar la recuperación de Au, mantener o incrementar la ley de Au en el concentrado y reducir el consumo específico de reactivos. Las recomendaciones generadas por el modelo fueron interpretadas como soporte técnico para la toma de decisiones y no como mecanismos automáticos de control, debido a que toda sugerencia operativa debía ser revisada por especialistas metalúrgicos antes de su aplicación. Esta precaución fue necesaria porque los modelos basados en datos podían presentar limitaciones cuando enfrentaban condiciones operativas no representadas en el conjunto de entrenamiento, por lo que su uso debía integrarse con conocimiento experto del proceso [3], [16].

La investigación se llevó a cabo siguiendo los principios de confidencialidad, veracidad, responsabilidad técnica, integridad científica y uso responsable de datos

industriales, contemplados en el Código de Ética en Investigación de la Universidad César Vallejo. Debido a que se empleó información operativa real de una planta concentradora ubicada en la región Lima, los datos recolectados fueron tratados de forma confidencial y utilizados únicamente con fines académicos y científicos. No se reveló información sensible sobre la identidad de la empresa, la ubicación exacta de la operación, parámetros estratégicos de producción, costos internos, condiciones comerciales ni otros datos que pudieran comprometer la seguridad o competitividad de la organización. Esta reserva fue particularmente importante ya que el estudio utilizó datos industriales provenientes de sistemas SCADA/PLC y reportes metalúrgicos, que formaban parte del saber operativo de la planta. La digitalización de la minería facilita supervisar los procesos, pero también obliga a manejar con cuidado los datos que genera [6].

De igual manera, se aseguró que la información estuviera protegida y anonimizada. Los datos se codificaron y se suprimieron los identificadores directos de la empresa, del personal operativo, de turnos específicos o de información comercial sensible antes del análisis. Para no revelar datos que permitieran identificar estrategias internas u operaciones críticas de la planta, los resultados se mostraron de manera agregada, utilizando gráficos generales, métricas de desempeño e indicadores estadísticos. Con ello se protegió la confidencialidad de la empresa, condición indispensable para trabajar con datos industriales en aplicaciones de inteligencia artificial [55]. Además, los modelos predictivos debían contribuir a mejorar la supervisión del proceso sin reemplazar indebidamente el criterio técnico de los especialistas [16].

La investigación también atendió el principio de no maleficencia técnica, por lo que las recomendaciones generadas por el modelo predictivo no fueron aplicadas automáticamente sin revisión previa de los responsables de planta. Cualquier sugerencia relacionada con dosificación de reactivos, ajustes de pH, condiciones de operación o cambios en parámetros del circuito debía ser evaluada por personal técnico autorizado. Esta precaución fue necesaria porque los modelos de inteligencia artificial podían generar errores cuando se enfrentaban a condiciones que no estuvieron representadas en los datos históricos de entrenamiento. Los modelos interpretables ayudaron a comprender la influencia de las variables y redujeron el riesgo de adoptar decisiones basadas en sistemas opacos [7]. Además, la flotación

es un proceso sumamente complejo, por lo que su optimización mediante aprendizaje automático debía ir acompañada de conocimiento metalúrgico y criterio operativo [3].

Con respecto a la integridad académica, se reconoció cada autoría de las fuentes empleadas y las referencias se citaron según la norma IEEE. La bibliografía se utilizó para sustentar el marco teórico, la metodología y la discusión de los resultados, de modo que se evitaron el plagio, la tergiversación de datos y la presentación de hallazgos no verificables. Las bases de datos se procesaron manteniendo un registro de las modificaciones realizadas, para que los procedimientos pudieran ser revisados y, si fuera necesario, reproducidos. Esta práctica fue consistente con el carácter científico de la investigación y con la necesidad de asegurar resultados fidedignos en investigaciones aplicadas de inteligencia artificial. Para valorar la validez de modelos predictivos en flotación, resultó esencial mostrar con claridad los datos, las métricas y la metodología empleados [18], [20]. Asimismo, el informe fue sometido al software Turnitin para verificar su originalidad (Anexo 7). Al no involucrar personas como unidad de análisis, el estudio no requirió consentimiento ni asentimiento informado; en su lugar, se contó con la solicitud y la autorización de la empresa para el uso de su información, con el compromiso de mantener en reserva su identidad (Anexos 4 y 5), documentos que no se publicarán en el Repositorio Institucional. El uso de herramientas de inteligencia artificial como apoyo al proceso de investigación se declaró conforme a la normativa interna de originalidad de la universidad.

Por último, la investigación se comprometió con la sostenibilidad y la responsabilidad social porque optimizar la flotación de relaves podía ayudar a recuperar metales valiosos, reducir las pérdidas metalúrgicas, disminuir el uso innecesario de reactivos y mejorar la administración de pasivos ambientales. Al fomentar el uso de tecnologías que apuntaban a una minería más eficiente y responsable, esta perspectiva se relacionó con el Objetivo de Desarrollo Sostenible 9, vinculado con la innovación, la infraestructura y la industria. Según Kursunoglu [2], el reprocesamiento de relaves permite recuperar materiales críticos y disminuir los efectos ambientales de los depósitos mineros. Por su parte, Chávez Quispe [8] señaló que, en el Perú, la adopción de tecnologías innovadoras en el sector minero podía optimizar las operaciones y la toma de decisiones basada en datos, lo que conducía hacia una minería más inteligente y sostenible.

III. Resultados

En este capítulo se presentan los resultados obtenidos al aplicar el procedimiento descrito en la metodología a los 547 registros válidos del circuito de flotación de relaves de lixiviación, generados entre enero y setiembre de 2026. Primero se describen los datos y su partición temporal; luego, el desempeño de Random Forest y XGBoost frente al modelo base en cada variable objetivo y la importancia de las variables predictoras; y, por último, el contraste de las hipótesis. Salvo que se indique otra cosa, las métricas corresponden al conjunto de prueba, cuyos registros no intervinieron en la elección de los hiperparámetros ni en el entrenamiento de los modelos finales.

La partición temporal por proporciones asignó los 382 registros más antiguos al entrenamiento (69.8 %), los 82 siguientes a la validación (15.0 %) y los 83 más recientes a la prueba (15.2 %); por lo tanto, el conjunto con el que se calculó el modelo base y se reentrenaron los modelos finales reunió 464 registros. Las tres variables objetivo no tuvieron valores faltantes. Entre los predictores, solo el cianuro libre residual registró datos ausentes, 31 en total (5.7 % de la base), que se trataron en la etapa de preprocesamiento; las 37 variables restantes estuvieron completas. La Tabla 4 resume los estadísticos descriptivos de las variables objetivo en cada subconjunto y la Figura 1 muestra su distribución.

Tabla 4

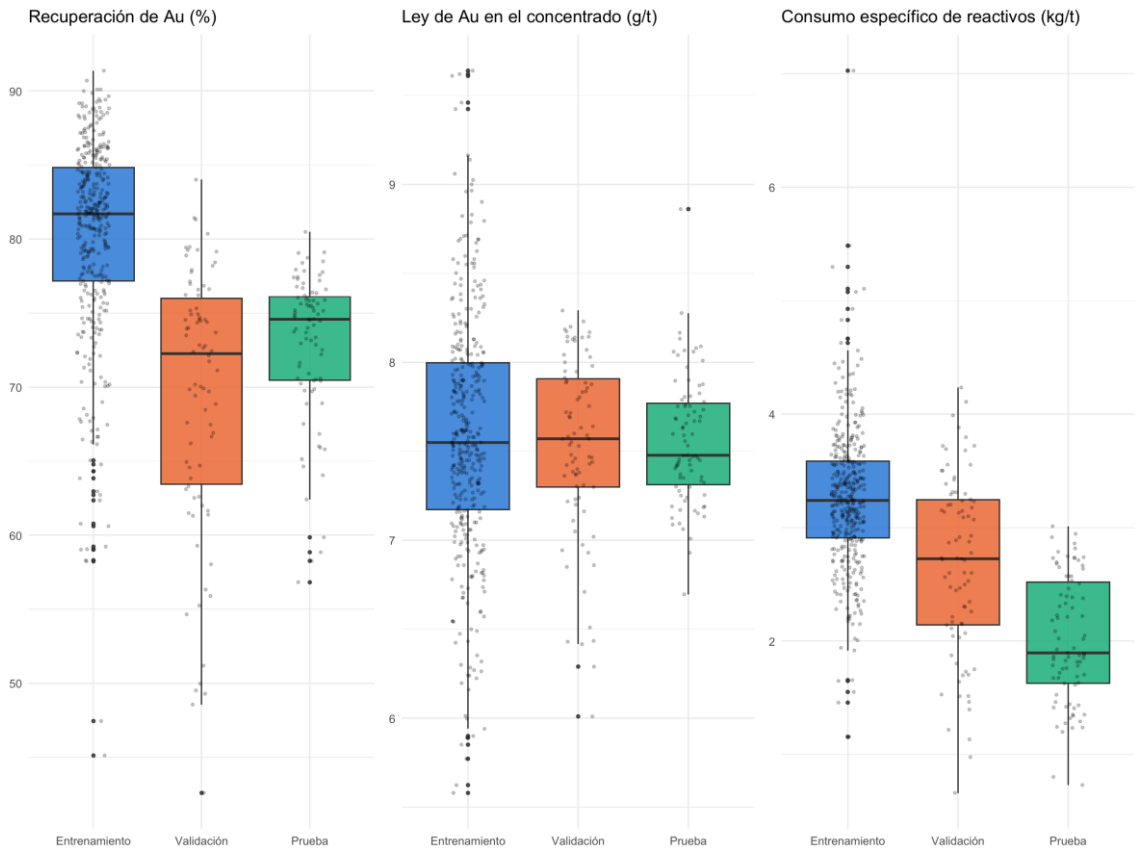
Estadísticos descriptivos de las variables objetivo por subconjunto

Variable	Subconjunto	n	Media	DE	Mín.	Q1	Mediana	Q3	Máx.	CV (%)
Recuperación de Au (%)	Entrenamiento	382	80.139	6.915	45.121	77.166	81.703	84.825	91.372	8.6
	Validación	82	69.340	9.028	42.593	63.438	72.262	75.990	84.012	13.0
	Prueba	83	72.875	5.082	56.821	70.476	74.580	76.110	80.484	7.0
Ley de Au en el concentrado (g/t)	Entrenamiento	382	7.584	0.691	5.580	7.171	7.550	7.997	9.639	9.1
	Validación	82	7.531	0.508	6.010	7.300	7.571	7.908	8.292	6.7
	Prueba	83	7.561	0.356	6.696	7.313	7.477	7.770	8.861	4.7
Consumo específico de reactivos (kg/t)	Entrenamiento	382	3.258	0.632	1.157	2.911	3.239	3.586	7.027	19.4
	Validación	82	2.672	0.793	0.662	2.143	2.727	3.245	4.235	29.7
	Prueba	83	2.015	0.550	0.732	1.630	1.895	2.519	3.013	27.3

Nota. Elaboración propia a partir de los registros de la planta [11]. DE: desviación estándar; Q1 y Q3: primer y tercer cuartil; CV: coeficiente de variación. Los subconjuntos respetan el orden cronológico de los registros y ninguna de las tres variables presentó valores faltantes.

Figura 1

Distribución de las variables objetivo por subconjunto



Nota. Cada punto representa un registro de guardia; la caja abarca del primer al tercer cuartil y la línea central indica la mediana. Elaboración propia a partir de los registros de la planta [11].

Los tres subconjuntos no fueron equivalentes, y esa diferencia resultó decisiva para interpretar el resto de los resultados. La recuperación de Au promedió 80.14 % en entrenamiento, 69.34 % en validación y 72.88 % en prueba, es decir, el periodo más reciente operó en promedio 7.3 puntos porcentuales (pp) por debajo del periodo de entrenamiento. La validación fue el tramo más irregular, con una desviación estándar de 9.03 pp y un mínimo de 42.59 %, mientras que la prueba presentó la menor dispersión, con un coeficiente de variación de 7.0 %. La ley de Au en el concentrado, en cambio, se mantuvo estable entre subconjuntos, con medias de 7.58 g/t, 7.53 g/t y 7.56 g/t, aunque su dispersión disminuyó de forma progresiva: la desviación estándar bajó de 0.691 g/t a 0.356 g/t. El consumo específico de reactivos fue la variable con el desplazamiento más marcado. Su media descendió de 3.258 kg/t en entrenamiento a 2.672 kg/t en validación y a 2.015 kg/t en prueba, una caída de 38.2 %, con coeficientes de variación de 19.4 % a 29.7 %. En la Figura 1 se aprecia

que la mediana del consumo en prueba (1.895 kg/t) quedó incluso por debajo del primer cuartil del entrenamiento (2.911 kg/t).

Como parte del análisis exploratorio, la Tabla 5 presenta la media y la desviación estándar de las 38 variables predictoras en cada subconjunto, agrupadas en los cinco bloques definidos en la metodología, junto con el número total de datos faltantes. En la columna «NA total», el valor 0 significa que la variable no tuvo datos faltantes en ninguno de los tres subconjuntos, y así ocurrió en 37 de las 38 variables. La única excepción fue el cianuro libre residual, con 31 registros sin dato (5.7 % de la base), que se trataron en la etapa de preprocesamiento. La base con la que se entrenaron y evaluaron los modelos estuvo, por lo tanto, prácticamente completa, y no fue necesario descartar ninguna variable por falta de información.

Tabla 5

Estadísticos descriptivos de las variables predictoras por subconjunto

Variable predictora	Entrenamiento (n = 382)		Validación (n = 82)		Prueba (n = 83)		NA total
	Media	DE	Media	DE	Media	DE	
Variables mineralógicas y de composición de la alimentación							
Ley de Cu ccPy	0.889	0.218	0.585	0.261	0.669	0.165	0
Ley de Pb ccPy	3.124	0.678	2.154	0.795	2.471	0.564	0
Ley de Zn ccPy	4.483	0.893	3.138	1.096	3.562	0.610	0
Ley de Fe ccPy	33.007	4.687	32.647	3.525	32.867	2.494	0
Ley de As ccPy	6.662	2.089	6.581	1.655	6.655	1.151	0
Ley de Ag ccPy	89.720	12.611	89.886	17.241	89.938	28.099	0
%H_2O ccPy (%)	11.758	2.446	11.614	1.821	11.732	1.239	0
200M_ccPy (%)	99.424	0.285	99.428	0.284	99.438	0.226	0
Ley de Au de cabeza (g/t)	1.850	0.451	1.809	0.347	1.844	0.235	0
Porcentaje de sólidos (%)	48.379	3.385	43.350	4.140	44.770	2.546	0
% Insolubles (%)	14.064	3.830	14.394	3.561	13.970	2.681	0
Densidad de pulpa (g/L)	1559.168	66.646	1531.344	55.635	1582.169	32.995	0
Granulometría −200 mallas (%)	89.041	6.210	86.038	5.184	88.757	3.914	0
K30 (µm)	1.803	0.053	1.803	0.053	1.803	0.037	0
K50 (µm)	10.813	0.315	10.827	0.335	10.815	0.260	0
K80 (µm)	38.476	8.491	37.774	6.262	38.088	4.784	0
Variables de dosificación de reactivos							
Sulfato de cobre (kg/t)	1.819	0.405	1.196	0.495	1.368	0.308	0
PAX + SIPX (Z-6 + Z-11) (kg/t)	0.360	0.214	0.291	0.103	0.211	0.056	0
MIBC (kg/t)	0.063	0.040	0.043	0.018	0.046	0.017	0
Metabisulfito de sodio (kg/t)	0.974	0.403	1.101	0.710	0.347	0.431	0
Antiespumante (kg/t)	0.042	0.108	0.041	0.100	0.042	0.090	0
Variables fisicoquímicas							
pH inicial	9.001	0.364	8.825	0.193	8.859	0.171	0
pH final	8.612	0.404	8.337	0.235	8.178	0.285	0
Potencial redox (mV)	−3.352	62.757	13.707	46.277	30.982	48.811	0
O_2 disuelto (mg/L)	7.076	0.564	7.129	0.581	7.074	0.381	0
FCN_Inic (ppm)	70.527	39.677	60.213	40.925	54.518	30.027	0
FCN_Fin (ppm)	30.339	18.933	15.238	5.904	14.307	4.423	0
CN libre residual (mg/L)	12.641	1.695	12.393	1.662	12.602	1.693	31
Variables operacionales e hidráulicas							
Masa de alimentación (t)	471.993	177.721	613.224	150.564	695.150	121.886	0
Caudal de pulpa (m^3/h)	46.463	17.072	63.039	14.527	66.393	10.584	0
Q de agua de lavado, si aplica (m^3/h)	0.918	0.203	0.925	0.205	0.933	0.144	0

Variable predictora	Entrenamiento (n = 382)		Validación (n = 82)		Prueba (n = 83)		NA total
	Media	DE	Media	DE	Media	DE	
Nivel de pulpa (%)	62.381	1.865	62.444	1.690	62.414	1.203	0
Tiempo de flotación (min)	149.681	81.008	92.257	25.577	75.933	8.372	0
Variables de aireación y formación de espuma							
Caudal de aire (Nm³/h)	99.338	4.238	99.997	4.607	99.461	3.953	0
Presión de aire (kPa)	35.678	2.663	35.976	2.563	35.846	1.979	0
Presión manifold (kPa)	50.634	9.007	50.768	10.361	50.910	8.151	0
Apertura de aire (%)	41.671	2.601	41.756	2.925	41.350	1.975	0
Altura de espuma (mm)	384.136	26.617	380.488	27.818	384.366	19.701	0

Nota. Elaboración propia a partir de los registros de la planta [11]. DE: desviación estándar. NA total: número de datos faltantes de la variable en los 547 registros; el valor 0 indica que la variable no tuvo datos faltantes en ninguno de los tres subconjuntos. Las leyes del bloque ccPy se presentan sin unidad, tal como figuran en el registro de planta.

La Tabla 5 muestra, además, que las variables predictoras cambiaron a lo largo del periodo de estudio. La masa de alimentación promedio aumentó de 472.0 t en entrenamiento a 613.2 t en validación y a 695.2 t en prueba, y el caudal de pulpa pasó de 46.5 m³/h a 66.4 m³/h entre el primer y el último subconjunto. En sentido contrario, el tiempo de flotación se redujo de 149.7 min a 75.9 min, y su desviación estándar, de 81.0 min a 8.4 min. En la dosificación, el metabisulfito de sodio bajó de 0.974 kg/t a 0.347 kg/t, el PAX + SIPX de 0.360 kg/t a 0.211 kg/t y el sulfato de cobre de 1.819 kg/t a 1.368 kg/t. El potencial redox se desplazó de −3.4 mV a 31.0 mV, y el cianuro libre final (FCN_Fin), de 30.3 ppm a 14.3 ppm. La ley de Au de cabeza (1.85 g/t, 1.81 g/t y 1.84 g/t), los parámetros granulométricos K30, K50 y K80 y las variables de aireación y de espuma, por su parte, se mantuvieron prácticamente constantes. En conjunto, el periodo de prueba correspondió a un régimen de mayor tonelaje, menor tiempo de residencia y menor dosificación de reactivos que el que predominó en el entrenamiento, de modo que la evaluación en ese periodo exigió a los modelos generalizar hacia condiciones de operación nuevas.

La dispersión de los predictores aporta una segunda lectura. En el entrenamiento, los predictores con mayor dispersión fueron los de dosificación y los de química del cianuro: la desviación estándar del antiespumante fue 2.6 veces su media, y el MIBC, el PAX + SIPX, el cianuro libre inicial y final y el tiempo de flotación registraron coeficientes de variación de entre 54 % y 64 %. En el otro extremo, los parámetros granulométricos K30 y K50, el porcentaje pasante la malla 200 del bloque ccPy, el nivel de pulpa, el caudal de aire, la densidad de pulpa y el pH variaron menos de 5 % respecto de su media. Una variable que casi no cambia aporta poca información a un modelo, aunque su efecto físico sea relevante, y esto anticipa lo que se observa más

adelante en las medidas de importancia, donde ninguna de esas variables figuró entre las cinco primeras.

Por último, la dispersión disminuyó del entrenamiento a la prueba en 36 de las 38 variables, en parte porque el periodo de prueba es más corto. La desviación estándar del tiempo de flotación bajó de 81.0 min a 8.4 min, la del cianuro libre final de 18.9 ppm a 4.4 ppm, la de la masa de alimentación de 177.7 t a 121.9 t y la del caudal de pulpa de 17.1 m³/h a 10.6 m³/h, lo que describe una operación más regular en el tramo final. La ley de Ag del bloque ccPy siguió el camino inverso: su desviación estándar pasó de 12.6 en entrenamiento a 28.1 en prueba, mientras su media se mantuvo entre 89.7 y 89.9; el metabisulfito de sodio, por su parte, mantuvo una dispersión parecida (0.403 kg/t y 0.431 kg/t). En conjunto, el análisis exploratorio confirma que el periodo de prueba no repitió las condiciones del entrenamiento, sino que combinó un cambio de nivel en varias variables de operación y dosificación con una menor dispersión, rasgo que debe tenerse presente al interpretar las métricas de los modelos.

La Tabla 6 presenta el desempeño de los tres modelos en el conjunto de prueba. Con el mejor algoritmo de cada variable, el R^2 fue de 0.973 en la recuperación de Au (Random Forest), de 0.985 en la ley de Au en el concentrado (Random Forest) y de 0.897 en el consumo específico de reactivos (XGBoost), con valores de MAPE de 0.94 %, 0.46 % y 8.92 %, respectivamente. En los tres casos, el MAE y el RMSE se redujeron en más de 85 % respecto al modelo base, muy por encima del criterio complementario de mejora práctica de 15 %. De los seis modelos de aprendizaje automático evaluados, cinco cumplieron a la vez los cuatro criterios de decisión; la excepción fue Random Forest en el consumo específico de reactivos, cuyo R^2 de 0.740 quedó por debajo del umbral de 0.75 y cuyo MAPE de 14.70 % superó el límite de 10 %.

Tabla 6

Desempeño predictivo de los modelos en el conjunto de prueba

Variable objetivo	Modelo	R^2	MAE	RMSE	MAPE (%)	Red. MAE (%)	Red. RMSE (%)	Cumple
Recuperación de Au (%)	Modelo base	−1.124	5.473	7.362	8.07	—	—	—
	Random Forest	**0.973**	**0.686**	**0.836**	**0.94**	**87.5**	**88.6**	**Sí**
	XGBoost	0.960	0.838	1.005	1.15	84.7	86.4	Sí
Ley de Au en el concentrado (g/t)	Modelo base	−0.002	0.285	0.354	3.77	—	—	—
	Random Forest	**0.985**	**0.035**	**0.044**	**0.46**	**87.9**	**87.6**	**Sí**
	XGBoost	0.979	0.040	0.051	0.53	86.0	85.5	Sí
Consumo específico de reactivos (kg/t)	Modelo base	−4.350	1.140	1.264	70.95	—	—	—
	Random Forest	0.740	0.226	0.279	14.70	80.1	78.0	No
	XGBoost	**0.897**	**0.142**	**0.175**	**8.92**	**87.6**	**86.1**	**Sí**

Nota. Elaboración propia. En negrita, el mejor modelo de cada variable. Red. MAE y Red. RMSE: reducción porcentual respecto al modelo base, calculada con la ecuación i15. Cumple: $R^2 \geq 0.75$, MAPE ≤ 10 % y MAE y RMSE menores que los del modelo base. El MAE y el RMSE se expresan en las unidades de cada variable (pp, g/t o kg/t); n = 83 registros.

El modelo base obtuvo un R^2 negativo en la recuperación (−1.124) y en el consumo (−4.350), y prácticamente nulo en la ley (−0.002). Lejos de ser un error de cálculo, este resultado es lo que cabe esperar cuando se predice con la media histórica un periodo cuya media es distinta. Según la ecuación i16, que resulta de combinar la predicción constante de la ecuación i5 con la definición del R^2 de la ecuación i10, el R^2 del modelo base depende únicamente de la distancia entre la media histórica y la media del periodo evaluado, medida en desviaciones estándar de ese periodo.

En la recuperación, la media histórica fue de 78.23 % y la de prueba de 72.88 %; la diferencia de 5.36 pp, dividida entre la desviación estándar poblacional del periodo de prueba (5.05 pp) y elevada al cuadrado, reproduce el R^2 de −1.124. En el consumo, la media histórica de 3.154 kg/t superó en 1.139 kg/t a la de prueba, una distancia equivalente a más de dos desviaciones estándar, lo que explica, salvo diferencias de redondeo, el R^2 de −4.350 y el MAPE de 70.95 %. En la ley, ambas medias casi coincidieron (7.575 g/t y 7.561 g/t), y el R^2 del modelo base resultó cercano a cero. Debe notarse que el R^2 de los algoritmos se calcula con la misma referencia, la media del periodo de prueba, de manera que para superar el umbral de 0.75 Random Forest y XGBoost tuvieron que seguir tanto el cambio de nivel del proceso como su variación entre guardias, algo que la media histórica no puede hacer.

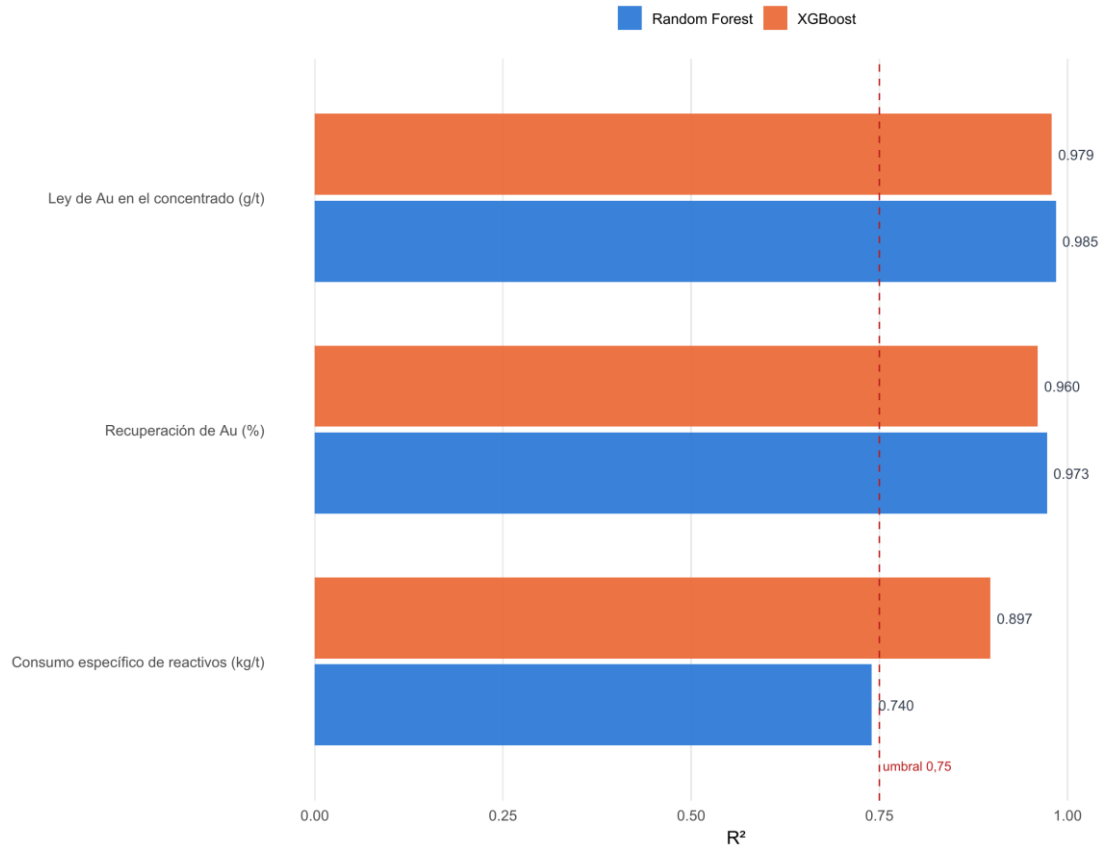
Conviene advertir, además, que el modelo base cumplió por sí solo el umbral de MAPE en la recuperación (8.07 %) y en la ley (3.77 %), porque ambas variables tienen

valores altos y una variación relativa moderada. En esas dos variables, el MAPE no permitió distinguir un modelo útil de uno ingenuo; la diferencia la marcaron el R^2 y la reducción del MAE y del RMSE, que fue de al menos 84.7 % en los cuatro modelos. En el consumo, por el contrario, el MAPE sí discriminó: el modelo base alcanzó 70.95 % y Random Forest 14.70 %, ambos por encima del límite, mientras que XGBoost lo redujo a 8.92 %.

La Figura 2 compara el R^2 de ambos algoritmos con el umbral de 0.75. En la recuperación y en la ley, las barras de Random Forest y XGBoost quedaron muy próximas entre sí y por encima de 0.95, con una ventaja de Random Forest de 0.013 y 0.006, respectivamente. En el consumo, la distancia fue de 0.157 a favor de XGBoost, y Random Forest quedó 0.010 por debajo del umbral.

Figura 2

Comparación del R^2 de Random Forest y XGBoost en el conjunto de prueba



Nota. La línea discontinua roja señala el umbral $R^2 = 0.75$ fijado en las hipótesis específicas. Elaboración propia.

Como verificación complementaria, se calculó el cociente RMSE/MAE (ecuación i20) de cada modelo en el conjunto de prueba. En los seis modelos de aprendizaje automático, este cociente se ubicó entre 1.20 y 1.29: 1.22 y 1.20 en la recuperación,

1.27 y 1.29 en la ley, y 1.23 y 1.24 en el consumo, para Random Forest y XGBoost, respectivamente. Son valores muy cercanos a 1.25, el cociente teórico de errores con distribución normal [50], lo que indica que el error total no se concentró en unas pocas predicciones de gran magnitud, sino que se repartió de manera bastante uniforme entre los registros. Las tolerancias operativas definidas por los autores se cumplieron en cinco de los seis casos. En la recuperación, el MAE no pasó de 0.84 pp ni el RMSE de 1.01 pp, muy por debajo de los límites de 3 pp y 5 pp; en la ley, ambos errores fueron inferiores al 0.70 % de la media observada; y en el consumo, XGBoost registró un MAE equivalente al 7.03 % y un RMSE equivalente al 8.69 % de la media, mientras que el MAE de Random Forest, igual al 11.24 % de la media, excedió el límite de 10 %.

En relación con el primer objetivo específico, la Tabla 7 detalla el desempeño de los modelos de recuperación de Au en los tres subconjuntos. Las métricas son las mismas de la Tabla 6, calculadas ahora en entrenamiento, validación y prueba.

Tabla 7

Desempeño de los modelos en la predicción de la recuperación de Au (%) por subconjunto

Subconjunto	n	Modelo	R^2	MAE (pp)	RMSE (pp)	MAPE (%)
Entrenamiento	382	Random Forest	0.995	0.348	0.491	0.45
		XGBoost	0.984	0.701	0.880	0.86
Validación	82	Random Forest	0.947	1.161	2.063	1.98
		XGBoost	0.968	1.095	1.608	1.75
Prueba	83	Modelo base	−1.124	5.473	7.362	8.07
		Random Forest	**0.973**	**0.686**	**0.836**	**0.94**
		XGBoost	0.960	0.838	1.005	1.15

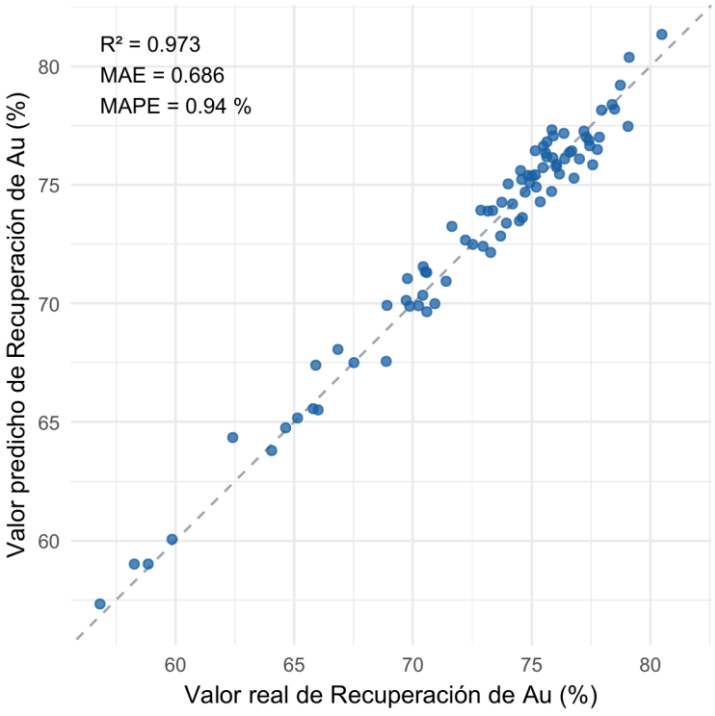
Nota. Elaboración propia. En negrita, el modelo seleccionado. En entrenamiento y validación se reportan los modelos ajustados con el subconjunto de entrenamiento; en prueba, los modelos reentrenados con entrenamiento y validación. pp: puntos porcentuales. La comparación con la prueba de Diebold-Mariano se presenta en la Tabla 11.

Random Forest obtuvo en prueba un R^2 de 0.973, un MAE de 0.686 pp y un RMSE de 0.836 pp, casi la novena parte del RMSE del modelo base (7.362 pp). XGBoost alcanzó un R^2 de 0.960, con un MAE de 0.838 pp y un RMSE de 1.005 pp. Frente al modelo base, cuyo MAE fue de 5.473 pp, ambos algoritmos redujeron el error absoluto en 87.5 % y 84.7 %, respectivamente. Llevado a la operación, esto significa que, en una guardia con una recuperación real de 75 %, la estimación de Random Forest se aparta en promedio menos de 0.7 pp de ese valor, mientras que la media histórica se alejaría más de 5 pp.

La comparación entre subconjuntos deja dos observaciones. La primera es que el ajuste en entrenamiento fue mayor que el de prueba (R^2 de 0.995 en Random Forest y de 0.984 en XGBoost), pero la caída posterior fue moderada, de alrededor de 0.02 en el R^2 en ambos casos, de modo que no se evidenció un sobreajuste que comprometiera la generalización. La segunda es que en validación XGBoost superó a Random Forest (R^2 de 0.968 frente a 0.947 y RMSE de 1.608 pp frente a 2.063 pp), mientras que en prueba el orden se invirtió. El subconjunto de validación contuvo las recuperaciones más bajas de toda la serie, con un mínimo de 42.59 % y un coeficiente de variación de 13.0 %, y en ese tramo el cociente RMSE/MAE de Random Forest subió a 1.78, señal de que unas pocas guardias atípicas concentraron buena parte de su error. Este cambio de posición muestra que la ventaja de un algoritmo puede depender del periodo evaluado; por esa razón, la comparación formal entre ambos se basó en la prueba de Diebold-Mariano aplicada al conjunto de prueba.

Figura 3

Valores observados frente a valores predichos de la recuperación de Au por Random Forest en el conjunto de prueba



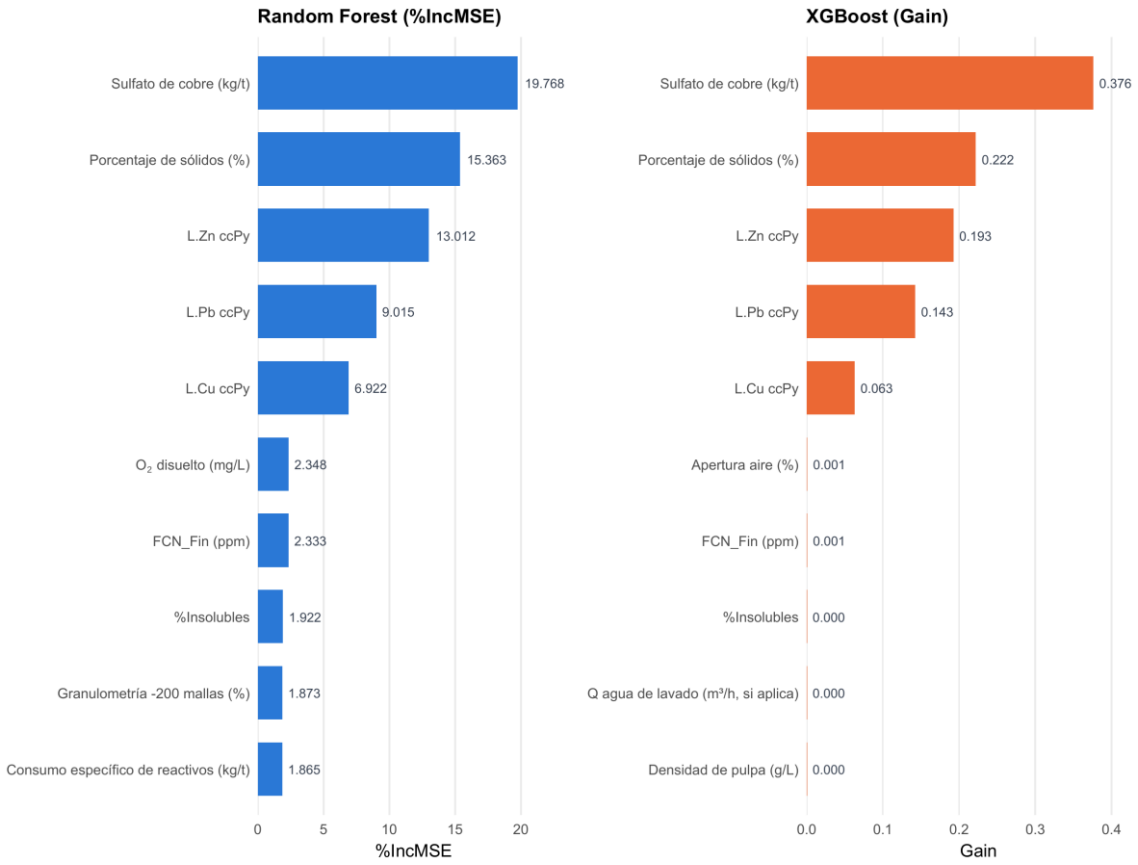
Nota. La línea discontinua representa la igualdad entre el valor observado y el valor predicho; n = 83 registros del conjunto de prueba. Elaboración propia.

La Figura 3 muestra que las predicciones de Random Forest se alinearon con la diagonal de igualdad en todo el rango observado en prueba, desde 56.8 % hasta

80.5 %. Las recuperaciones inferiores a 65 %, poco frecuentes en ese periodo, también se estimaron con desviaciones pequeñas; las mayores, de alrededor de 2 pp, aparecieron en registros aislados entre 62 % y 70 %, sin que se observe un patrón sistemático de sobrestimación o de subestimación en los extremos.

Figura 4

Importancia de las variables predictoras en los modelos de recuperación de Au



Nota. %IncMSE: incremento porcentual del error cuadrático medio al permutar la variable en Random Forest; Gain: ganancia relativa en XGBoost. Se muestran las diez variables de mayor importancia en cada modelo. Elaboración propia.

En cuanto a la importancia de las variables (Figura 4), ambos algoritmos coincidieron en las cinco primeras posiciones y en su orden: sulfato de cobre, porcentaje de sólidos y leyes de Zn, Pb y Cu del bloque ccPy. En XGBoost, esas cinco variables concentraron el 99.7 % de la ganancia total, por lo que el resto de predictores tuvo una participación marginal. En Random Forest la importancia se repartió algo más: el oxígeno disuelto, el cianuro libre final, el porcentaje de insolubles, la granulometría y el consumo específico de reactivos aparecieron con valores de %IncMSE de entre 1.9 y 2.3, muy lejos del sulfato de cobre (19.8). La preponderancia del sulfato de cobre,

activador de los sulfuros, concuerda con el papel que cumple la activación en la flotabilidad de la pirita aurífera [12], [13].

Respecto al segundo objetivo específico, la Tabla 8 presenta los resultados de la ley de Au en el concentrado. Random Forest alcanzó en prueba un R^2 de 0.985, un MAE de 0.035 g/t y un RMSE de 0.044 g/t, con un MAPE de 0.46 %; ese RMSE equivale a la octava parte del obtenido por el modelo base (0.354 g/t). XGBoost obtuvo un R^2 de 0.979, un MAE de 0.040 g/t y un MAPE de 0.53 %. Ambos redujeron el error del modelo base en más de 85 %. En términos operativos, la ley estimada por Random Forest se apartó en promedio 0.035 g/t del valor informado por el laboratorio, frente a 0.285 g/t de la media histórica.

Tabla 8

Desempeño de los modelos en la predicción de la ley de Au en el concentrado (g/t) por subconjunto

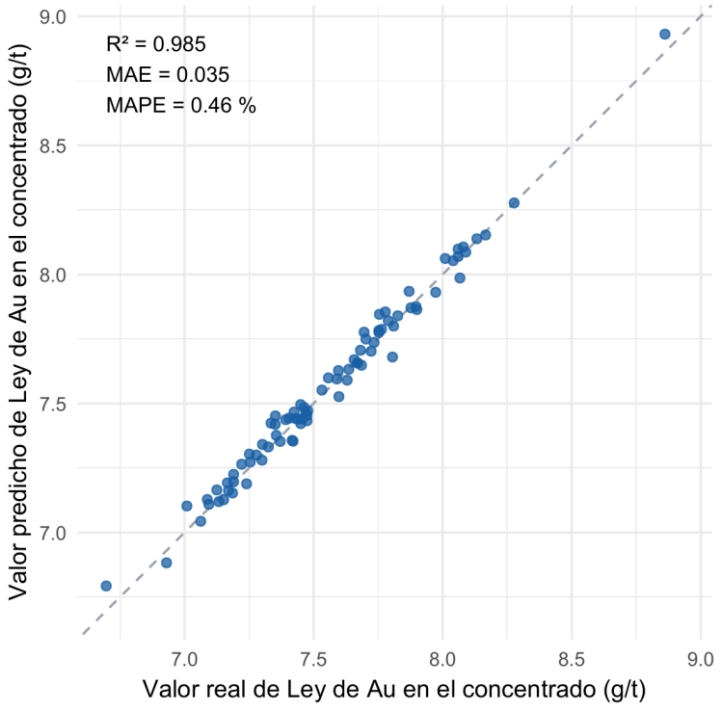
Subconjunto	n	Modelo	R^2	MAE (g/t)	RMSE (g/t)	MAPE (%)
Entrenamiento	382	Random Forest	0.999	0.014	0.019	0.19
		XGBoost	1.000	0.001	0.002	0.02
Validación	82	Random Forest	0.992	0.035	0.045	0.47
		XGBoost	0.988	0.045	0.055	0.61
Prueba	83	Modelo base	−0.002	0.285	0.354	3.77
		Random Forest	**0.985**	**0.035**	**0.044**	**0.46**
		XGBoost	0.979	0.040	0.051	0.53

Nota. Elaboración propia. En negrita, el modelo seleccionado. Criterios de entrenamiento, validación y prueba como en la Tabla 7.

El ajuste en entrenamiento fue casi perfecto en los dos algoritmos, sobre todo en XGBoost, que llegó a un R^2 de 1.000 y a un MAE de 0.001 g/t. Un ajuste de esa magnitud indica que el modelo prácticamente memorizó los registros de entrenamiento; aun así, el descenso hasta 0.979 en prueba fue pequeño, lo que significa que la relación aprendida se sostuvo con datos nuevos. A diferencia de lo ocurrido con la recuperación, Random Forest superó a XGBoost tanto en validación (R^2 de 0.992 frente a 0.988) como en prueba, de modo que el orden de los algoritmos fue estable en esta variable. La Figura 5 confirma la estrecha correspondencia entre la ley observada y la predicha: los puntos se agrupan sobre la diagonal entre 6.7 g/t y 8.3 g/t, y el único registro de prueba con una ley superior a 8.5 g/t (8.86 g/t) se estimó con una diferencia menor de 0.1 g/t.

Figura 5

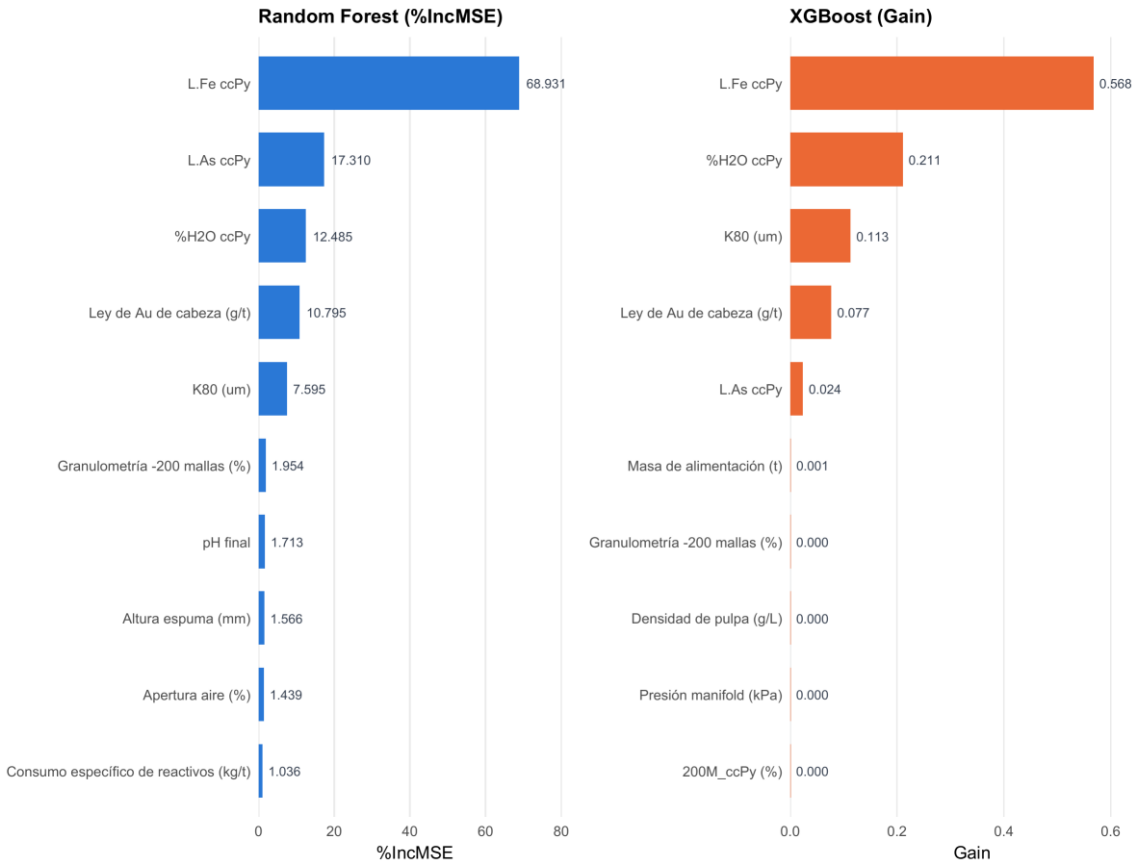
Valores observados frente a valores predichos de la ley de Au en el concentrado por Random Forest en el conjunto de prueba



Nota. La línea discontinua representa la igualdad entre el valor observado y el valor predicho; n = 83 registros del conjunto de prueba. Elaboración propia.

Figura 6

Importancia de las variables predictoras en los modelos de ley de Au en el concentrado



Nota. %IncMSE en Random Forest y Gain en XGBoost; se muestran las diez variables de mayor importancia en cada modelo. Elaboración propia.

La importancia de las variables en la ley (Figura 6) siguió un patrón distinto al de la recuperación. La ley de Fe del bloque ccPy fue el predictor dominante en ambos algoritmos, con un %IncMSE de 68.9 en Random Forest y el 56.8 % de la ganancia de XGBoost. Le siguieron la ley de As y la humedad del mismo bloque, la ley de Au de cabeza y el parámetro granulométrico K80, y estas cinco variables reunieron el 99.3 % de la ganancia de XGBoost. Las variables de dosificación, las fisicoquímicas y las de aireación tuvieron, en cambio, una participación mínima; el consumo específico de reactivos, por ejemplo, ocupó el décimo lugar en Random Forest, con un %IncMSE de 1.04. Según estos resultados, la ley del concentrado se explicó sobre todo por la composición del material asociado a la pirita y por la ley de cabeza, más que por las condiciones de operación de la guardia.

En relación con el tercer objetivo específico, la Tabla 9 resume el desempeño en la predicción del consumo específico de reactivos, la variable más difícil de las tres.

XGBoost obtuvo en prueba un R^2 de 0.897, un MAE de 0.142 kg/t, un RMSE de 0.175 kg/t y un MAPE de 8.92 %, con lo que cumplió todos los criterios. Random Forest alcanzó un R^2 de 0.740 y un MAPE de 14.70 % y no cumplió dos de ellos, aunque también redujo los errores del modelo base en 80.1 % (MAE) y 78.0 % (RMSE).

Tabla 9

Desempeño de los modelos en la predicción del consumo específico de reactivos (kg/t) por subconjunto

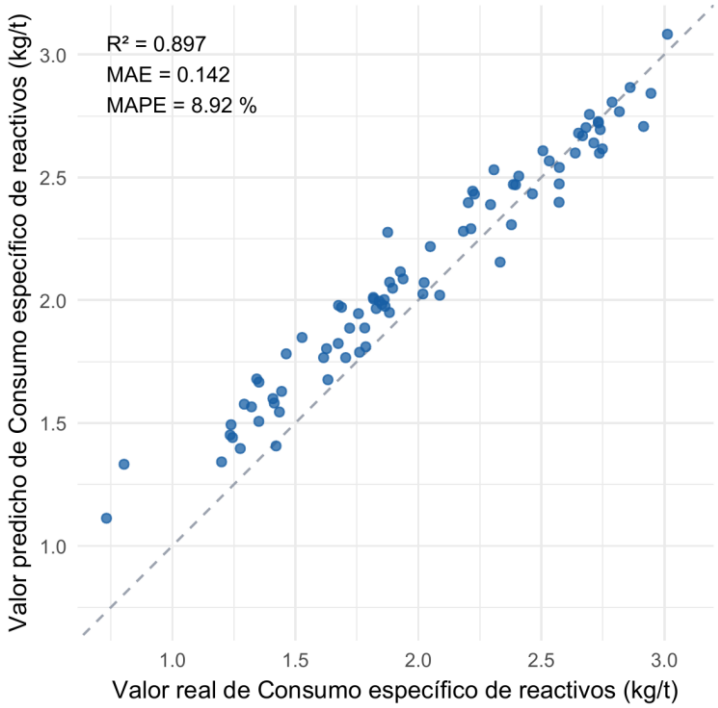
Subconjunto	n	Modelo	R^2	MAE (kg/t)	RMSE (kg/t)	MAPE (%)
Entrenamiento	382	Random Forest	0.957	0.071	0.130	2.29
		XGBoost	0.983	0.059	0.083	1.84
Validación	82	Random Forest	0.710	0.310	0.425	17.42
		XGBoost	0.816	0.237	0.338	13.60
Prueba	83	Modelo base	−4.350	1.140	1.264	70.95
		Random Forest	0.740	0.226	0.279	14.70
		XGBoost	**0.897**	**0.142**	**0.175**	**8.92**

Nota. Elaboración propia. En negrita, el modelo seleccionado. Criterios de entrenamiento, validación y prueba como en la Tabla 7.

En esta variable se produjo la mayor distancia entre el entrenamiento y la prueba. Random Forest pasó de un R^2 de 0.957 en entrenamiento a 0.710 en validación y a 0.740 en prueba; XGBoost, de 0.983 a 0.816 y a 0.897. En ambos casos, el RMSE de prueba fue más del doble que el de entrenamiento (0.279 kg/t frente a 0.130 kg/t en Random Forest y 0.175 kg/t frente a 0.083 kg/t en XGBoost). Esta pérdida de exactitud coincidió con el desplazamiento del consumo hacia valores bajos descrito en la Tabla 4: el conjunto de prueba concentró consumos que en el conjunto de ajuste eran poco frecuentes. La Figura 7 lo hace visible. Aunque los puntos siguen la diagonal, XGBoost tendió a sobrestimar los consumos menores de 1.5 kg/t, y los dos registros más bajos (0.73 kg/t y 0.80 kg/t) se estimaron en 1.11 kg/t y 1.33 kg/t; por encima de 2.5 kg/t, en cambio, varias predicciones quedaron ligeramente por debajo del valor observado.

Figura 7

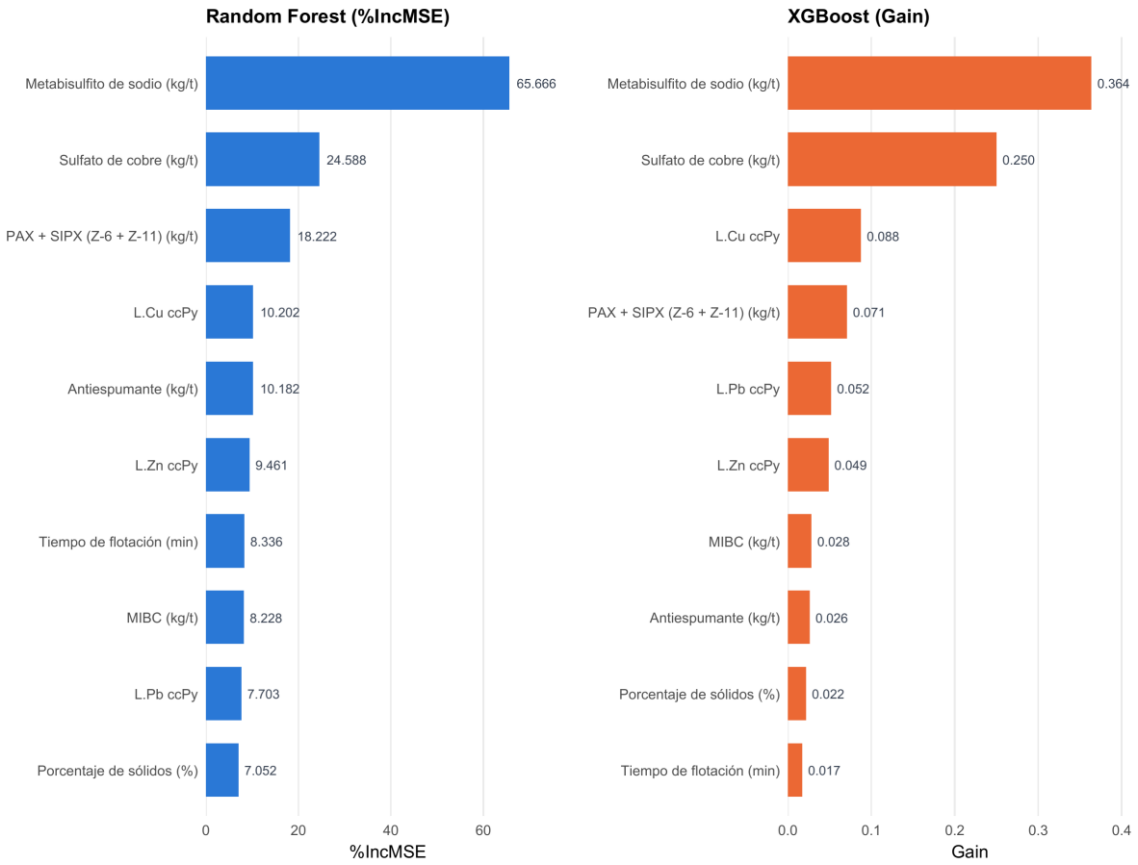
Valores observados frente a valores predichos del consumo específico de reactivos por XGBoost en el conjunto de prueba



Nota. La línea discontinua representa la igualdad entre el valor observado y el valor predicho; n = 83 registros del conjunto de prueba. Elaboración propia.

Figura 8

Importancia de las variables predictoras en los modelos de consumo específico de reactivos



Nota. %IncMSE en Random Forest y Gain en XGBoost; se muestran las diez variables de mayor importancia en cada modelo. Elaboración propia.

En los dos algoritmos, el metabisulfito de sodio y el sulfato de cobre ocuparon los dos primeros lugares de importancia (Figura 8), con valores de %IncMSE de 65.7 y 24.6 en Random Forest y con el 36.4 % y el 25.0 % de la ganancia de XGBoost. Les siguieron el PAX + SIPX, el MIBC y el antiespumante, junto con las leyes de Cu, Pb y Zn del bloque ccPy, el tiempo de flotación y el porcentaje de sólidos; las cinco dosificaciones de reactivos sumaron el 73.9 % de la ganancia de XGBoost. El orden fue coherente con la variabilidad de cada insumo: el metabisulfito fue el reactivo cuya dosificación media más cambió entre periodos, de 1.101 kg/t en validación a 0.347 kg/t en prueba, y el sulfato de cobre, el de mayor dosificación media. Además, la media del consumo específico coincidió en cada subconjunto con la suma de las medias de las cinco dosificaciones: 3.258 kg/t en entrenamiento, 2.672 kg/t en validación y 2.014 kg/t en prueba, frente a 2.015 kg/t observado, diferencia atribuible al redondeo.

La Tabla 10 reúne el contraste de las tres primeras hipótesis específicas, según las reglas de decisión de la Tabla 3. En la recuperación de Au, Random Forest y XGBoost cumplieron a la vez los cuatro criterios, por lo que se rechazó Ho1 y se aceptó Hi1. En la ley de Au en el concentrado ocurrió lo mismo, y se rechazó Ho2 y se aceptó Hi2. En el consumo específico de reactivos solo XGBoost cumplió los criterios; como la regla exigía que al menos un algoritmo los satisficiera, se rechazó Ho3 y se aceptó Hi3. Al aceptarse Hi1, Hi2 e Hi3, se rechazó la hipótesis nula general y se aceptó la hipótesis alterna general (Hi): el modelo predictivo basado en inteligencia artificial presentó un desempeño predictivo adecuado para estimar la flotación de relaves de lixiviación en sus tres dimensiones.

Tabla 10

Contraste de las hipótesis Ho1-Hi1, Ho2-Hi2 y Ho3-Hi3 en el conjunto de prueba

Variable objetivo	Modelo	R^2	MAE	RMSE	MAPE (%)	Cumple criterios	Decisión
Recuperación de Au (%)	Modelo base	−1.124	5.473	7.362	8.07	Referencia	Se acepta Hi1 y se rechaza Ho1 (cumplen ambos algoritmos)
	Random Forest	0.973	0.686	0.836	0.94	**Cumple**	
	XGBoost	0.960	0.838	1.005	1.15	**Cumple**	
Ley de Au en el concentrado (g/t)	Modelo base	−0.002	0.285	0.354	3.77	Referencia	Se acepta Hi2 y se rechaza Ho2 (cumplen ambos algoritmos)
	Random Forest	0.985	0.035	0.044	0.46	**Cumple**	
	XGBoost	0.979	0.040	0.051	0.53	**Cumple**	
Consumo específico de reactivos (kg/t)	Modelo base	−4.350	1.140	1.264	70.95	Referencia	Se acepta Hi3 y se rechaza Ho3 (cumple XGBoost)
	Random Forest	0.740	0.226	0.279	14.70	**No cumple**	
	XGBoost	0.897	0.142	0.175	8.92	**Cumple**	
Hipótesis general (Ho-Hi): se acepta Hi y se rechaza Ho							

Nota. Elaboración propia. Métricas calculadas en el conjunto de prueba (n = 83). El MAE y el RMSE se expresan en pp, g/t o kg/t, según la variable. Cumple: $R^2 \geq 0.75$, MAPE ≤ 10 % y MAE y RMSE menores que los del modelo base. Se acepta Hi1, Hi2 o Hi3 si al menos un algoritmo cumple; si ninguno cumple, se acepta la hipótesis nula correspondiente. Ho-Hi: se acepta Hi si se aceptan Hi1, Hi2 e Hi3 (Tabla 3).

Para la cuarta hipótesis específica se compararon, registro por registro, los errores de Random Forest y de XGBoost en el conjunto de prueba. Con los 83 registros se calcularon los diferenciales de pérdida de la ecuación i17, tanto con el error al cuadrado como con el error absoluto, y con ellos el estadístico de Diebold-Mariano de la ecuación i18 [70]. Por tratarse de una muestra pequeña y de predicciones a un paso, el estadístico se corrigió con la ecuación i19 [71] y su valor p se obtuvo con una distribución t de Student con 82 grados de libertad [74]. Un estadístico negativo indica que Random Forest tuvo menor pérdida, y uno positivo, que la tuvo XGBoost.

La Tabla 11 presenta el contraste. En la recuperación de Au, Random Forest obtuvo mayor R^2 y menores MAE, RMSE y MAPE que XGBoost, y la prueba de Diebold-Mariano fue significativa con las dos funciones de pérdida (DM* = −2.778 y p = 0.0068 con errores al cuadrado; DM* = −2.504 y p = 0.0143 con errores absolutos); por lo tanto, Random Forest fue significativamente superior. En el consumo específico de reactivos, XGBoost dominó las cuatro métricas y la diferencia fue significativa con ambas pérdidas (DM* = 6.070 y DM* = 8.664; p < 0.001), de modo que XGBoost fue significativamente superior. En la ley de Au en el concentrado, Random Forest también dominó las cuatro métricas y la prueba fue significativa con los errores al cuadrado (DM* = −2.174; p = 0.0326), pero no con los errores absolutos (DM* = −1.774; p = 0.0797); al no cumplirse la doble condición, no se declaró una superioridad significativa. Como la regla de decisión requería la superioridad significativa de un algoritmo en al menos una variable, y esta se verificó en dos de las tres, se rechazó Ho4 y se aceptó Hi4.

Tabla 11

Contraste de la hipótesis Ho4-Hi4 entre Random Forest y XGBoost en el conjunto de prueba

Variable objetivo	Modelo	R^2	MAE	RMSE	MAPE (%)	DM* (p) con e^2	DM* (p) con |e|	Decisión
Recuperación de Au (%)	Random Forest	0.973	0.686	0.836	0.94	−2.778 (0.0068)	−2.504 (0.0143)	**Random Forest significativamente superior**
	XGBoost	0.960	0.838	1.005	1.15			
Ley de Au en el concentrado (g/t)	Random Forest	0.985	0.035	0.044	0.46	−2.174 (0.0326)	−1.774 (0.0797)	**Sin superioridad significativa**
	XGBoost	0.979	0.040	0.051	0.53			
Consumo específico de reactivos (kg/t)	Random Forest	0.740	0.226	0.279	14.70	6.070 (< 0.001)	8.664 (< 0.001)	**XGBoost significativamente superior**
	XGBoost	0.897	0.142	0.175	8.92			
Hipótesis específica 4 (Ho4-Hi4): se acepta Hi4 y se rechaza Ho4								

Nota. Elaboración propia. Métricas calculadas en el conjunto de prueba (n = 83). El MAE y el RMSE se expresan en pp, g/t o kg/t, según la variable. DM*: estadístico de Diebold-Mariano con la corrección de Harvey, Leybourne y Newbold (ecuaciones i17 a i19); entre paréntesis, el valor p bilateral. Un DM* negativo indica menor pérdida de Random Forest y uno positivo, de XGBoost. Superioridad significativa: mayor R^2 y menores MAE, RMSE y MAPE que el otro algoritmo, y p < 0.05 con errores al cuadrado (e^2) y con errores absolutos (|e|). Se acepta Hi4 si esto ocurre en al menos una variable.

En síntesis, ningún algoritmo fue superior en todas las variables. Random Forest fue la mejor opción para la recuperación de Au y para la ley del concentrado, aunque en esta última su ventaja sobre XGBoost no alcanzó significancia estadística con los dos tipos de error; XGBoost fue la mejor opción para el consumo específico de reactivos y el único algoritmo que cumplió los criterios en las tres variables objetivo. En

consecuencia, el modelo predictivo propuesto para la planta quedó conformado por Random Forest para la recuperación y la ley, y por XGBoost para el consumo específico de reactivos.

IV. Discusión de resultados

En este capítulo se interpretan los resultados a la luz de los antecedentes y de las bases teóricas, y se valoran sus alcances y limitaciones. La discusión sigue el orden de los objetivos: primero el general y luego cada uno de los específicos; al final se examinan las fortalezas y debilidades de la metodología y la relevancia del estudio en su contexto.

El objetivo general consistió en determinar en qué medida el modelo predictivo basado en inteligencia artificial permitía predecir la flotación de relaves de lixiviación. Los resultados respondieron de manera afirmativa: con el mejor algoritmo de cada variable, el R^2 en el conjunto de prueba se ubicó entre 0.897 y 0.985, el MAPE entre 0.46 % y 8.92 %, y el MAE y el RMSE se redujeron entre 86.1 % y 88.6 % respecto de la media histórica. Al aceptarse Hi1, Hi2 e Hi3, se aceptó también la hipótesis general. Estas cifras se sitúan en la franja alta de lo que reporta la literatura de flotación. Los antecedentes resumidos en la Tabla 2 informaron coeficientes de determinación de 0.836 a 0.971 para los mejores modelos de ensamble entrenados con datos de planta o con ensayos sistemáticos [20], [27], [28], [43], y de 0.91 a 0.92 en conjuntos de laboratorio [21], [37]. Los modelos de esta investigación igualaron o superaron esos valores con datos de una operación industrial.

Que el desempeño fuera alto no significa que la tarea fuera sencilla. En el periodo de prueba, la media de la recuperación fue 7.3 pp inferior a la del entrenamiento y la del consumo específico cayó 38.2 %, mientras cambiaban el tonelaje, el tiempo de flotación y las dosificaciones. La ecuación i16 permitió comprobar que el R^2 negativo del modelo base se debió precisamente a ese desplazamiento de nivel. Con una partición aleatoria, los registros de prueba se habrían mezclado con los de entrenamiento, la media histórica habría quedado cerca de la media de prueba y el problema habría pasado inadvertido, con estimaciones más optimistas que las que se obtendrían en la operación real, tal como advierten Hewamalage et al. [24] para datos con dependencia temporal. La partición cronológica, en cambio, reprodujo la situación de la planta, en la que el modelo se entrena con el pasado y se utiliza con las guardias siguientes.

Una parte de la exactitud se explica por la naturaleza de los datos y por los algoritmos elegidos. La base reunió variables tabulares en escalas distintas, con relaciones no

lineales e interacciones, un escenario en el que los ensambles de árboles mantienen ventaja sobre las redes profundas [26]. Random Forest promedia árboles profundos construidos sobre muestras bootstrap y subconjuntos aleatorios de variables [78], mientras que XGBoost agrega árboles de forma secuencial y regularizada para corregir los residuos del ensamble previo [79]; ambos capturan umbrales e interacciones sin que el analista tenga que especificarlos. Ahora bien, el R^2 no debe leerse separado de la procedencia de los predictores. Como se discute más adelante, algunas determinaciones del bloque ccPy y las dosificaciones de reactivos guardan una relación muy directa con las variables objetivo, y esa cercanía explica una parte de valores tan elevados.

En cuanto al primer objetivo específico, Random Forest estimó la recuperación de Au con un R^2 de 0.973, un MAE de 0.686 pp y un MAPE de 0.94 %, y XGBoost con un R^2 de 0.960; ambos cumplieron los cuatro criterios y se aceptó Hi1. Estos resultados superan los de He et al. [20], quienes, con 182 días de datos de producción y un ensamble de tipo stacking con diez variables, obtuvieron un R^2 de 0.843, un MAE de 0.929 y un error relativo medio de 1.229 %. También superan el R^2 de 0.8541 que Erkan y Günen [43] lograron con Random Forest para la recuperación de zinc en menas carbonatadas y el de 0.88 que Chehreh Chelgani et al. [28] alcanzaron con CatBoost en la recuperación de cobre de un circuito industrial. Solo Amankwaa-Kyeremeh et al. [44] informaron errores menores, con un MAPE inferior a 0.25 %, aunque su modelo se entrenó con más de 1.3 millones de registros de seis años de operación, frente a los 464 registros de ajuste disponibles en esta investigación.

La coincidencia con Chehreh Chelgani et al. [28] va más allá de la magnitud del ajuste. En su estudio, Random Forest (R^2 de 0.75 a 0.87) superó a XGBoost (R^2 de 0.64 a 0.80) en todos los escenarios de prueba, y en esta investigación Random Forest también fue superior en la recuperación, con una diferencia estadísticamente significativa. Una explicación plausible se encuentra en la estructura del error. La recuperación de una guardia resulta de numerosas interacciones entre la alimentación, la química de la pulpa y la operación, y arrastra además ruido de muestreo y de análisis. Frente a una respuesta de ese tipo, el promedio de árboles poco correlacionados que realiza Random Forest reduce la varianza de la predicción [25], [78], mientras que el ajuste secuencial de XGBoost puede adaptarse en exceso a parte de ese ruido si la regularización no lo impide.

Desde el punto de vista metalúrgico, el orden de importancia de las variables fue coherente con el proceso. El sulfato de cobre, principal predictor en ambos algoritmos, es el activador de los sulfuros: el cobre adsorbido sobre la pirita favorece la fijación del xantato, y su combinación con el metabisulfito modifica la flotabilidad de la pirita aurífera [12], [13]. En los relaves cianurados, donde el oro remanente suele quedar encapsulado en pirita con superficies deprimidas por el cianuro residual, la activación cobra todavía más peso [14], [15]. El porcentaje de sólidos, segundo predictor, condiciona la probabilidad de colisión entre partículas y burbujas, la viscosidad de la pulpa y el tiempo de residencia efectivo [3], [36]. Estos resultados difieren de los de Devasahayam [7], quien halló que la potencia de molienda, la ley de cabeza y el tiempo de procesamiento dominaban la recuperación de oro. La diferencia tiene una explicación operativa: la planta estudiada no tiene etapa de molienda, de manera que la granulometría llega fijada por el relave alimentado y varió poco (88.8 % pasante la malla −200 en prueba, con una desviación estándar de 3.9 pp), al igual que la ley de cabeza (1.84 g/t, con una desviación estándar de 0.24 g/t). Una variable que apenas cambia difícilmente puede explicar las variaciones de la recuperación, aunque su importancia física sea real. El análisis exploratorio de la Tabla 5 muestra que lo mismo sucede con otras variables del proceso, como el nivel de pulpa, el caudal de aire, la densidad de pulpa y el pH, cuya variación fue inferior a 5 % de su media.

La presencia de las leyes de Zn, Pb y Cu del bloque ccPy entre los cinco primeros predictores pide una lectura cautelosa. Si esas determinaciones describen el concentrado, informan cuánto sulfuro de metales base acompañó a la pirita en la espuma, lo cual se relaciona con la selectividad de la separación y, por esa vía, con la masa de concentrado que interviene en la ecuación i1. En ese caso, el modelo de recuperación tendría un componente anticipatorio, sostenido por el sulfato de cobre y el porcentaje de sólidos, que se registran durante la guardia, y otro componente que solo estaría disponible cuando el laboratorio entregue los análisis del concentrado.

Respecto al segundo objetivo específico, Random Forest predijo la ley de Au en el concentrado con un R^2 de 0.985 y un MAPE de 0.46 %, y XGBoost con un R^2 de 0.979; ambos cumplieron los criterios y se aceptó Hi2. Estos resultados superan el R^2 de 0.92 que Devasahayam [21] obtuvo con regresión bayesiana para la ley acumulada de oro en ensayos de laboratorio, y están muy por encima del R^2 de 0.54 que Zhao et al. [88] reportaron para la ley de Fe con un modelo de grafos dinámicos, en el que

Random Forest y XGBoost fueron todavía menos exactos. La comparación con Nasiri Abarbekouh et al. [16], que predijeron la ley de oro en celdas rougher con redes informadas por la física, es menos directa, porque sus métricas se expresan como reducciones del error frente a otros modelos; aun así, ambos estudios coinciden en que la ley del concentrado puede estimarse con errores pequeños cuando se dispone de registros sistemáticos del proceso.

En la ley no se demostró que un algoritmo fuera significativamente superior al otro. Random Forest dominó las cuatro métricas y la prueba de Diebold-Mariano fue significativa con errores al cuadrado ($p = 0.0326$), pero no con errores absolutos ($p = 0.0797$). Esto sugiere que la ventaja de Random Forest provino, sobre todo, de una menor frecuencia de errores grandes, que la pérdida cuadrática pondera más, y no de una mejora del error típico. El hallazgo es coherente con Amadghous et al. [87], quienes compararon trece modelos en una planta polimetálica y encontraron diferencias muy pequeñas entre CatBoost, Random Forest y XGBoost en la ley de Cu (MAE de 1.43, 1.46 y 1.47, respectivamente), aunque sin someterlas a una prueba estadística. En esta investigación, la prueba de Diebold-Mariano permitió separar una diferencia numérica de una diferencia que se sostiene frente a la variabilidad muestral.

La importancia de variables mostró que la ley se explicó ante todo por la ley de Fe del bloque ccPy, seguida de la ley de As, la humedad, la ley de cabeza y el K80. En términos metalúrgicos, el resultado tiene sentido: en los relaves de cianuración, el oro remanente se asocia principalmente a la pirita y, en menor medida, a la arsenopirita [14], [15], de modo que un concentrado con más Fe y As suele contener más sulfuro aurífero por tonelada. Sin embargo, la metodología dejó pendiente el examen del punto de muestreo y del momento en que se conocen estas determinaciones. Varias evidencias del propio registro indican que el bloque ccPy describe el concentrado de pirita y no la alimentación: la humedad promedio de 11.7 %, propia de un producto filtrado; el 99.4 % pasante la malla 200, más fino que el relave alimentado (88.8 %); la ley de Fe cercana a 33 %, compatible con un concentrado rico en pirita; y una ley de Ag de alrededor de 90 g/t, muy superior a la de los relaves auríferos peruanos de referencia [9], [10].

Si esa lectura se confirma, la ley de Au y las leyes ccPy procederían de la misma muestra de concentrado y del mismo ciclo de análisis. El modelo seguiría siendo útil

para estimar la ley de Au a partir de determinaciones más rápidas o menos costosas que el ensayo al fuego, o para detectar inconsistencias entre análisis, pero no serviría para anticipar la ley antes de que exista el concentrado. Kapoor y Narayanan [84] describen esta situación como una forma de fuga de información, en la que el modelo emplea predictores que no estarían disponibles en el momento real de la predicción, y advierten que, en tal caso, las métricas sobrestiman el desempeño que se obtendrá en el uso. Por esa razón, emplear el modelo como sensor blando en sentido estricto, como los de Pural [5] o Nasiri Abarbekouh et al. [16], que trabajan con variables disponibles en línea, exige verificar la disponibilidad temporal de cada predictor y, de ser necesario, reentrenarlo solo con las variables que se conocen antes del resultado de laboratorio.

En relación con el tercer objetivo específico, XGBoost estimó el consumo específico de reactivos con un R^2 de 0.897 y un MAPE de 8.92 % y fue el único algoritmo que cumplió los cuatro criterios, por lo que se aceptó Hi3; Random Forest, con un R^2 de 0.740 y un MAPE de 14.70 %, quedó cerca del umbral sin alcanzarlo. Los errores obtenidos son mayores que los que Yu et al. [89] informaron para la dosificación de colector y de espumante en una planta de carbón (error relativo medio de 5.94 % y 8.11 % con Random Forest) y que los de Pérez Cortés et al. [90] para el consumo de agua en concentradoras de cobre (MAPE de 4.95 % con Random Forest y de 5.17 % con XGBoost). Esos estudios, sin embargo, contaron con 26 225 registros continuos y con 366 registros diarios, respectivamente, y no afrontaron una caída tan pronunciada del nivel de la variable entre el entrenamiento y la prueba como la observada aquí. En la introducción se anticipó que el umbral de MAPE sería un reto mayor para el consumo, cuyo coeficiente de variación en el primer trimestre fue de 44.84 % [11], y los resultados lo confirmaron: fue la única variable en la que un algoritmo no cumplió los criterios.

La interpretación de este resultado exige considerar cómo se construye la variable. Según la ecuación i3, el consumo específico es la suma de los reactivos dosificados por tonelada de alimentación, y en esta investigación las cinco dosificaciones (sulfato de cobre, metabisulfito de sodio, PAX + SIPX, MIBC y antiespumante) se incluyeron como predictores. La coincidencia entre la media del consumo y la suma de las medias de las cinco dosificaciones en los tres subconjuntos, descrita en los resultados, confirma esa relación. En consecuencia, el modelo de consumo aprendió,

en lo esencial, a reconstruir una suma, y así lo reflejó la importancia de variables, encabezada por el metabisulfito, el sulfato de cobre y el PAX + SIPX.

Esta característica ayuda a entender por qué XGBoost superó con amplitud a Random Forest ($p < 0.001$ con ambas pérdidas). El boosting construye el modelo como una suma de árboles añadidos por etapas [86], de modo que puede representar con relativa facilidad una respuesta aditiva: cada árbol incorpora una porción del efecto de un reactivo. Random Forest, en cambio, promedia árboles que intentan aproximar cada uno la función completa [78]; sus predicciones son promedios de valores observados en las hojas y tienden a contraerse hacia el centro de la distribución en las zonas con pocos datos. Es lo que sucedió con los consumos bajos del periodo de prueba: XGBoost los sobrestimó ligeramente, y Random Forest acumuló un MAE 60 % mayor que el de XGBoost.

Desde el punto de vista práctico, este hallazgo matiza el alcance de Hi3. Si el consumo específico es la suma de las dosificaciones, una vez conocidas estas el consumo puede calcularse sin error con la ecuación i3, y una combinación lineal de las cinco variables lo reproduciría exactamente. El valor del modelo de consumo, tal como se configuró, reside más en demostrar que el procedimiento de modelamiento recupera una relación conocida que en anticipar un dato desconocido. Para que el consumo se convierta en una variable verdaderamente predictiva, el modelo tendría que estimarlo, o estimar la dosificación necesaria, a partir de la alimentación y de las condiciones de operación y antes de dosificar, en la línea de los modelos de dosificación de Yu et al. [89] y de los sistemas de optimización de circuitos de flotación de Hasidi et al. [29]. Esta reformulación se plantea en las recomendaciones.

El cuarto objetivo específico fue comparar Random Forest y XGBoost. Los resultados no favorecieron a un mismo algoritmo en todas las variables: Random Forest fue significativamente superior en la recuperación, XGBoost lo fue en el consumo, y en la ley la ventaja de Random Forest no superó la doble exigencia de la prueba de Diebold-Mariano. Como la regla de decisión pedía superioridad significativa en al menos una variable, se aceptó Hi4. Este patrón coincide con lo que la literatura ya sugería: el mejor algoritmo depende del material, de la variable y de los datos disponibles. Ji et al. [27] encontraron que XGBoost era el más preciso para el rendimiento y las cenizas en la flotación de carbón; Chehreh Chelgani et al. [28] observaron lo contrario en un

circuito de cobre, con Random Forest por encima de XGBoost y ambos por debajo de CatBoost; y Amankwaa-Kyeremeh et al. [44] obtuvieron el mejor resultado con procesos gaussianos. En un plano más general, Grinsztajn et al. [85] mostraron que los modelos basados en árboles siguen superando a las redes profundas en datos tabulares de tamaño medio, lo que respalda la elección de ambos ensambles para un problema como el de esta planta.

Más allá de cuál algoritmo resultó mejor, la comparación deja una lección metodológica. En la recuperación, XGBoost fue mejor en validación y Random Forest en prueba; si la selección se hubiera basado solo en el subconjunto de validación, se habría elegido el algoritmo que después resultó inferior. Cerqueira et al. [81] mostraron que, en series reales no estacionarias, conviene estimar el desempeño con esquemas que respeten el orden temporal, como el empleado aquí, y Lones [59] advierte que las conclusiones extraídas de una sola partición, sin una prueba estadística, pueden no sostenerse. En esta investigación, la evaluación por única vez en el conjunto de prueba y el uso de la prueba de Diebold-Mariano con dos funciones de pérdida volvieron la comparación más exigente de lo que es habitual en los estudios de flotación revisados, que por lo general se limitan a ordenar los modelos según sus métricas [28], [87].

La prueba de Diebold-Mariano tiene, con todo, supuestos que conviene hacer explícitos. Requiere que el diferencial de pérdida sea estacionario en covarianza, y con 83 registros su potencia es limitada; además, en series industriales los errores pueden estar autocorrelacionados o ser heterocedásticos, condiciones en las que la versión estándar puede distorsionar su tamaño real [52], [72], [73]. La corrección de Harvey, Leybourne y Newbold [71] atenúa el problema de las muestras pequeñas, pero no lo elimina. Por ello, el resultado de la ley, con $p = 0.0797$ en la pérdida absoluta, debe leerse como ausencia de evidencia suficiente y no como prueba de que ambos algoritmos sean equivalentes.

Entre las fortalezas de la metodología destacan cuatro. La primera es el uso de datos reales de una planta industrial, que distingue a este estudio de los trabajos basados en once ensayos de laboratorio [7] o en datos generados por un gemelo digital [16], y que responde a la limitación señalada por Estay et al. [22] sobre la escasez de datos confiables para llevar los modelos a la operación. La segunda es la partición

cronológica con reentrenamiento antes de la prueba, que impidió que información del futuro llegara al entrenamiento. La tercera es la comparación con un modelo base explícito, práctica recomendada para saber cuánto aporta realmente un algoritmo [24], [59], y que aquí permitió explicar, mediante la ecuación i16, por qué la media histórica falla cuando el proceso cambia de nivel. La cuarta es el contraste formal de la cuarta hipótesis con una prueba estadística, poco frecuente en la literatura revisada.

También se identificaron debilidades que acotan el alcance de los resultados. La primera es la ya comentada disponibilidad temporal de los predictores: las determinaciones ccPy, si corresponden al concentrado, y las dosificaciones de reactivos, en el caso del consumo, acercan el problema a una reconstrucción más que a una anticipación, y es probable que un sensor blando estricto obtenga un desempeño menor que el reportado [84]. La segunda es el tamaño y la cobertura de la muestra: 547 registros de nueve meses en una sola planta permiten conclusiones válidas para esa operación, pero no autorizan a generalizarlas a otras plantas de relaves sin una nueva validación. La tercera se relaciona con la interpretación. El %IncMSE y la ganancia son medidas globales: pueden verse sesgadas por la escala o por el número de valores distintos de cada predictor [83] y, cuando los predictores están correlacionados, repartir o concentrar la importancia de forma engañosa [68]; en XGBoost, por ejemplo, cinco variables acumularon más del 99 % de la ganancia en la recuperación y en la ley. El análisis SHAP, previsto como complemento en la metodología, no formó parte de los resultados y permitiría descomponer cada predicción en la contribución de cada variable, tanto en el plano local como en el global [46], [80].

La cuarta debilidad es el cambio de régimen del proceso. La caída del consumo y de la recuperación entre periodos, junto con los cambios de tonelaje, de tiempo de flotación y de dosificación descritos en la Tabla 5, indica que la relación entre entradas y salidas puede desplazarse con el tiempo, fenómeno conocido como deriva de concepto [82]. Un modelo entrenado una sola vez perdería exactitud a medida que la planta cambie de relave o de práctica operativa; por eso, el reentrenamiento periódico y el monitoreo de los errores son una condición para su uso y no un complemento opcional. La quinta debilidad atañe a los criterios de decisión. El modelo base cumplió por sí solo el umbral de MAPE en la recuperación y en la ley, lo que demuestra que ese criterio, tomado de una escala general [31], fue poco exigente para variables con

valores altos y baja variación relativa. En futuras investigaciones convendría fijar los umbrales en términos relativos al modelo base, como el cociente entre errores o las reducciones porcentuales, según sugieren Hewamalage et al. [24]. Por último, los hiperparámetros se eligieron con un único bloque de validación; un esquema de origen móvil habría ofrecido una estimación más estable [81].

Pese a estas limitaciones, los resultados son relevantes en el contexto científico y social. En el plano científico, aportan evidencia empírica sobre un material poco estudiado, el relave aurífero previamente cianurado y reprocesado por flotación a escala industrial, para el que la revisión de la literatura no halló modelos predictivos comparables [7], [16], [17]. Muestran, además, que una misma base de datos puede requerir algoritmos distintos para respuestas distintas del proceso, y que la comparación debe hacerse con un protocolo temporal y con pruebas estadísticas. En el plano práctico, un sensor blando que estime la recuperación con un error medio inferior a 0.7 pp permitiría a la guardia evaluar el efecto de cambios en la dosificación de sulfato de cobre o en el porcentaje de sólidos sin esperar el balance metalúrgico, siempre con la revisión del metalurgista, como se estableció en los principios éticos del estudio [3], [7]. En el plano social y ambiental, una flotación más estable y un uso de reactivos guiado por datos contribuyen a recuperar metal de un pasivo minero y a reducir el consumo de insumos químicos, en línea con la meta 9.4 del Objetivo de Desarrollo Sostenible 9 y con los principios de economía circular aplicados a los relaves [1], [2].

V. Conclusiones

Primera. Se determinó que el modelo predictivo basado en inteligencia artificial permitió predecir la flotación de relaves de lixiviación en sus tres dimensiones. Con el mejor algoritmo de cada variable, el R^2 en el conjunto de prueba se ubicó entre 0.897 y 0.985, el MAPE entre 0.46 % y 8.92 %, y el MAE y el RMSE se redujeron en más de 85 % frente al modelo base de media histórica. Al aceptarse Hi1, Hi2 e Hi3, se aceptó la hipótesis general Hi y se rechazó Ho.

Segunda. Se determinó que el modelo permitió predecir el rendimiento de la recuperación metálica. Random Forest estimó la recuperación de Au con un R^2 de 0.973, un MAE de 0.686 puntos porcentuales (pp) y un MAPE de 0.94 %, y redujo el MAE y el RMSE en 87.5 % y 88.6 % respecto al modelo base; XGBoost también cumplió los criterios, con un R^2 de 0.960. El sulfato de cobre y el porcentaje de sólidos fueron los predictores de mayor importancia, lo que concuerda con el papel de la activación y de las condiciones de la pulpa en la flotación de la pirita aurífera.

Tercera. Se determinó que el modelo permitió predecir la calidad del concentrado. Random Forest estimó la ley de Au en el concentrado con un R^2 de 0.985, un MAE de 0.035 g/t y un MAPE de 0.46 %, y XGBoost con un R^2 de 0.979, ambos con reducciones del error superiores a 85 %. La ley de Fe del bloque ccPy fue el predictor dominante, por lo que el uso del modelo como sensor anticipatorio queda condicionado a confirmar que esas determinaciones están disponibles antes del resultado de laboratorio de la ley de Au.

Cuarta. Se determinó que el modelo permitió predecir la eficiencia en el uso de insumos químicos. XGBoost estimó el consumo específico de reactivos con un R^2 de 0.897 y un MAPE de 8.92 % y fue el único algoritmo que cumplió los criterios, mientras que Random Forest obtuvo un R^2 de 0.740 y un MAPE de 14.70 %. Como el consumo específico se calcula como la suma de las dosificaciones incluidas entre los predictores, el modelo reprodujo esa agregación; su valor predictivo para la planta dependerá de reformularlo con variables que se conozcan antes de dosificar.

Quinta. Se determinó que ninguno de los dos algoritmos fue superior en todas las variables. Random Forest fue significativamente superior en la recuperación de Au ($p = 0.0068$ con errores al cuadrado y $p = 0.0143$ con errores absolutos) y XGBoost en

el consumo específico de reactivos ($p < 0.001$ con ambas pérdidas), mientras que en la ley de Au la ventaja de Random Forest no fue significativa con los errores absolutos ($p = 0.0797$). Por ello se aceptó Hi4, y la configuración recomendada para la planta combina Random Forest para la recuperación y la ley con XGBoost para el consumo específico de reactivos.

VI. Recomendaciones

Primera. A la gerencia de operaciones de la planta concentradora, implementar el modelo Random Forest de recuperación de Au como sensor blando de apoyo a la decisión, conectado a la base del sistema SCADA/PLC, en una fase piloto en la que sus predicciones se registren en paralelo con los resultados del balance metalúrgico durante no menos de tres meses y sin intervenir en la operación. Si en ese periodo el MAE se mantiene por debajo de 1 pp y el R^2 por encima de 0.75, el modelo podrá incorporarse a los reportes de guardia, siempre con la revisión del metalurgista responsable.

Segunda. Al área de metalurgia y al laboratorio de la planta, documentar el punto de muestreo y la hora en que se obtiene cada determinación del bloque ccPy, y reentrenar los modelos de recuperación y de ley con un conjunto de predictores formado solo por variables disponibles antes del resultado de laboratorio, es decir, los registros SCADA/PLC, las dosificaciones y las características de la alimentación. La comparación entre ambas versiones permitirá cuantificar cuánto del desempeño depende de información del concentrado y qué exactitud cabe esperar de un sensor blando estricto.

Tercera. A los responsables del control de reactivos, reformular el modelo de consumo para que estime la dosificación o el consumo específico requerido a partir de la alimentación y de las condiciones de operación, sin incluir como predictores las dosificaciones que componen la variable. Con ese modelo y con los de recuperación y ley, podría plantearse un problema de optimización que busque el menor consumo compatible con una recuperación y una ley objetivo, en la línea de los sistemas de optimización de circuitos de flotación basados en datos [29].

Cuarta. Al equipo encargado de mantener los modelos, establecer un protocolo mensual de monitoreo que compare la distribución de las variables de entrada y los errores de predicción con los del entrenamiento, y que active el reentrenamiento cuando el MAE supere de forma sostenida los valores obtenidos en la prueba. El protocolo debe incluir el control de calidad de los datos, la sincronización de los registros de guardia con los análisis de laboratorio y la detección de valores atípicos [23], [82].

Quinta. A los futuros investigadores, ampliar el periodo de estudio y el número de plantas, evaluar los modelos con un esquema de origen móvil en lugar de un único bloque de prueba, incorporar el análisis SHAP para interpretar las predicciones individuales y comparar Random Forest y XGBoost con CatBoost, procesos gaussianos y modelos informados por la física [16], [28], [44], [80], [81]. Asimismo, se recomienda definir los umbrales de decisión en términos relativos al modelo base y emplear versiones de la prueba de Diebold-Mariano robustas a la autocorrelación y a la heterocedasticidad de los errores [24], [72].

Referencias

[1] P. Kinnunen, M. Karhu, E. Yli-Rantala, P. Kivikytö-Reponen y J. Mäkinen, “A review of circular economy strategies for mine tailings,” *Clean. Eng. Technol.*, vol. 8, Art. no. 100499, 2022, doi: 10.1016/j.clet.2022.100499.

[2] S. Kursunoglu, “A review on the recovery of critical metals from mine and mineral processing tailings: recent advances,” *J. Sustain. Metall.*, vol. 11, pp. 2023–2050, 2025, doi: 10.1007/s40831-025-01126-y.

[3] A. Szmigiel, D. B. Apel, K. Skrzypkowski, L. Wojtecki y Y. Pu, “Advancements in machine learning for optimal performance in flotation processes: a review,” *Minerals*, vol. 14, no. 4, Art. no. 331, 2024, doi: 10.3390/min14040331.

[4] P. Quintanilla, D. Navia, S. J. Neethling y P. R. Brito-Parada, “Economic model predictive control for a rougher froth flotation cell using physics-based models,” *Miner. Eng.*, vol. 196, Art. no. 108050, 2023, doi: 10.1016/j.mineng.2023.108050.

[5] Y. E. Pural, “Developing a data-driven soft sensor to predict silicate impurity in iron ore flotation concentrate,” *Physicochem. Probl. Miner. Process.*, vol. 59, no. 5, Art. no. 169823, 2023, doi: 10.37190/ppmp/169823.

[6] O. Hasidi *et al.*, “Digital twin of minerals processing operations for an advanced monitoring and supervision: froth flotation process case study,” *Int. J. Adv. Manuf. Technol.*, vol. 132, pp. 1031–1049, 2024, doi: 10.1007/s00170-024-13384-3.

[7] S. Devasahayam, “Interpretable machine learning for identifying key variables influencing gold recovery and grade,” *Materials*, vol. 18, no. 18, Art. no. 4318, 2025, doi: 10.3390/ma18184318.

[8] L. Chávez Quispe, “La era del ‘smart mining’: así se usan las tecnologías disruptivas en las minas peruanas,” *Forbes Perú*, 1 sep. 2023. [En línea]. Disponible en: https://forbes.pe/especiales/2023-09-01/la-era-de-la-mineria-inteligente-asi-se-usan-las-tecnologias-disruptivas-en-las-minas-peruanas

[9] C. J. Berrospi Borda, “Tratamiento metalúrgico a los relaves para la recuperación de oro a nivel de laboratorio en la planta concentradora

Copperfield Perú S.A.C. Lima – 2022," Tesis, Univ. Nacional Daniel Alcides Carrión, Cerro de Pasco, Perú, 2023. [En línea]. Disponible en: http://repositorio.undac.edu.pe/handle/undac/3494

[10] Y. M. Mory Blas, "Efecto de colectores secundarios en el tratamiento de relaves para la flotación de pirita aurífera," Tesis, Univ. Nacional José Faustino Sánchez Carrión, Huacho, Perú, 2024. [En línea]. Disponible en: https://repositorio.unjfsc.edu.pe/handle/20.500.14067/10248

[11] Planta concentradora en la región Lima, "Registros operacionales, reportes metalúrgicos, reportes de consumo y costos de reactivos y base histórica SCADA/PLC del circuito de flotación de relaves de lixiviación, 2026," documento interno no publicado, en la región Lima, 2026.

[12] C. I. Castellón, N. Toro, E. Gálvez, P. Robles, W. H. Leiva y R. I. Jeldres, "Froth flotation of chalcopyrite/pyrite ore: a critical review," *Materials*, vol. 15, no. 19, Art. no. 6536, 2022, doi: 10.3390/ma15196536.

[13] C. I. Castellón, P. Toledo, F. Rojas, F. D. Sepúlveda y R. I. Jeldres, "Pyrite depression by sodium metabisulfite in freshwater and seawater with copper activation," *Minerals*, vol. 14, no. 10, Art. no. 1036, 2024, doi: 10.3390/min14101036.

[14] Z. Huang y T. Yang, "Gold recovery from cyanidation tailings using flotation process," *Arch. Metall. Mater.*, vol. 67, no. 1, pp. 37–43, 2022. [En línea]. Disponible en: https://czasopisma.pan.pl/dlibra/publication/137469/edition/122502/content

[15] O. Allard, M. Lopez, I. Demers y L. Coudert, "Gold recovery from sulfide concentrates produced by environmental desulfurization of mine tailings," *Minerals*, vol. 12, no. 8, Art. no. 1011, 2022, doi: 10.3390/min12081011.

[16] M. Nasiri Abarbekouh, S. Iqbal y S. Särkkä, "Physics-informed machine learning for grade prediction in froth flotation," *Miner. Eng.*, vol. 227, Art. no. 109297, 2025, doi: 10.1016/j.mineng.2025.109297.

[17] A. Gomez-Flores, S. Ilyas, G. W. Heyes y H. Kim, “A critical review of artificial intelligence in mineral concentration,” *Miner. Eng.*, vol. 189, Art. no. 107884, 2022, doi: 10.1016/j.mineng.2022.107884.

[18] A. H. Alsafasfeh, L. Z. Alagha, A. Alzidaneen y V. S. S. Nadendla, “Optimization of flotation efficiency of phosphate minerals in mine tailings using polymeric depressants: experiments and machine learning,” *Physicochem. Probl. Miner. Process.*, vol. 58, no. 4, Art. no. 150477, 2022, doi: 10.37190/PPMP/150477.

[19] D. Zhang, X. Gao y H. Wang, “Prediction model of iron reverse flotation tailings grade based on multi-feature fusion,” *Measurement*, vol. 206, Art. no. 112062, 2023, doi: 10.1016/j.measurement.2022.112062.

[20] G. He, M. Liu, H. Zhao y K. Huang, “Ensemble prediction modeling of flotation recovery based on machine learning,” *Int. J. Min. Sci. Technol.*, vol. 34, no. 12, pp. 1727–1740, 2024, doi: 10.1016/j.ijmst.2024.11.012.

[21] S. Devasahayam, “Advancing flotation process modeling: Bayesian vs. sklearn approaches for gold grade prediction,” *Minerals*, vol. 15, no. 6, Art. no. 591, 2025, doi: 10.3390/min15060591.

[22] H. Estay, P. Lois-Morales, G. Montes-Atenas y J. Ruiz del Solar, “On the challenges of applying machine learning in mineral processing and extractive metallurgy,” *Minerals*, vol. 13, no. 6, Art. no. 788, 2023, doi: 10.3390/min13060788.

[23] C. Lartey, J. Liu, R. K. Asamoah, C. Greet, M. Zanin y W. Skinner, “Effective outlier detection for ensuring data quality in flotation data modelling using machine learning (ML) algorithms,” *Minerals*, vol. 14, no. 9, Art. no. 925, 2024, doi: 10.3390/min14090925.

[24] H. Hewamalage, K. Ackermann y C. Bergmeir, “Forecast evaluation for data scientists: common pitfalls and best practices,” *Data Min. Knowl. Discov.*, vol. 37, no. 2, pp. 788–832, 2023, doi: 10.1007/s10618-022-00894-5.

[25] G. James, D. Witten, T. Hastie, R. Tibshirani y J. Taylor, *An Introduction to Statistical Learning: with Applications in Python*. Cham, Suiza: Springer, 2023, doi: 10.1007/978-3-031-38747-0.

[26] R. Shwartz-Ziv y A. Armon, “Tabular data: deep learning is not all you need,” *Inf. Fusion*, vol. 81, pp. 84–90, 2022, doi: 10.1016/j.inffus.2021.11.011.

[27] Y. Ji et al., “Evaluation of parametric effects of coal flotation based on boosting modeling method,” *Physicochem. Probl. Miner. Process.*, vol. 60, no. 6, Art. no. 196385, 2024, doi: 10.37190/ppmp/196385.

[28] S. Chehreh Chelgani, A. Homafar, H. Nasiri y M. Rezaei Laksar, “CatBoost-SHAP for modeling industrial operational flotation variables – A ‘conscious lab’ approach,” *Miner. Eng.*, vol. 213, Art. no. 108754, 2024, doi: 10.1016/j.mineng.2024.108754.

[29] O. Hasidi et al., “Data-driven system for intelligent monitoring and optimization of froth flotation circuits using artificial neural networks and genetic algorithms,” *J. Process Control*, Art. no. 103198, 2024, doi: 10.1016/j.jprocont.2024.103198.

[30] J. F. Hair, Jr., G. T. M. Hult, C. M. Ringle y M. Sarstedt, *A Primer on Partial Least Squares Structural Equation Modeling (PLS-SEM)*, 3.ª ed. Thousand Oaks, CA, EE. UU.: SAGE, 2022.

[31] S. Zarbakhsh, A. R. Shahsavar y M. Soltani, “Optimizing PGRs for in vitro shoot proliferation of pomegranate with bayesian-tuned ensemble stacking regression and NSGA-II: a comparative evaluation of machine learning models,” *Plant Methods*, vol. 20, no. 1, Art. no. 82, 2024, doi: 10.1186/s13007-024-01211-5.

[32] G. A. Castro Melendez, “Aplicación del Machine Learning y el pronóstico de mineralización en la concesión minera Gus del Aire, Huánuco 2023,” Tesis, Univ. Nacional Daniel Alcides Carrión, Cerro de Pasco, Perú, 2025. [En línea]. Disponible en: http://repositorio.undac.edu.pe/handle/undac/5864

[33] Y. P. Idrogo Zamora, “Machine Learning aplicado al control de la fragmentación de rocas en la voladura de minas a tajo abierto,” Tesis, Univ. Nacional de Ingeniería, Lima, Perú, 2022. [En línea]. Disponible en: http://hdl.handle.net/20.500.14076/22525

[34] A. Tapfuma *et al.*, “Gold tailing metal extraction and sustainable end-use: a closed-loop review,” *Miner. Eng.*, vol. 239, Art. no. 110075, 2026, doi: 10.1016/j.mineng.2026.110075.

[35] A. Karppinen, S. Seisko, L. Nevatalo, B. P. Wilson, K. Yliniemi y M. Lundström, “Gold recovery from cyanidation residue by chloride leaching and carbon adsorption – Preliminary results from CICL process,” *Hydrometallurgy*, vol. 226, Art. no. 106304, 2024, doi: 10.1016/j.hydromet.2024.106304.

[36] F. Concha A. y O. A. Bascur, *The Engineering Science of Mineral Processing: A Fundamental and Practical Approach*. Boca Raton, FL, EE. UU.: CRC Press, 2024.

[37] D. Ali, M. B. Hayat, L. Alagha, K. C. Monyake y H. Khalid, “Artificial intelligence and machine learning models for predicting the metallurgical performance of complex sulfide ore flotation process,” *Miner. Process. Extr. Metall.*, vol. 134, no. 1, pp. 13–32, 2025, doi: 10.1177/25726641241311475.

[38] E. Özdemir *et al.*, “Modeling and simulation of a gold concentrator plant implementing a dissolution loop method,” *Physicochem. Probl. Miner. Process.*, vol. 59, no. 5, Art. no. 166377, 2023, doi: 10.37190/ppmp/166377.

[39] J. Benitez, V. Flores, S. Curilef, R. Martinez-Pelaez y C. Leiva, “Predicting copper recovery from flotation using machine learning and laboratory-generated data,” *Chaos*, vol. 35, no. 9, 2025, doi: 10.1063/5.0278193.

[40] A. Géron, *Hands-On Machine Learning with Scikit-Learn, Keras, and TensorFlow: Concepts, Tools, and Techniques to Build Intelligent Systems*, 3.ª ed. Sebastopol, CA, EE. UU.: O’Reilly Media, 2022.

[41] A. Gomez-Flores et al., “Prediction of grade and recovery in flotation from physicochemical and operational aspects using machine learning models,” *Miner. Eng.*, Art. no. 107627, 2022, doi: 10.1016/j.mineng.2022.107627.

[42] N. Henríquez, E. Ortiz, R. Martinez-Pelaez y C. Leiva, “Random forest for generating recommendations for predicting copper recovery by flotation,” *IEEE Lat. Am. Trans.*, vol. 22, no. 6, pp. 443–450, 2024, doi: 10.1109/TLA.2024.10534301.

[43] I. Erkan y M. A. Günen, “Comparison of Zn recovery prediction from carbonate ores with machine-learning methods,” *Int. J. Miner. Metall. Mater.*, vol. 33, no. 3, pp. 820–832, 2026, doi: 10.1007/s12613-025-3286-4.

[44] B. Amankwaa-Kyeremeh, C. McCamley, M. Zanin, C. Greet, K. Ehrig y R. K. Asamoah, “Prediction and optimisation of copper recovery in the rougher flotation circuit,” *Minerals*, vol. 14, no. 1, Art. no. 36, 2024, doi: 10.3390/min14010036.

[45] V. Plevris, G. Solorzano, N. Bakas y M. Ben Seghier, “Investigation of performance metrics in regression analysis and machine learning-based prediction models,” en *8th European Congress on Computational Methods in Applied Sciences and Engineering (ECCOMAS Congress 2022)*, Oslo, Noruega, 2022, doi: 10.23967/eccomas.2022.155.

[46] C. Molnar, *Interpretable Machine Learning: A Guide for Making Black Box Models Explainable*, 2.ª ed. Christoph Molnar, 2022. [En línea]. Disponible en: https://christophm.github.io/interpretable-ml-book/

[47] F. Nakhaei, S. Rahimi y M. Fathi, “Prediction of sulfur removal from iron concentrate using column flotation froth features: comparison of k-means clustering, regression, backpropagation neural network, and convolutional neural network,” *Minerals*, vol. 12, no. 11, Art. no. 1434, 2022, doi: 10.3390/min12111434.

[48] A. Bendaouia *et al.*, “Hybrid features extraction for the online mineral grades determination in the flotation froth using deep learning,” *Eng. Appl. Artif. Intell.*, vol. 129, Art. no. 107680, 2024, doi: 10.1016/j.engappai.2023.107680.

[49] X. Chen, D. Liu, L. Yu, P. Shao, M. An y S. Wen, “Recent advances in flotation froth image analysis via deep learning,” *Eng. Appl. Artif. Intell.*, vol. 147, Art. no. 110283, 2025, doi: 10.1016/j.engappai.2025.110283.

[50] T. O. Hodson, “Root-mean-square error (RMSE) or mean absolute error (MAE): when to use them or not,” *Geosci. Model Dev.*, vol. 15, no. 14, pp. 5481–5487, 2022, doi: 10.5194/gmd-15-5481-2022.

[51] Ş. G. Özkan, “Artificial intelligence versus natural intelligence in mineral processing,” *Physicochem. Probl. Miner. Process.*, vol. 59, no. 5, Art. no. 167501, 2023, doi: 10.37190/ppmp/167501.

[52] L. Coroneo y F. Iacone, “Testing for equal predictive accuracy with strong dependence,” *Int. J. Forecast.*, vol. 41, no. 3, pp. 1073–1092, 2025, doi: 10.1016/j.ijforecast.2024.11.003.

[53] S. Sarwar, G. Aziz y D. Balsalobre-Lorente, “Forecasting accuracy of traditional regression, machine learning, and deep learning: a study of environmental emissions in Saudi Arabia,” *Sustainability*, vol. 15, no. 20, Art. no. 14957, 2023, doi: 10.3390/su152014957.

[54] H. Ñaupas Paitán, E. Mejía Mejía, I. R. Trujillo Román, H. E. Romero Delgado, W. Medina Bárcena y E. Novoa Ramírez, *Metodología de la investigación total: cuantitativa, cualitativa y redacción de tesis*, 6.ª ed. Bogotá, Colombia: Ediciones de la U, 2023.

[55] Y. Li *et al.*, “Artificial intelligence of mineral processing process: a review of research progress,” *J. Environ. Chem. Eng.*, vol. 13, no. 5, Art. no. 118313, 2025, doi: 10.1016/j.jece.2025.118313.

[56] N. Maldonado-Suárez y F. Santoyo-Telles, “Validez de contenido por juicio de expertos: integración cuantitativa y cualitativa en la construcción de instrumentos de medición,” *REIRE Rev. Innov. Recer. Educ.*, vol. 17, no. 2, 2024, doi: 10.1344/reire.46238.

[57] C. Merino-Soto, “Coeficientes V de Aiken: diferencias en los juicios de validez de contenido,” *MHSalud*, vol. 20, no. 1, pp. 23–32, 2023, doi: 10.15359/mhs.20-1.3.

[58] J. R. Torres-Malca, V. J. Vera-Ponce, F. E. Zuzunaga-Montoya, J. E. Talavera y J. A. De la Cruz-Vargas, “Validez de contenido por juicio de expertos de un instrumento para medir conocimientos, actitudes y prácticas sobre el consumo de sal en la población peruana,” *Rev. Fac. Med. Hum.*, vol. 22, no. 2, pp. 273–279, 2022, doi: 10.25176/RFMH.v22i2.4768.

[59] M. A. Lones, “Avoiding common machine learning pitfalls,” *Patterns*, vol. 5, no. 10, Art. no. 101046, 2024, doi: 10.1016/j.patter.2024.101046.

[60] scikit-learn developers, “DummyRegressor,” scikit-learn 1.9.1 documentation. Consultado: 11 oct. 2026. [En línea]. Disponible en: https://scikit-learn.org/stable/modules/generated/sklearn.dummy.DummyRegressor.html

[61] R Core Team, *R: A Language and Environment for Statistical Computing*. Viena, Austria: R Foundation for Statistical Computing, 2026. [En línea]. Disponible en: https://www.R-project.org/

[62] Posit Team, *RStudio: Integrated Development Environment for R*. Boston, MA, EE. UU.: Posit Software, PBC, 2026. [En línea]. Disponible en: https://posit.co/

[63] W. Chang et al., “shiny: Web application framework for R,” paquete de R, versión 1.14.0, 2026, doi: 10.32614/CRAN.package.shiny.

[64] C. Sievert, J. Cheng y G. Aden-Buie, “bslib: Custom ‘Bootstrap’ ‘Sass’ themes for ‘shiny’ and ‘rmarkdown’,” paquete de R, versión 0.12.0, 2026, doi: 10.32614/CRAN.package.bslib.

[65] H. Wickham y J. Bryan, “readxl: Read Excel files,” paquete de R, versión 1.5.0.1, 2026, doi: 10.32614/CRAN.package.readxl.

[66] L. Breiman, A. Cutler, A. Liaw y M. Wiener, “randomForest: Breiman and Cutler’s random forests for classification and regression,” paquete de R, versión 4.7-1.2, 2024, doi: 10.32614/CRAN.package.randomForest.

[67] T. Chen et al., “xgboost: Extreme gradient boosting,” paquete de R, versión 3.2.1.1, 2026, doi: 10.32614/CRAN.package.xgboost.

[68] F. K. Ewald, L. Bothmann, M. N. Wright, B. Bischl, G. Casalicchio y G. König, “A guide to feature importance methods for scientific inference,” en *Explainable Artificial Intelligence* (Communications in Computer and Information Science). Cham, Suiza: Springer, 2024, pp. 440–464, doi: 10.1007/978-3-031-63797-1_22.

[69] M. Z. Naser y A. H. Alavi, “Error metrics and performance fitness indicators for artificial intelligence and machine learning in engineering and sciences,” *Archit.*

Struct. Constr., vol. 3, no. 4, pp. 499–517, 2023, doi: 10.1007/s44150-021-00015-8.

[70] F. X. Diebold y R. S. Mariano, “Comparing predictive accuracy,” *J. Bus. Econ. Stat.*, vol. 13, no. 3, pp. 253–263, 1995, doi: 10.1080/07350015.1995.10524599.

[71] D. Harvey, S. Leybourne y P. Newbold, “Testing the equality of prediction mean squared errors,” *Int. J. Forecast.*, vol. 13, no. 2, pp. 281–291, 1997, doi: 10.1016/S0169-2070(96)00719-4.

[72] D. I. Harvey, S. J. Leybourne y Y. Zu, “Tests for equal forecast accuracy under heteroskedasticity,” *J. Appl. Econometrics*, vol. 39, no. 5, pp. 850–869, 2024, doi: 10.1002/jae.3050.

[73] D. I. Harvey, S. J. Leybourne y Y. Zu, “Testing for equal average forecast accuracy in possibly unstable environments,” *J. Bus. Econ. Stat.*, vol. 43, no. 3, pp. 643–656, 2025, doi: 10.1080/07350015.2024.2418835.

[74] R. Hyndman et al., “forecast: Forecasting functions for time series and linear models,” paquete de R, versión 9.0.2, 2026, doi: 10.32614/CRAN.package.forecast.

[75] H. Wickham et al., “ggplot2: Create elegant data visualisations using the grammar of graphics,” paquete de R, versión 4.0.3, 2026, doi: 10.32614/CRAN.package.ggplot2.

[76] Y. Xie, J. Cheng, X. Tan y G. Aden-Buie, “DT: A wrapper of the JavaScript library ‘DataTables’,” paquete de R, versión 0.34.0, 2025, doi: 10.32614/CRAN.package.DT.

[77] B. Auguié, “gridExtra: Miscellaneous functions for ‘grid’ graphics,” paquete de R, versión 2.3.1, 2026, doi: 10.32614/CRAN.package.gridExtra.

[78] L. Breiman, “Random forests,” *Mach. Learn.*, vol. 45, no. 1, pp. 5–32, 2001, doi: 10.1023/A:1010933404324.

[79] T. Chen y C. Guestrin, “XGBoost: a scalable tree boosting system,” en *Proc. 22nd ACM SIGKDD Int. Conf. Knowl. Discov. Data Min.*, San Francisco, CA, EE. UU., 2016, pp. 785–794, doi: 10.1145/2939672.2939785.

[80] S. M. Lundberg *et al.*, “From local explanations to global understanding with explainable AI for trees,” *Nat. Mach. Intell.*, vol. 2, no. 1, pp. 56–67, 2020, doi: 10.1038/s42256-019-0138-9.

[81] V. Cerqueira, L. Torgo e I. Mozetič, “Evaluating time series forecasting models: an empirical study on performance estimation methods,” *Mach. Learn.*, vol. 109, no. 11, pp. 1997–2028, 2020, doi: 10.1007/s10994-020-05910-7.

[82] J. Lu, A. Liu, F. Dong, F. Gu, J. Gama y G. Zhang, “Learning under concept drift: a review,” *IEEE Trans. Knowl. Data Eng.*, vol. 31, no. 12, pp. 2346–2363, 2019, doi: 10.1109/TKDE.2018.2876857.

[83] C. Strobl, A.-L. Boulesteix, A. Zeileis y T. Hothorn, “Bias in random forest variable importance measures: illustrations, sources and a solution,” *BMC Bioinformatics*, vol. 8, Art. no. 25, 2007, doi: 10.1186/1471-2105-8-25.

[84] S. Kapoor y A. Narayanan, “Leakage and the reproducibility crisis in machine-learning-based science,” *Patterns*, vol. 4, no. 9, Art. no. 100804, 2023, doi: 10.1016/j.patter.2023.100804.

[85] L. Grinsztajn, E. Oyallon y G. Varoquaux, “Why do tree-based models still outperform deep learning on typical tabular data?,” en *Adv. Neural Inf. Process. Syst. 35 (NeurIPS 2022), Datasets and Benchmarks Track*, Nueva Orleans, LA, EE. UU., 2022, doi: 10.48550/arXiv.2207.08815.

[86] J. H. Friedman, “Greedy function approximation: a gradient boosting machine,” *Ann. Stat.*, vol. 29, no. 5, pp. 1189–1232, 2001, doi: 10.1214/aos/1013203451.

[87] Y. Amadghous, I. Berrada, A. Zagriri, A. Aboulaich, K. Sefrioui Boujemaa y R. Beniazza, “Grade and tailing prediction in polymetallic flotation: DT ensembles vs ANNs on Moroccan industrial data,” en *Proc. 12th World Congr. Mech., Chem., Mater. Eng. (MCM’26)*, Londres, Reino Unido, 2026, Paper no. MMME 149, doi: 10.11159/mmme26.149.

[88] L. Zhao, F. Qu, H. Chen, Z. Liu, Y. Ji y X. Liu, “A dynamic relationship-aware approach to flotation concentrate grade prediction using DGraFormer,” *Separations*, vol. 13, no. 9, Art. no. 261, 2026, doi: 10.3390/separations13090261.

[89] Y. Yu *et al.*, “Study on the applicability of coal flotation reagent dosage prediction models trained based on a large amount of actual industrial on-site data,” *Int. J. Coal Prep. Util.*, publicación anticipada en línea, pp. 1–15, 2025, doi: 10.1080/19392699.2025.2601641.

[90] S. A. Pérez Cortés, E. H. Contreras Moreno, H. Flores Páez, J. P. Hurtado Cruz y J. A. Jarufe Troncoso, “Predictive model for water consumption in a copper mineral concentrator plant located in a desert area using machine learning,” *Water*, vol. 17, no. 1, Art. no. 15, 2025, doi: 10.3390/w17010015.

[91] M. S. Ben-Shachar *et al.*, “effectsize: Indices of effect size,” paquete de R, versión 1.0.3, 2026, doi: 10.32614/CRAN.package.effectsize.

Anexos

Anexo 1. Tabla de operacionalización de variables

VARIABLES DE ESTUDIO	DEFINICIÓN CONCEPTUAL	DEFINICIÓN OPERACIONAL	DIMENSIONES	INDICADORES	ESCALA DE MEDICIÓN
VI: Modelo predictivo basado en inteligencia artificial	Un modelo predictivo basado en inteligencia artificial es una herramienta computacional que emplea algoritmos de aprendizaje automático y análisis de datos para reconocer patrones en información histórica y actual, con el propósito de estimar comportamientos, eventos o resultados futuros. Su aplicación permite anticipar escenarios, reducir incertidumbre y apoyar la toma de decisiones mediante predicciones generadas a partir de datos [3], [7].				

VARIABLES DE ESTUDIO	DEFINICIÓN CONCEPTUAL	DEFINICIÓN OPERACIONAL	DIMENSIONES	INDICADORES	ESCALA DE MEDICIÓN
VD: Flotación de relaves de lixiviación	La flotación de relaves de lixiviación es un proceso fisicoquímico de concentración mineral aplicado a residuos sólidos posteriores a la lixiviación, cuyo objetivo es recuperar minerales valiosos remanentes mediante la separación selectiva por flotación [2], [3], [18].	La flotación de relaves de lixiviación se midió cuantitativamente mediante tres dimensiones: rendimiento de recuperación metálica, calidad del concentrado y eficiencia en el uso de insumos químicos, a partir de los registros de la ficha de recolección de datos operacionales y metalúrgicos.	Rendimiento de recuperación metálica	Recuperación de Au (%) $R = \frac{Cc \times L}{F \times f} \times 100$ i1 Donde R es la recuperación de Au (%), Cc es la masa del concentrado (t), L es la ley de Au en el concentrado (g/t), F es la masa de alimentación (t) y f es la ley de Au en la alimentación (g/t). [36], [38]	Razón
			Calidad del concentrado	Ley de Au en el concentrado (g/t) $L = \frac{Cf}{Cc}$ i2 Donde L es la ley de Au en el concentrado (g/t), Cf es el contenido de oro fino en el concentrado (g) y Cc es la masa del concentrado (t). [10], [36]	Razón
			Eficiencia en el uso de insumos químicos	Consumo específico de reactivos (kg/t) $Cerf = \frac{R_1 + R_2 + \cdots + R_n}{F}$ i3 Donde Cerf es el consumo específico de reactivos de flotación (kg/t); R_1, R_2, ⋯, R_n son los consumos de cada reactivo (kg) y F es la masa de alimentación (t). [12], [36]	Razón

Anexo 2. Instrumento de recolección de datos

INSTRUMENTO N° 01

FICHA DE RECOLECCIÓN DE DATOS OPERACIONALES Y METALÚRGICOS

Título de la investigación:

Aplicación de machine learning para predecir la flotación de relaves de lixiviación, Lima 2026.

Objetivo:

Recopilar y consolidar información histórica proveniente del sistema SCADA/PLC y de los reportes metalúrgicos para el entrenamiento, validación y evaluación de modelos predictivos basados en inteligencia artificial.

Unidad de análisis:

Registro operacional del proceso de flotación.

Fuente:

Sistema SCADA/PLC, reportes metalúrgicos de laboratorio y reportes de producción.

Periodo de análisis:

Enero – Setiembre 2026.

DATOS DE IDENTIFICACIÓN

Fecha: …….

Turno: …….

Hora: ……...

Línea/Celda: …….

Operador: …….

VARIABLES DE ENTRADA

1. Variables mineralógicas y de composición de la alimentación
    - Ley de Cu ccPy
    - Ley de Pb ccPy
    - Ley de Zn ccPy
    - Ley de Fe ccPy
    - Ley de As ccPy
    - Ley de Ag ccPy

- %H_2O ccPy (%)
- 200M_ccPy (%)
- Ley de Au de cabeza (g/t)
- Porcentaje de sólidos (%)
- % Insolubles (%)
- Densidad de pulpa (g/L)
- Granulometría -200 mallas (%)
- K30 (µm)
- K50 (µm)
- K80 (µm)

2. Variables de dosificación de reactivos
    - Sulfato de cobre (kg/t)
    - PAX + SIPX (Z-6 + Z-11) (kg/t)
    - MIBC (kg/t)
    - Metabisulfito de sodio (kg/t)
    - Antiespumante (kg/t)

3. Variables fisicoquímicas
    - pH inicial (adimensional)
    - pH final (adimensional)
    - Potencial redox (mV)
    - O_2 disuelto (mg/L)
    - FCN_Inic (ppm)
    - FCN_Fin (ppm)
    - CN libre residual (mg/L)

4. Variables operacionales e hidráulicas
    - Masa de alimentación (t)
    - Caudal de pulpa (m^3/h)
    - Q de agua de lavado, si aplica (m^3/h)
    - Nivel de pulpa (%)

- Tiempo de flotación (min)

5. Variables de aireación y formación de espuma
    - Caudal de aire (Nm^3/h)
    - Presión de aire (kPa)
    - Presión manifold (kPa)
    - Apertura de aire (%)
    - Altura de espuma (mm)

VARIABLES DE SALIDA

- Recuperación de Au (%)
- Ley de Au en el concentrado (g/t)
- Consumo específico de reactivos (kg/t)

Observaciones:

Anexo 3. Ficha de validación de contenido para un instrumento

VALIDACIÓN DE EXPERTOS

INSTRUCCIÓN: A continuación, se le hace llegar el instrumento de recolección de datos (Ficha de Observación), que permitirá recoger la información en la presente investigación: Aplicación de machine learning para predecir la flotación de relaves de lixiviación, Lima 2026. Por ello, se solicita que tenga a bien evaluar el instrumento y, de ser el caso, formular las sugerencias para realizar las correcciones pertinentes. Los criterios de validación de contenido son:

Criterios	Detalle	Calificación
Suficiencia	El ítem pertenece a la dimensión/subcategoría y basta para obtener la medición de esta.	1: de acuerdo 0: en desacuerdo
Claridad	El ítem se comprende fácilmente, es decir, su sintáctica y semántica son adecuadas.	1: de acuerdo 0: en desacuerdo
Coherencia	El ítem tiene relación lógica con el indicador que está midiendo.	1: de acuerdo 0: en desacuerdo
Relevancia	El ítem es esencial o importante, es decir, debe ser incluido.	1: de acuerdo 0: en desacuerdo

Nota. Criterios adaptados de la propuesta de Maldonado-Suárez y Santoyo-Telles [56].

Matriz de validación de la ficha de observación / variable

Flotación de relaves de lixiviación

Definición de la variable: La flotación de relaves de lixiviación es un proceso fisicoquímico de concentración mineral aplicado a residuos sólidos posteriores a la lixiviación, cuyo objetivo es recuperar minerales valiosos remanentes mediante la separación selectiva por flotación [2], [3], [18]. La flotación de relaves de lixiviación se mide cuantitativamente mediante tres dimensiones: rendimiento de recuperación metálica, calidad del concentrado y eficiencia en el uso de insumos químicos.

Dimensión	Indicador	Suficiencia	Claridad	Coherencia	Relevancia	Observación
Rendimiento de recuperación metálica	Recuperación de Au (%)	1	1	1	1	
Calidad del concentrado	Ley de Au en el concentrado (g/t)	1	1	1	1	
Eficiencia en el uso de insumos químicos	Consumo específico de reactivos (kg/t)	1	1	1	1	

Ficha de validación de juicio de experto

Nombre del instrumento	Flotación de relaves de lixiviación
Objetivo del instrumento	Poder medir variables y dimensiones
Nombres y apellidos del experto	Christian Josué Vargas Vega
Documento de identidad	45078305
Años de experiencia en el área	13 años
Máximo grado académico	Magíster
Nacionalidad	Peruana
Institución	UNIVERSIDAD DEL CALLAO
Cargo	Docente
Número telefónico	+51 950594545
Firma	
Fecha	18/06/2026

PERÚ | Superintendencia Nacional de Educación Superior Universitaria | Dirección de Registro y Reconocimiento de Grados y Títulos e Información Universitaria

REGISTRO NACIONAL DE GRADOS ACADÉMICOS Y TÍTULOS PROFESIONALES

Graduado	Grado o Título	Institución
VARGAS VEGA, CHRISTIAN JOSUE **DNI 45078305**	INGENIERO INDUSTRIAL Fecha de diploma: 23/05/2011	UNIVERSIDAD NACIONAL DEL CALLAO ***PERU***
VARGAS VEGA, CHRISTIAN JOSUE **DNI 45078305**	BACHILLER EN INGENIERIA INDUSTRIAL Fecha de diploma: 27/09/2010 Fecha matrícula: Sin información (***) Fecha egreso: Sin información (***)	UNIVERSIDAD NACIONAL DEL CALLAO ***PERU***
VARGAS VEGA, CHRISTIAN JOSUE **DNI 45078305**	MAESTRO EN INGENIERÍA INDUSTRIAL CON MENCIÓN EN GERENCIA DE LA CALIDAD Y PRODUCTIVIDAD Fecha de diploma: 13/10/2023 Fecha matrícula: 18/08/2014 Fecha egreso: 31/07/2016	UNIVERSIDAD NACIONAL DEL CALLAO ***PERU***
VARGAS VEGA, CHRISTIAN JOSUE **DNI 45078305**	MAESTRO EN EDUCACIÓN Fecha de diploma: 13/11/23 Fecha matrícula: 02/09/2019 Fecha egreso: 16/08/2023	UNIVERSIDAD CÉSAR VALLEJO S.A.C. ***PERU***
VARGAS VEGA, CHRISTIAN JOSUE **DNI 45078305**	SEGUNDA ESPECIALIDAD EN POLÍTICAS EDUCATIVAS Y GESTIÓN PÚBLICA Fecha de diploma: 10/03/25 Fecha matrícula: 01/04/2024 Fecha egreso: 28/01/2025	UNIVERSIDAD CÉSAR VALLEJO S.A.C. ***PERU***
VARGAS VEGA, CHRISTIAN JOSUE **DNI 45078305**	SEGUNDA ESPECIALIDAD EN INGENIERÍA DE PROCESOS Fecha de diploma: 18/05/26 Fecha matrícula: 01/04/2025 Fecha egreso: 28/01/2026	UNIVERSIDAD CÉSAR VALLEJO S.A.C. ***PERU***

Matriz de validación de la ficha de observación / variable

Flotación de relaves de lixiviación

Definición de la variable: La flotación de relaves de lixiviación es un proceso fisicoquímico de concentración mineral aplicado a residuos sólidos posteriores a la lixiviación, cuyo objetivo es recuperar minerales valiosos remanentes mediante la separación selectiva por flotación [2], [3], [18]. La flotación de relaves de lixiviación se mide cuantitativamente mediante tres dimensiones: rendimiento de recuperación metálica, calidad del concentrado y eficiencia en el uso de insumos químicos.

Dimensión	Indicador	Suficiencia	Claridad	Coherencia	Relevancia	Observación
Rendimiento de recuperación metálica	Recuperación de Au (%)	1	1	1	1	
Calidad del concentrado	Ley de Au en el concentrado (g/t)	1	1	1	1	
Eficiencia en el uso de insumos químicos	Consumo específico de reactivos (kg/t)	1	1	1	1	

Ficha de validación de juicio de experto

Nombre del instrumento	Flotación de relaves de lixiviación
Objetivo del instrumento	Poder medir variables y dimensiones
Nombres y apellidos del experto	Aldo Enrique Farfán Sánchez
Documento de identidad	10032391
Años de experiencia en el área	13 años
Máximo grado académico	Maestro
Nacionalidad	Peruana
Institución	IESTP “ANTENOR ORREGO ESPINOZA”
Cargo	Docente
Número telefónico	+51 917217065
Firma	
Fecha	18/06/2026

PERÚ | Superintendencia Nacional de Educación Superior Universitaria | Dirección de Registro y Reconocimiento de Grados y Títulos e Información Universitaria

REGISTRO NACIONAL DE GRADOS ACADÉMICOS Y TÍTULOS PROFESIONALES

Graduado	Grado o Título	Institución
FARFAN SANCHEZ, ALDO ENRIQUE **DNI 10032391**	INGENIERO DE SISTEMAS DE INFORMATICA Fecha de diploma: 14/01/2014	UNIVERSIDAD ALAS PERUANAS S.A. ***PERU***
FARFAN SANCHEZ, ALDO ENRIQUE **DNI 10032391**	BACHILLER EN INGENIERIA DE SISTEMAS Y COMPUTACION Fecha de diploma: 27/05/2013 Fecha matrícula: Sin información (***) Fecha egreso: Sin información (***)	UNIVERSIDAD PERUANA LOS ANDES ***PERU***
FARFAN SANCHEZ, ALDO ENRIQUE **DNI 10032391**	MAESTRO EN EDUCACIÓN MENCIÓN EN: DOCENCIA EN EDUCACIÓN SUPERIOR Fecha de diploma: 28/12/22 Fecha matrícula: 20/09/2014 Fecha egreso: 24/07/2016	UNIVERSIDAD PERUANA LOS ANDES ***PERU***

Matriz de validación de la ficha de observación / variable

Flotación de relaves de lixiviación

Definición de la variable: La flotación de relaves de lixiviación es un proceso fisicoquímico de concentración mineral aplicado a residuos sólidos posteriores a la lixiviación, cuyo objetivo es recuperar minerales valiosos remanentes mediante la separación selectiva por flotación [2], [3], [18]. La flotación de relaves de lixiviación se mide cuantitativamente mediante tres dimensiones: rendimiento de recuperación metálica, calidad del concentrado y eficiencia en el uso de insumos químicos.

Dimensión	Indicador	Suficiencia	Claridad	Coherencia	Relevancia	Observación
Rendimiento de recuperación metálica	Recuperación de Au (%)	1	1	1	1	
Calidad del concentrado	Ley de Au en el concentrado (g/t)	1	1	1	1	
Eficiencia en el uso de insumos químicos	Consumo específico de reactivos (kg/t)	1	1	1	1	

Ficha de validación de juicio de experto

Nombre del instrumento	Flotación de relaves de lixiviación
Objetivo del instrumento	Poder medir variables y dimensiones
Nombres y apellidos del experto	Brian Keith Huby Silva
Documento de identidad	41636207
Años de experiencia en el área	15 años
Máximo grado académico	Maestro
Nacionalidad	Peruana
Institución	UNIVERSIDAD PRIVADA DEL NORTE
Cargo	Docente
Número telefónico	+51 940202471
Firma	
Fecha	18/06/2026

PERÚ | Superintendencia Nacional de Educación Superior Universitaria | Dirección de Registro y Reconocimiento de Grados y Títulos e Información Universitaria

REGISTRO NACIONAL DE GRADOS ACADÉMICOS Y TÍTULOS PROFESIONALES

Graduado	Grado o Título	Institución
HUBY SILVA, BRIAN KEITH **DNI 41636207**	INGENIERO DE MINAS Fecha de diploma: 25/03/2011	UNIVERSIDAD NACIONAL DE TRUJILLO ***PERU***
HUBY SILVA, BRIAN KEITH **DNI 41636207**	BACHILLER EN INGENIERIA DE MINAS Fecha de diploma: 26/06/2009 Fecha matrícula: Sin información (***) Fecha egreso: Sin información (***)	UNIVERSIDAD NACIONAL DE TRUJILLO ***PERU***
HUBY SILVA, BRIAN KEITH **DNI 41636207**	MAESTRO EN INVESTIGACIÓN Y DOCENCIA UNIVERSITARIA Fecha de diploma: 23/04/25 Fecha matrícula: 05/10/2019 Fecha egreso: 04/10/2020	UNIVERSIDAD CATÓLICA DE TRUJILLO BENEDICTO XVI ***PERU***

Validación de la ficha de observación por V de Aiken / variable

Flotación de relaves de lixiviación

ITEM	VD: FLOTACIÓN DE RELAVES DE LIXIVIACIÓN
DIM. 1: Rendimiento de recuperación metálica	INDIC. 1: Recuperación de Au (%)
DIM. 2: Calidad del concentrado	INDIC. 2: Ley de Au en el concentrado (g/t)
DIM. 3: Eficiencia en el uso de insumos químicos	INDIC. 3: Consumo específico de reactivos (kg/t)

EXPERTO	SUFICIENCIA			CLARIDAD			COHERENCIA			RELEVANCIA		
	I1	I2	I3	I1	I2	I3	I1	I2	I3	I1	I2	I3
CHRISTIAN JOSUE VARGAS VEGA	1	1	1	1	1	1	1	1	1	1	1	1
ALDO ENRIQUE FARFAN SANCHEZ	1	1	1	1	1	1	1	1	1	1	1	1
BRIAN KEITH HUBY SILVA	1	1	1	1	1	1	1	1	1	1	1	1
Nro. de expertos (n): 3												
Nro. de valores (c): 2												
Suma (S)	3	3	3	3	3	3	3	3	3	3	3	3
V de Aiken por pregunta	1.00	1.00	1.00	1.00	1.00	1.00	1.00	1.00	1.00	1.00	1.00	1.00
V de Aiken por criterio	1.00			1.00			1.00			1.00		
V de Aiken general	**1.00**											

Anexo 4. Solicitud de autorización para realizar la investigación en una institución

Barranca, 24 de mayo de 2026

Señor: Ing. Fredy Palomino Huaroto – Jefe de Planta Concentradora

Copperfield Perú SAC

Presente.-

Es grato dirigirme a usted para saludarlo, y a la vez manifestarle que, dentro de mi formación académica en la experiencia curricular de investigación del 1°ciclo, se contempla la realización de una investigación con fines netamente académicos para la obtención de mi Grado de Maestro en Inteligencia Artificial.

En tal sentido, considerando la relevancia de su organización, solicito su colaboración para que pueda realizar mi investigación en su representada y obtener la información necesaria para poder desarrollar la investigación titulada "Modelo predictivo basado en inteligencia artificial aplicado a la flotación de relaves de lixiviación en el norte del Perú, 2026". En dicha investigación me comprometo a mantener en reserva el nombre o cualquier distintivo de la empresa, salvo que se crea a bien su socialización.

Se adjunta la carta de autorización de uso de información en caso de que se considere la aceptación de esta solicitud para ser llenada por el representante de la empresa.

Agradeciéndole anticipadamente por vuestro apoyo en favor de mi formación profesional, hago propicia la oportunidad para expresar las muestras de mi especial consideración.

Atentamente,

Edwin Miguel Barboza Duran

DNI Nº 20119834



Anexo 5. Autorización de uso de información de una institución

Yo, Fredy Palomino Huaroto, identificado con DNI: 42092820, en mi calidad de Jefe de Planta Concentradora

OTORGO LA AUTORIZACION

Al señor: Edwin Miguel Barboza Duran, identificado con DNI N° 20119834, del Programa de Estudios de la Maestría en Inteligencia Artificial de la Universidad César Vallejo, para que tengan acceso y empleen datos e información de la planta de beneficio de minerales, con la finalidad de que pueda desarrollar su trabajo de investigación titulado: Modelo predictivo basado en inteligencia artificial aplicado a la flotación de relaves de lixiviación en el norte del Perú, 2026
Indicar si el representante que autoriza la información de la institución solicita mantener el nombre o cualquier distintivo de la empresa en reserva, marcando con una X la opción seleccionada.

(X) Mantener en reserva el nombre o cualquier distintivo de la empresa o
( ) Mencionar el nombre de la empresa



DNI N° 42092820

El estudiante declara que los datos emitidos en esta carta y en el Trabajo de Investigación son auténticos. En caso de comprobarse la falsedad de datos, el estudiante será sometido al inicio del procedimiento disciplinario correspondiente, asimismo, asumirá toda la responsabilidad ante posibles acciones legales que la empresa, otorgante de información, pueda ejecutar.



DNI N° 20119834

Anexo 6. Matriz de consistencia

PROBLEMAS	OBJETIVOS	HIPÓTESIS	VARIABLES Y DIMENSIONES	METODOLOGÍA
Problema general ¿En qué medida el modelo predictivo basado en inteligencia artificial permite predecir la flotación de relaves de lixiviación, Lima 2026?	**Objetivo general** Determinar en qué medida el modelo predictivo basado en inteligencia artificial permite predecir la flotación de relaves de lixiviación, Lima 2026.	**Hipótesis general** **Ho:** El modelo predictivo basado en inteligencia artificial no presenta un desempeño predictivo adecuado para estimar la flotación de relaves de lixiviación. Esto se evidencia cuando, en al menos una de las variables objetivo (recuperación de Au, ley de Au en el concentrado o consumo específico de reactivos), tanto Random Forest como XGBoost obtienen en el conjunto de prueba al menos uno de estos resultados: $R^2 < 0.75$, MAPE > 10 %, o un MAE o un RMSE igual o mayor que el del modelo base, Lima 2026. **Hi:** El modelo predictivo basado en inteligencia artificial presenta un desempeño predictivo adecuado para estimar la flotación de relaves de lixiviación. Esto se evidencia cuando, en cada una de las tres variables objetivo, al menos uno de los algoritmos, Random Forest o XGBoost, obtiene a la vez en el conjunto de prueba un $R^2 \geq 0.75$, un MAPE ≤ 10 %, y un MAE y un RMSE menores que los del modelo base, Lima 2026. **Regla de decisión:** se acepta Hi cuando se aceptan Hi1, Hi2 y Hi3.	**VI: Modelo predictivo basado en inteligencia artificial** **VD: Flotación de relaves de lixiviación** **D1:** Rendimiento de recuperación metálica (**I1:** Recuperación de Au, %). **D2:** Calidad del concentrado (**I2:** Ley de Au en el concentrado, g/t). **D3:** Eficiencia en el uso de insumos químicos (**I3:** Consumo específico de reactivos, kg/t).	**Tipo:** aplicada. **Enfoque:** cuantitativo. **Diseño:** no experimental, transversal y predictivo. **Alcance:** explicativo. **Población:** registros operacionales del circuito de flotación de relaves de lixiviación, enero a setiembre de 2026. **Muestra:** censo de 547 registros válidos. **Técnica:** observación estructurada. **Instrumento:** ficha de recolección de datos operacionales y metalúrgicos (V de Aiken = 1.00). **Análisis:** Random Forest y XGBoost con partición temporal, comparados con un modelo base de media histórica; métricas R^2, MAE, RMSE y MAPE; prueba de Diebold-Mariano; importancia de variables (%IncMSE y Gain).
PE1 ¿En qué medida el modelo predictivo basado en inteligencia artificial permite predecir el rendimiento de la recuperación metálica, Lima 2026?	**OE1** Determinar en qué medida el modelo predictivo basado en inteligencia artificial permite predecir el rendimiento de la recuperación metálica, Lima 2026.	**HE1** **Ho1:** El modelo predictivo basado en inteligencia artificial no presenta una capacidad predictiva adecuada para estimar el rendimiento de la recuperación metálica, expresado mediante la recuperación de Au (%). Esto se evidencia cuando tanto Random Forest como XGBoost obtienen en el conjunto de prueba al menos uno de estos resultados: $R^2 < 0.75$, MAPE > 10 %, o un MAE o un RMSE igual o mayor que el del modelo base, Lima 2026. **Hi1:** El modelo predictivo basado en inteligencia artificial presenta una capacidad predictiva adecuada para estimar el rendimiento de la recuperación metálica, expresado mediante la recuperación de Au (%). Esto se evidencia cuando al menos uno de los algoritmos, Random Forest o XGBoost, obtiene a la vez en el conjunto de prueba un $R^2 \geq 0.75$, un MAPE ≤ 10 %, y un MAE y un RMSE menores que los del modelo base, Lima 2026.		
PE2 ¿En qué medida el modelo predictivo basado en inteligencia artificial permite predecir la calidad del concentrado, Lima 2026?	**OE2** Determinar en qué medida el modelo predictivo basado en inteligencia artificial permite predecir la calidad del concentrado, Lima 2026.	**HE2** **Ho2:** El modelo predictivo basado en inteligencia artificial no presenta una capacidad predictiva adecuada para estimar la calidad del concentrado, expresada mediante la ley de Au en el concentrado (g/t). Esto se evidencia cuando tanto Random Forest como XGBoost obtienen en el conjunto de prueba al menos uno de estos resultados: $R^2 < 0.75$, MAPE > 10 %, o un MAE o un RMSE igual o mayor que el del modelo base, Lima 2026. **Hi2:** El modelo predictivo basado en inteligencia artificial presenta una capacidad predictiva adecuada para estimar la calidad del concentrado, expresada mediante la ley de Au en el concentrado (g/t). Esto se evidencia cuando al menos uno de los algoritmos, Random Forest o XGBoost, obtiene a la vez en el conjunto de prueba un $R^2 \geq 0.75$, un MAPE ≤ 10 %, y un MAE y un RMSE menores que los del modelo base, Lima 2026.		
PE3 ¿En qué medida el modelo predictivo basado en inteligencia artificial permite predecir la eficiencia en el uso de insumos químicos, Lima 2026?	**OE3** Determinar en qué medida el modelo predictivo basado en inteligencia artificial permite predecir la eficiencia en el uso de insumos químicos, Lima 2026.	**HE3** **Ho3:** El modelo predictivo basado en inteligencia artificial no presenta una capacidad predictiva adecuada para estimar la eficiencia en el uso de insumos químicos, expresada mediante el consumo específico de reactivos (kg/t). Esto se evidencia cuando tanto Random Forest como XGBoost obtienen en el conjunto de prueba al menos uno de estos resultados: $R^2 < 0.75$, MAPE > 10 %, o un MAE o un RMSE igual o mayor que el del modelo base, Lima 2026. **Hi3:** El modelo predictivo basado en inteligencia artificial presenta una capacidad predictiva adecuada para estimar la eficiencia en el uso de insumos químicos, expresada mediante el consumo específico de reactivos (kg/t). Esto se evidencia cuando al menos uno de los algoritmos, Random Forest o XGBoost, obtiene a la vez en el conjunto de prueba un $R^2 \geq 0.75$, un MAPE ≤ 10 %, y un MAE y un RMSE menores que los del modelo base, Lima 2026.		
PE4 ¿Cuál de los modelos, Random Forest o XGBoost, presenta un mejor desempeño en la predicción de la flotación de relaves de lixiviación, Lima 2026?	**OE4** Comparar el desempeño de los modelos Random Forest y XGBoost para identificar cuál presenta mayor capacidad predictiva en la flotación de relaves de lixiviación, Lima 2026.	**HE4** **Ho4:** Ninguno de los modelos, Random Forest o XGBoost, presenta un desempeño predictivo significativamente superior al del otro en las variables objetivo de la flotación de relaves de lixiviación. Esto se evidencia cuando, en cada variable, ocurre en el conjunto de prueba al menos una de estas situaciones: ningún algoritmo obtiene a la vez mayor R^2 y menores RMSE, MAE y MAPE que el otro; la prueba de Diebold-Mariano da $p \geq 0.05$ con los errores al cuadrado o con los errores absolutos, Lima 2026. **Hi4:** Uno de los modelos, Random Forest o XGBoost, presenta un desempeño predictivo significativamente superior al del otro en al menos una de las variables objetivo de la flotación de relaves de lixiviación. Esto se evidencia cuando, en esa variable, el algoritmo superior cumple a la vez en el conjunto de prueba estas condiciones: obtiene mayor R^2 y menores RMSE, MAE y MAPE que el otro; la prueba de Diebold-Mariano da $p < 0.05$ tanto con los errores al cuadrado como con los errores absolutos, Lima 2026.		

Anexo 7. Reporte de similitud del software Turnitin